

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS NATURAIS E EXATAS
DEPARTAMENTO DE ESTATÍSTICA

CONTROLE ESTATÍSTICO DO PROCESSO

4^a. Edição

Prof. Fernando J. Moreira Jr.

Santa Maria, janeiro de 2021.

SUMÁRIO

1.	Introdução ao Controle Estatístico do Processo	5
1.1.	Considerações Iniciais	5
1.2.	Breve Histórico	6
1.3.	Sistema de Controle e CEP	8
1.4.	Etapas para a Implantação do CEP	9
1.4.1.	Desdobramento da qualidade	10
1.4.2.	Desdobramento dos processos	12
1.4.3.	Direcionamento das ações	15
1.4.4.	Identificação dos postos de controle e parâmetros e características de qualidade do processo a serem monitorados	16
1.4.5.	Definição de critérios de classificação dos produtos	17
1.4.6.	Definição dos parâmetros e características de qualidade do processo ...	17
1.4.7.	Definição do procedimento de coleta de dados	17
1.4.8.	Avaliação do sistema de medição	18
1.4.9.	Definição das responsabilidades	18
1.4.10.	Definição da documentação necessária e Treinamento	18
1.4.11.	Implantação efetiva, acompanhamento e consolidação	19
2.	Ferramentas da Qualidade	20
2.1.	Fluxograma	20
2.2.	Folha de Verificação	21
2.3.	Diagrama de Concentração de Defeitos	22
2.4.	Brainstorming	23
2.5.	Técnica Nominal de Grupo	23
2.6.	Análise do Campo de Forças	24
2.7.	Histograma	25
2.8.	Gráfico de Ramo-e-Folhas	27
2.9.	Gráfico de Pareto	28
2.10.	Diagrama de Causa e Efeito	29
2.11.	Gráfico de Dispersão	31
2.12.	Gráfico Sequencial	33
2.13.	Estratificação	33
2.14.	Gráficos de Controle	34
2.15.	Capabilidade do Processo	36
3.	Gráficos de Controle e Capacidade do Processo	40
3.1.	Tipos de Causas da Variabilidade do Processo	40
3.1.1.	Causas Comuns	40
3.1.2.	Causas Especiais	42
3.1.3.	Causas Estruturais	45
3.2.	Procedimentos Gerais para a Elaboração de Gráficos de Controle	46
3.3.	Gráficos de Controle para Variáveis	48
3.3.1.	Gráfico de Controle para a Média e para a Amplitude	49
3.3.2.	Gráfico de Controle para a Média e para o Desvio Padrão	62
3.3.3.	Gráfico de Controle para Valores Individuais e Amplitude Móvel	67
3.4.	Gráficos de Controle para Atributos	70
3.4.1.	Gráfico de Controle para a Proporção de Não-Conformes: Gráfico p ...	71
3.4.2.	Gráfico de Controle para o Número de Não-Conformes: Gráfico np	76
3.4.3.	Gráfico de Controle para o Número de Não-Conformidades: Gráfico c 79	

3.4.4.	Gráfico de Controle para o Número de Não-Conformidades por Unidade: o Gráfico u	81
4.	A Função de Perda Quadrática	84
4.1.	A Função de Perda Quadrática para Características da Qualidade do Tipo Nominal-é-Melhor	85
4.2.	A Função de Perda Quadrática para Características da Qualidade do Tipo Maior-é-Melhor	87
4.3.	A Função de Perda Quadrática para Características da Qualidade do Tipo Menor-é-Melhor	88
4.4.	Utilidade da Função de Perda Quadrática	89
5.	Análise de Sistemas de Medição	90
5.1.	Estabilidade	90
5.2.	Tendência.....	91
5.3.	Linearidade	92
5.4.	Repetitividade.....	92
5.5.	Reprodutividade	93
5.6.	R&R.....	93
5.7.	Variação Peça-a-Peça	94
5.8.	Variação Total do Processo	94
5.9.	Avaliação do Sistema de Medição.....	94
5.10.	Métodos de Estudos de R&R.....	95
5.10.1.	O Método da amplitude	96
5.10.2.	O Método da média e amplitude	96
5.10.3.	O Método da ANOVA.....	97
5.11.	Sistemas de Medição para Atributos	99
6.	Gráficos de Controle Especiais	101
6.1.	Gráfico de Controle de Somas Acumuladas (CUSUM).....	101
6.2.	Gráfico de Controle de Médias Móveis Exponencialmente Ponderadas (MMEP).....	105
6.3.	Gráfico de Controle para Médias Móveis.....	106
6.4.	Gráfico de Controle para a Mediana e para a Amplitude.....	108
6.5.	Gráficos para dados autocorrelacionados.....	110
6.5.1.	Metodologia Box-Jenkins aplicada ao CEP	110
6.6.	Gráficos de Controle Multivariados	116
6.7.	Outros Gráficos de Controle.....	120
	Referências	121
	Anexos.....	123

PREFÁCIO (4ª. Edição)

O objetivo da elaboração dessa apostila foi aliar teoria e prática sobre o Controle Estatístico do Processo (CEP) de tal forma que o conteúdo resultante contemple o conteúdo programático e atenda às necessidades dos alunos das disciplinas STC1090 (Controle Estatístico do Processo) do curso de Bacharelado em Estatística e STC 851 (Controle Estatístico do Processo) do Programa de Pós Graduação em Estatística e Modelagem Quantitativa (PPGEM) da Universidade Federal de Santa Maria - UFSM. Embora essas duas disciplinas não tenham exatamente a mesma ementa, essa apostila foi elaborada de forma a abranger os conteúdos de ambas as disciplinas, além de abordar outros conteúdos importantes de CEP que não constam nas ementas das disciplinas. O conteúdo dessa apostila foi desenvolvido com base em livros, artigos e outras apostilas sobre o assunto.

Procurou-se dar uma visão geral sobre o controle estatístico da qualidade com ênfase no controle estatístico do processo. O conteúdo desenvolvido aqui aborda basicamente as ferramentas da qualidade, os gráficos de controle, a função da perda quadrática e a análise de sistemas de medição, indo além do previsto pelo conteúdo programático das disciplinas. Procurou-se sempre apresentar os aspectos teóricos ilustrados com aplicações práticas reais, a fim de que o leitor possa ter uma visão prática de todo o conteúdo abordado.

Na segunda edição dessa apostila foram corrigidas eventuais falhas decorrentes de erros de digitação, foram inseridos exemplos em Seções que não tinham exemplo, outros exemplos foram alterados e melhorados e, ainda, foi aumentada a quantidade de exemplos. A ordem de alguns conteúdos foi alterada de forma a deixar o material mais claro, sistemático e organizado. Foram acrescentadas algumas informações a respeito da fundamentação teórico-estatística dos gráficos de controles que não são apresentadas na maioria dos livros sobre CEP. Também foram feitas atualizações em algumas Seções.

Na terceira edição foram feitas algumas correções e padronizações de fórmulas e notações.

Na quarta edição foi feita uma revisão mais ampla, algumas Seções foram ampliadas, foram incluídos mais exemplos e foram feitas algumas atualizações.

Espera-se que o material criado seja de grande utilidade aos alunos e que também possa servir para possíveis consultas na aplicação prática de um CEP.

Santa Maria, janeiro de 2021.

1. Introdução ao Controle Estatístico do Processo

1.1. Considerações Iniciais

Controle da qualidade (CQ) é um conjunto de ações ou medidas desenvolvidas com o objetivo de assegurar que os serviços ou produtos gerados atendam aos requisitos segundo os quais foram especificados. De acordo com a ISO 8402, Controle da Qualidade é definido como sendo o conjunto de “técnicas e atividades operacionais usadas para atender os requisitos para a qualidade” (LOPES, 2007).

Uma das ferramentas utilizadas no controle da qualidade é o controle estatístico do processo (CEP). Conforme Ribeiro e Ten Caten (2011), o CEP é uma técnica estatística geralmente aplicada à produção que permite a redução sistemática da variabilidade nas características da qualidade de interesse, contribuindo para a melhoria da qualidade intrínseca, da produtividade, da confiabilidade e do custo do que está sendo produzido.

Para Lopes (2007), o CEP pode ser definido por meio da junção dos significados de cada uma das palavras:

- Controle: manter algo dentro dos limites (padrões) ou fazer algo se comportar de forma adequada.
- Estatística: obter conclusões com base em dados e números que trazem informações.
- Controle Estatístico: fazer com que os resultados se mantenham conforme o previsto pelos padrões com a ajuda de estatísticas obtidas de dados numéricos.
- Processo: é uma combinação entre o homem, os materiais, as máquinas, os equipamentos e o meio ambiente para fabricar um determinado produto ou para fornecer um serviço. Em outras palavras, um processo é qualquer conjunto de condições ou conjunto de causas (sistema de causas) que trabalham simultaneamente para produzir um determinado resultado.

Dessa forma, segundo o raciocínio de Lopes (2007), pode-se concluir que CEP é um método preventivo de se comparar, continuamente, os resultados de um processo com os padrões, identificando a partir de dados estatísticos as tendências para variações significativas, a fim de eliminar/controlar essas variações.

O controle estatístico do processo pode ser considerado um sistema de inspeção por amostragem, operando ao longo do processo, com o objetivo de verificar a presença de causas especiais, que são causas que não são naturais ao processo e que podem prejudicar a qualidade do produto ou serviço. Dessa forma, o CEP fornece uma espécie de “radiografia” do processo, identificando sua variabilidade e possibilitando o controle dessa variabilidade ao longo do tempo através da coleta de dados continuada, análise e bloqueio de possíveis causas especiais que estejam tornando o sistema instável. Num ambiente competitivo, o controle estatístico abre caminho para melhorias contínuas, uma vez que garante um processo estável, previsível, com uma identidade e capacidade definidas, cuja evolução pode ser facilmente acompanhada (RIBEIRO/ TEN CATEN, 2011).

Dessa forma, os objetivos do CEP são:

- Realizar um diagnóstico inicial do processo, por meio de coleta de dados e da análise desses por meio das ferramentas estatísticas da qualidade (histograma, gráfico de pareto, gráfico de controle, etc.).
- Identificar, atuar sobre e prevenir as causas especiais de um processo.

- Estabelecer limites de controle e controlar o processo.
- Verificar a capacidade do processo sob controle e atuar nele (na centralização ou na variação) para melhorar a capacidade.
- Monitorar as características de interesse, assegurando que elas irão se manter dentro de limites preestabelecidos e indicando quando devem ser tomadas ações de correção e melhoria. Quanto mais cedo se detectar os defeitos, menos matéria-prima será colocada fora e a mão-de-obra não será perdida com um produto defeituoso.
- Possibilitar um controle eficaz da qualidade, feito pelo próprio operador em tempo real. Consequentemente, isso aumenta o comprometimento do operador com a qualidade do que está sendo produzido e permite com que a gerência não se ocupe com os problemas operacionais e esteja disponível para se dedicar às tarefas de melhoria.
- Aumentar a capacidade dos processos. Consequentemente, se reduz o refugo e o retrabalho, e o chamado “custo da má qualidade”. Assim, ele proporciona às empresas a base para melhorar a qualidade de produtos e serviços e, simultaneamente, reduzir substancialmente o custo da má qualidade.

1.2. Breve Histórico

Não é possível saber com precisão quando foi que o controle da qualidade começou a ser utilizado, de forma sistemática, de modo a assegurar que os resultados das ações empreendidas viessem a atender aos requisitos dos projetos, na forma como foram concebidos. Entretanto, a perfeição das obras remanescentes das civilizações grega, romana, egípcia, chinesa, e outras, sob a forma de templos, termas, pirâmides, muralhas, etc., nos permite assegurar que alguma forma de controle devia ser por eles empregada (LOPES, 2007).

Registros históricos mostram que até o final do século XVIII, antes do início da era industrial, os empreendimentos eram, na sua maioria, de natureza individual ou familiar e cada um definia e controlava a qualidade dos produtos ou serviços que gerava. Curiosamente, esta é uma postura muito atual. No que se refere a “garantia da qualidade”, “cada um é responsável pela qualidade do que faz” A diferença entre um profissional do final do século XVIII e um dos anos 90 em diante é apresentada no **Erro! Fonte de referência não encontrada.** (LOPES, 2007).

Profissional do século XVIII	Profissional dos anos 90 em diante
- A “qualidade” estava relacionada ao atendimento as especificações do produto, quase sempre definidas por ele mesmo. - Ele definia o que deveria ser “qualidade”, produzia e, eventualmente, quase sempre sem uma programação específica definida, inspecionava o produto para verificar se estava conforme as suas especificações.	- A “qualidade” é definida pelo cliente. O profissional dos anos 90 deve produzir e controlar a qualidade do que ele produz. - O controle da qualidade por ele exercido é feito de forma sistematizada; é planejado de forma a cobrir todas as fases do processo e tem por objetivo assegurar que as necessidades do seu cliente vão ser atendidas.

Quadro 1. Diferença entre os profissionais

Com o advento da era industrial, uma nova fase para o controle da qualidade iniciou-se no início do século 20. As primeiras inspeções realizadas eram feitas no produto acabado e tinha por objetivo evitar que itens defeituosos chegassem ao

consumidor. Até então, nenhuma técnica estatística era usada. No final dos anos 20, como decorrência da crescente complexidade dos processos e da maior concorrência do mercado, iniciou-se a utilização de técnicas estatísticas para o controle dos produtos. Em 1924, foi criado o *Inspection Engineering Department of Western Electric's Bell Telephone Laboratories*, do qual foram membros personalidades como R. B. Miller, G. D. Peterson, H. F. Dodge, G. D. Edwards, P. S. Olmstead, M. N. Torrey e outros, aos quais devemos importantes trabalhos pioneiros de desenvolvimento de teorias e métodos de controle da qualidade, incluindo critérios para seleção e amostragem (LOPES, 2007). Muitos autores consideram que o controle da qualidade iniciou na década de 20, nos Estados Unidos.

O primeiro gráfico de controle (ou carta de controle) da qual se tem registro foi desenvolvido por Shewhart em 1924 e ficou conhecida como “Carta de Controle de Shewhart”. O Dr. Walter Shewhart desenvolveu uma técnica simples, porém, poderosa para fazer a distinção entre causas comuns e causas especiais. Ele propôs o uso das cartas de controle para a análise dos dados provenientes de amostragem, substituindo a mera detecção e correção de produtos defeituosos pelo estudo e prevenção dos problemas relacionados à qualidade, visando impedir que produtos defeituosos fossem produzidos. Na sequência, o controle da qualidade foi também adotado na Inglaterra. Em 1935, os trabalhos do estatístico E. S. Pearson foram utilizados como base para os padrões normativos britânicos (RIBEIRO; TEN CATEN, 2011).

Entre 1930 e 1940, o uso da estatística como ferramenta para o controle da qualidade se consolidou como técnica. Destacam-se nesse período os trabalhos do *Joint Committee for the Development of Statistical Applications in Engineering and Manufacturing*, presidido por Shewhart e apoiado pela *American Society for Testing Materials (ASTM)*, *American Society of Mechanical Engineers (ASME)*, *American Mathematical Society (AMS)*, *American Statistical Association (ASA)*, *Institute of Mathematical Statistics (IMS)* e o *American Institute of Electrical Engineers (AIEE)* (LOPES, 2007).

Na década de 40, o uso da estatística como ferramenta para o controle da qualidade se consolidou como prática indispensável, principalmente devido às condições impostas pela economia de guerra. A necessidade de massificar a produção levou a uma inevitável deterioração da qualidade dos produtos. Esse fato obrigou o sistema produtivo a utilizar, em escala sem precedentes, as técnicas estatísticas que já haviam sido desenvolvidas para o controle de produtos. Nesse período, intensivos programas de treinamento, orientados para a utilização destas técnicas, foram implementados, com os objetivos de: minimizar perdas, reduzir o custo de produção e, principalmente, assegurar a qualidade dos produtos. Nesse período, as forças armadas dos Estados Unidos e dos países aliados desempenharam um papel importantíssimo no desenvolvimento de novas técnicas estatísticas, na pesquisa de novas teorias de controle, na implementação de programas de controle da qualidade e, principalmente, no estabelecimento de padrões (LOPES, 2007).

De 1950 a 1960, as forças armadas dos países aliados, principalmente devido à guerra fria, que demandava contínuos e intensos programas de desenvolvimentos na área da indústria bélica, continuaram sendo os principais impulsionadores do desenvolvimento da área de controle da qualidade. Os principais esforços dos anos 50 foram orientados para os estabelecimentos de novos padrões. Nessa década, o controle da qualidade deixou de focar o produto e passou a orientar-se para o processo, o que, do ponto de vista estratégico, representou um passo importantíssimo. Na verdade, o responsável pelos itens defeituosos é o processo. Se o processo é “capaz” e se está

sendo devidamente controlado deve, portanto, gerar produtos sem defeitos (LOPES, 2007).

Após a guerra, na década de 50, o Japão iniciou sua jornada rumo à industrialização. Deming, que havia participado ativamente, na década de 40, dos programas de mobilização para a qualidade, nos Estados Unidos, foi para o Japão e, juntamente com Juran e Ishikawa, tornou-se o principal responsável pela disseminação dos conceitos de controle da qualidade naquele país. Nos anos 60, o uso prático da estatística como ferramenta para o controle de processo se consolidou e foram lançadas as bases para a implantação dos conceitos de *Total Quality Control (TQC)*, desenvolvidos por Feigenbaum. O parque industrial japonês serviu de palco para a implementação destes conceitos, na década seguinte. A década de 70 se caracterizou pela disseminação dos conceitos de TQC, principalmente no Japão e foram lançadas as bases para a implantação dos conceitos de *Total Quality Management (TQM)*. No final desta década, a *International Organization for Standardization (ISO)* criou o *Technical Committee 176 (TC-176)* cujos trabalhos levaram a criação das Normas ISO série 9000, aprovadas em 1987. Os anos 80 se caracterizaram pela implementação, em larga escala, dos conceitos de TQM. O Japão, mantendo a sua posição de vanguarda, liderou os países industrializados na implementação destes conceitos. A aprovação das Normas ISO série 9000, em 1987, representou uma mudança de paradigma e a Europa, berço dessas Normas, ocupou a posição de destaque neste novo cenário (LOPES, 2007). O método japonês para o controle da qualidade, envolvendo a participação de todos os setores e funcionários da empresa, contribuiu muito para que o Japão passasse a fabricar produtos de mais alta qualidade, até os dias de hoje.

No início da era industrial, ninguém se importava com a preservação do meio ambiente. A partir da década de 60, os problemas relacionados com a preservação da qualidade do meio ambiente passaram, cada vez mais, a ocupar o centro das atenções da nossa sociedade. O resultado desse movimento, principalmente nos países mais desenvolvidos, foi o início de pressões sociais para que os sistemas produtivos utilizassem tecnologias não poluidoras, já que a emissão de CO₂ e de outros gases exercem efeito estufa ocasionando mudanças climáticas no planeta. Em 1996, foram aprovadas as Normas ISO Série 14000, em 1996. Essas Normas especificam os requisitos relativos a um sistema de gestão ambiental e regem as relações contratuais para o comércio interno e entre países (LOPES, 2007). Atualmente, muitos congressos científicos abordam temas relacionados a isso, tais como, sustentabilidade, preservação do ambiente e desenvolvimento de tecnologias não poluidoras.

O controle de processo, para estar de acordo com o enfoque filosófico da era em que estamos vivendo, deve ser dinâmico, deve estar orientado para as necessidades dos clientes e ser capaz de acompanhar as mudanças das suas necessidades. Dentro deste contexto, a estatística é apenas uma ferramenta, importantíssima sem dúvidas, mas apenas uma ferramenta (LOPES, 2007).

1.3. Sistema de Controle e CEP

Conforme Ribeiro e Ten Caten (2011), o controle da qualidade depende de quatro elementos fundamentais, que constituem um sistema de controle do processo:

- O processo em si: é uma combinação de equipamentos, insumos, métodos, procedimentos e pessoas, tendo como objetivo a fabricação de um bem ou o fornecimento de um serviço. O desempenho do processo depende da maneira como ele foi projetado e construído e da maneira como ele é operado.

- As informações sobre o desempenho do processo: são obtidas a partir do estudo cruzado dos itens a seguir: a) qualidade das características do produto final, b) qualidade das características intermediárias e c) ajuste dos parâmetros do processo. As informações sobre o processo são úteis para orientar as ações de melhoria. Se não se pretende agir sobre o processo, coletar informações é inútil e dispendioso.
- Ações sobre o processo: são orientadas para o futuro, pois permitem detectar o defeito assim que ele é gerado, possibilitando a atuação sobre o processo no momento e local adequado. Essas ações podem envolver, por exemplo: controle sobre as matérias primas; ajuste nos parâmetros do processo; manutenção periódica; treinamento de operadores, etc. Corrigindo-se o processo, evita-se que novas peças defeituosas sejam produzidas.
- Ações sobre o produto final: são orientadas para o passado, pois elas permitem apenas separar o produto conforme do produto não-conforme (refugo) que pode eventualmente ser retrabalhado. A inspeção final tem algumas vantagens pois impede que produtos defeituosos cheguem ao cliente, mas não é uma forma eficiente de ação. Agir sobre o processo é mais eficaz, pois impede que novas peças defeituosas sejam produzidas.

A inspeção 100% e o controle estatístico do processo (CEP) possuem características e objetivos distintos.

Uma inspeção 100%, no curto prazo, fornece mais resultados na detecção de unidades defeituosas, pois elas são filtradas e dirigidas para retrabalho ou sucata. Por outro lado, as atividades de inspeção não promovem a melhoria dos processos, pois tomam tempo e mobilizam os recursos em atividades que não agregam valor. Além disso, podem levar a um certo “relaxamento” na manufatura, uma vez que tudo vai ser inspecionado depois.

Já o CEP prioriza ações sobre as causas especiais, ou seja, sobre a origem do problema. Ele não utiliza inspeção 100%, pois isso iria mobilizar os recursos que são importantes para a solução das causas especiais. Além disso, não seria muito útil, logo no primeiro dia, identificar um grande número de causas especiais, pois faltariam recursos para a investigação dessas causas. O CEP opera numa escala de tempo mais longa, pois as causas especiais vão sendo identificadas e eliminadas aos poucos, ao longo do tempo, com paciência e persistência.

Ribeiro e Ten Caten (2011) destacam várias vantagens na utilização do CEP:

- a) permite que o monitoramento do processo seja executado pelos próprios operadores,
- b) fornece uma distinção clara entre causas comuns e causas especiais, servindo de guia para ações locais ou gerenciais,
- c) fornece uma linguagem comum para discutir o desempenho do processo, possibilitando a alocação ótima dos investimentos em melhoria da qualidade e
- d) auxilia o processo a atingir alta qualidade, baixo custo unitário, consistência e previsibilidade.

1.4. Etapas para a Implantação do CEP

A coleta de dados para o preenchimento dos gráficos de controle exige investimentos em tempo, recursos e mudança na filosofia da empresa. A experiência tem mostrado que a implantação do CEP somente pode ser justificada quando os seguintes aspectos são observados (RIBEIRO; TEN CATEN, 2011):

- a) não utilizar um número excessivo de cartas de controle, sob risco do CEP transformar-se em atividade-gargalo na produção;

- b) aplicar o CEP em etapas prioritárias do processo, determinadas sob o ponto de vista da demanda de qualidade dos clientes;
- c) associar o CEP à uma estratégia de ação; coletar dados e não agir implica em desperdício de tempo e recursos.

Durante o planejamento do CEP, é importante a participação das pessoas envolvidas com a linha de produção: elas devem sentir-se co-responsáveis e comprometidas com a implantação do sistema. Deve-se investir um maior tempo na fase de planejamento, para minimizar a necessidade de alterações posteriores à implantação. Durante o planejamento, Ribeiro e Ten Caten (2011) consideram necessário definir:

- (i) Os processos críticos para a qualidade e produtividade da empresa onde será aplicado o CEP;
- (ii) Características de qualidade importantes para o cliente;
- (iii) Variáveis a serem controladas em cada processo;
- (iv) Capacidade do sistema de medição;
- (v) Indivíduos responsáveis pela ação sobre o sistema quando este sinalizar um estado de descontrole estatístico;
- (vi) Ações a serem tomadas quando o sistema estiver fora de controle.

Para auxiliar na definição desses itens, Ribeiro e Ten Caten (2011) baseados na sua experiência sugerem uma seqüência de etapas apresentadas nas seções que se seguem.

1.4.1. Desdobramento da qualidade

Nas três primeiras etapas do processo recomenda-se a utilização da metodologia do QFD (*Quality Function Deployment*), ou Desdobramento da Função Qualidade, o qual permite estabelecer relações entre a qualidade demandada pelo cliente e os processos responsáveis pelo atendimento desta demanda. Nesse Capítulo, o QFD será apresentado sucintamente.

O QFD é um caminho sistemático para garantir que o desenvolvimento das características e especificações do produto, bem como desenvolvimento de metodologias, processo e controles, sejam orientados pela necessidade do consumidor.

A primeira fase de um estudo de QFD consiste em entender o mercado, através de pesquisas e, assim, compreender as necessidades dos clientes. Através de uma pesquisa de mercado, tem-se um conhecimento sobre o que é importante para o consumidor e tem-se uma idéia geral do que o usuário final necessita e deseja encontrar em um determinado produto ou serviço. Tal conhecimento facilita a definição do produto ou serviço desejado, criando-se posteriormente especificações que vão ao encontro a essas demandas.

O estudo do QFD permite priorizar resultados desejados e planejar ações. O QFD é implementado através de um conjunto de matrizes nas quais são estabelecidas as relações entre características de qualidade demandadas pelo usuário e características de qualidade do produto/processo, procedimentos de manufatura, especificações, recursos humanos, infra-estrutura disponível e custos globais. Essas relações permitem determinar os elementos do produto e de seu processo de manufatura responsáveis pela construção da qualidade demandada pelo usuário. O QFD é feito por uma equipe multifuncional, envolvendo diversos departamentos da empresa, tais como marketing, engenharia de produto, engenharia de processo, custos, suprimentos, manufatura e gerência de qualidade.

Os resultados da pesquisa de mercado devem permitir uma priorização dos itens da demanda da qualidade através do estabelecimento de um peso de importância para cada item; o peso de importância do i -ésimo item de demanda é designado por ID_i . Na sequência, listam-se as características de qualidade potencialmente relacionadas com os itens de demanda identificados pelos usuários. No contexto do QFD, assim como no do CEP, características de qualidade são aspectos mensuráveis da demanda da qualidade.

O uso de uma matriz da qualidade (MQ), representada na Figura 1, permite identificar características de qualidade que contribuem para o atendimento dos itens de qualidade demandada. Na MQ, os itens da qualidade demandada são cruzados com as características de qualidade. Os elementos principais da matriz da qualidade estão apresentados no cabeçalho das linhas (itens de qualidade demandada) e no cabeçalho das colunas (características de qualidade).




Figura 1. Esquema da Matriz da Qualidade
Fonte: Ribeiro e Ten Caten (2011)

O preenchimento da matriz da qualidade (MQ) é realizado com a opinião da equipe técnica. São estabelecidos relacionamentos entre a qualidade demandada pelos clientes e as características de qualidade, originando o índice de intensidade dos relacionamentos (DQ_{ij}), onde j denota a característica de qualidade e i denota o item de qualidade demandada.

A escala utilizada na medição do índice de intensidade (DQ_{ij}), tem usualmente os seguintes valores:

- 9 para muito importante,
- 6 para importante,
- 3 para moderada,
- 1 para pouco importante e
- 0 para sem importância.

A priorização das características de qualidade é apresentada na última linha da matriz da qualidade. Uma característica de qualidade é considerada prioritária se:

- (i) atende a vários itens de qualidade demandada,
- (ii) atende a itens de qualidade demandada com pesos ID_j (importância da qualidade demandada) altos, e/ou
- (iii) mantém relações fortes com os itens de qualidade demandada.

Para o cálculo da priorização das características de qualidade, sugere-se um índice de importância (ICQ_j) dado pelo somatório dos índices de importância dos itens

da qualidade demandada (ID_i) multiplicados pela intensidade das relações atribuídas no interior da matriz (DQ_{ij}), ou seja:

$$ICQ_j = \sum_{i=1}^n ID_i DQ_{ij}$$

onde:

ICQ_j : índice da j-ésima característica de qualidade do produto, $j = 1, \dots, n$.

ID_i : índice de importância do i-ésimo item de qualidade demandada.

DQ_{ij} : intensidade do relacionamento entre o i-ésimo item de qualidade demandada e a j-ésima característica de qualidade do produto.

A Figura 2 apresenta um exemplo de matriz da qualidade aplicada a um determinado produto. A qualidade demandada em relação ao produto é o que o cliente deseja. As características da qualidade (variáveis) associadas ao desejo do cliente são definidas pelos especialistas. Os pesos são proporcionais à importância da qualidade demandada.

Qualidade Demandada	Características de Qualidade										
	Pesos (D_i)	Tensão de Rasgamento	Falta de vulcanização	Falhas no desenho	Rachadura nos gomos	Tensão de Ruptura	Resistência à abrasão	Resiliência	Espessura	Largura	Quantidade de cola
Desempenho	50	9	9	3	9	6	9	6	3	1	6
Acabamento	20	1	9	9	9						3
Facilidade de aplicação	5	3	6		1			1	1		
Aderência na aplicação	10										9
Dimensional	10								9	9	
Índice da Caract. Qual (ICQ_j)	485	660	330	635	300	450	305	245	140	450	

Figura 2. Exemplo de Matriz da Qualidade

Fonte: Ribeiro e Ten Caten (2011)

1.4.2. Desdobramento dos processos

O desdobramento dos processos permite associar características de qualidade do produto final, priorizadas na MQ descrita na etapa anterior, a parâmetros do processo ou características avaliadas durante o processo de manufatura. Este desdobramento auxilia na identificação dos parâmetros críticos do processo, sob o ponto de vista da qualidade percebida pelos usuários.

O desdobramento da tecnologia, o qual envolve o desdobramento dos processos, é um procedimento para identificar e remover, de forma organizada, gargalos de engenharia na fase de detalhamento do projeto do produto. Esses gargalos devem ser identificados nas etapas preliminares do projeto, para que suas soluções possam ser planejadas de forma organizada.

Inicialmente, é necessário entender o macro-fluxo dos processos da empresa e listar todos os processos de manufatura na ordem em que aparecem na linha de produção. A seguir, listam-se parâmetros do processo e as características de qualidade avaliadas em cada processo; estes serão cruzados com as características de qualidade do produto final, na matriz dos processos.

A matriz dos processos (MP), exemplificada pelo esquema na Figura 3, é constituída pelos seguintes elementos:

- (a) o cabeçalho (topo) da matriz é preenchido com as características de qualidade do produto final.
- (b) o cabeçalho das linhas (lado esquerdo da matriz) é preenchido com a lista de todos os parâmetros e características, também chamados de parâmetros do processo, avaliados durante a manufatura.




Figura 3. Esquema da Matriz de Processos
Fonte: Ribeiro e Ten Caten (2011)

Para identificar os processos críticos, é necessário quantificar as relações R_{kj} entre as características de qualidade ($j = 1, \dots, n$) dos processos críticos e os parâmetros ($k = 1, \dots, K$) dos processos de manufatura. Para cada característica de qualidade do produto, identifica-se a intensidade de monitoramento de um ou mais parâmetros recomendada para obtenção de medições satisfatórias da característica em questão; isto é feito através da determinação das relações R_{kj} . A intensidade das relações entre os processos e as características de qualidade mensuradas utilizando a escala proposta na Seção anterior são atribuídas pela equipe técnica e escritas no interior da matriz.

A avaliação do impacto (importância) de cada parâmetro e característica de qualidade do processo sobre a qualidade demandada pelo usuário é realizada levando-se em conta as relações estabelecidas no interior da matriz e o Índice de Importância Corrigido (ICQ_j^*) das características de qualidade, determinadas na matriz da qualidade.

Para a definição da importância para a qualidade de cada parâmetro e característica de qualidade do processo, foi estabelecido um índice de qualidade (IQP_k), dado pelo somatório do produto do Índice de Importância Corrigido das características de qualidade do produto (ICQ_j^*), multiplicado pela intensidade das relações atribuídas no interior da matriz, R_{kj} , ou seja:

$$IQP_k = \sum_{j=1}^n ICQ_j^* * R_{kj}$$

Esse índice considera que desvios em um parâmetro do processo comprometem uma ou mais características de qualidade do produto final

Após a identificação dos parâmetros e características de qualidade dos processos críticos, é necessário verificar qual a capacidade destes parâmetros e características

(conforme dado pelo índice Cp_k que será abordado em outro capítulo) e o domínio (conhecimento) técnico acerca destes elementos disponível na empresa. O objetivo é priorizar ações de melhoria nos processos e características que sejam importantes para a qualidade, conforme demandada pelo usuário.

Com o auxílio da equipe técnica, questiona-se a capacidade de cada parâmetro e característica do processo, estimada a partir do percentual de observações fora de especificação, conforme a Tabela 1. Tal percentual é derivado do índice Cp_k associado a cada característica, ou seja, a partir desse percentual identifica-se o nível de capacidade do processo. O nível sigma, associado com o desvio padrão em torno da média, identifica o nível da qualidade do processo.

Avaliação	Cp_k (capacidade real)	Contemplação (nível sigma)	% fora de especificação*
Muito incapaz	0,33	$\pm 1\sigma$	31,73%
Incapaz	0,66	$\pm 2\sigma$	4,55%
Capaz	1,00	$\pm 3\sigma$	0,27%
Muito capaz	1,33	$\pm 4\sigma$	0,0063%
Altamente capaz	1,67	$\pm 5\sigma$	0,000057%
Extremamente capaz	2,00	$\pm 6\sigma$	0,000000002%

Tabela 1. Escala para a avaliação da capacidade das etapas dos processos produtivos

(*) percentual considerado para processos centralizados.

A seguir, questiona-se o conhecimento da equipe técnica a respeito do processo. Deseja-se determinar se a equipe técnica conhece o ajuste ótimo dos parâmetros e características de qualidade do processo e o efeito desses parâmetros sobre diversos aspectos que determinam a qualidade do produto final. Para mensurar o conhecimento técnico, utiliza-se a escala apresentada na Tabela 2, onde o grau de conhecimento vem designado pela letra C.

Conhecimento	C
Muito pouco	0,2
Pouco	0,4
Moderado	0,6
Grande	0,8
Muito grande	1,0

Tabela 2. Escala para a avaliação do conhecimento associado às etapas dos processos produtivos

O índice de priorização IPP_k para o k -ésimo parâmetro do processo combina valores de IQP , Cp_k e C , estabelecendo os parâmetros críticos na composição da qualidade percebida pelos clientes. Serão considerados críticos parâmetros fortemente relacionados às características de qualidade demandadas pelos usuários do produto em estudo, oriundos de processos com baixa capacidade, acerca dos quais detém-se pequeno conhecimento técnico. O IPP_k é dado por:

$$IPP_k = \frac{IQP_k}{Cp_k C}$$

onde :

IPP_k é o índice de priorização,

IQP_k é o índice de qualidade,

Cp_k é o valor de capacidade,

C é o valor de conhecimento técnico, todos associados ao k -ésimo parâmetro do processo.

A Figura 4 apresenta um exemplo de matriz de processo aplicada a um determinado produto. Observa-se que, pelo resultado do IPP_k , deve ser priorizado o Peso/Metro da Extrusão, característica da qualidade que obteve o maior valor.

		Características de Qualidade										Índice de Qualidade	Capacidade	Conhecimento	Índice de Priorização
		Tensão de rasgamento	Falta de vulcanização	Falhas no desenho	Rachadura nos gomos	Tensão de Ruptura	Resistência à abrasão	Resiliência	Espessura	Largura	Quantidade de cola				
Índice da C.Q. (ICQj)		485	660	330	635	300	450	305	245	140	450	IQP_k	Cp_k	C_k	IPP_k
Processos desdobrados	Extrusão	Temperatura das Zonas	9	6			9	6	9		3	17820	1,67	0,7	15244
	Extrusão	Pressão do cabeçote	3	1			3	1	1	3		4435	1	0,2	22175
	Extrusão	Temperatura da massa	6	9	6		9	6	6			18060	0,63	0,8	35833
	Extrusão	Peso / Metro	6	6			3	3	3	9	9	13950	0,5	0,6	46500
	Extrusão	Temperatura de embobinamento	6	9	3	1	6	6	6			16805	0,77	0,9	24250
	Extrusão	Presença de caroços	1	6	3		6	6	6			11765	0,67	0,9	19511
	Vulcanização	Temperatura	3	9	3	3	6	3		9	6	16485	1,13	0,95	15356
	Vulcanização	Pressão	3	9	3	6	6	3		6	3	17235	1	0,8	21544
	Vulcanização	Tempo	3	9	6		6	3			3	13875	1	0,8	17344
	Vulcanização	Ciclo de fech/degasagem	6	3			6	6		1	3	10055	1	0,65	15469
	Vulcanização	Tempo de resfri da banda	6	3		3	6					9495	1	0,65	14608
	Vulcanização	Espessura total	9				6			9	3	8790	1,23	0,9	7940
	Vulcanização	Espessura da base	9				6			9	3	8790	1,23	0,9	7940
	Vulcanização	Largura	3		3		6			6	9	8325	1	0,9	9250
	Vulcanização	Profundidade do incavo	6		6	3	9			6		10965	1,67	1	6566
	Vulcanização	Dureza	6		6	6	6	3				11850	1,4	0,95	8910

Figura 4. Exemplo de Matriz de Processos

Fonte: Ribeiro e Ten Caten (2011)

1.4.3. Direcionamento das ações

Esta é a última etapa que faz uso da estrutura matricial do QFD. Aqui se concretiza o planejamento das melhorias da qualidade que irão reforçar o sistema de qualidade existente. Também nesta etapa, os parâmetros e características de qualidade dos processos críticos para a qualidade são analisados individualmente quanto às possíveis ações de melhoria a serem adotadas. A análise leva em conta a voz do cliente, custo e conhecimento técnico acerca dos parâmetros em estudo.

Questiona-se, junto à equipe técnica, a pertinência de um conjunto de ações de melhoria à situação em estudo; dentre elas, listam-se:

- treinamento;
- controle estatístico de processos (CEP);
- desenvolvimento de fornecedores;
- projeto de experimentos;
- estudos ergonômicos;
- aquisição de equipamentos;
- definição de procedimentos; e
- automatização.

Uma vez listadas as possíveis ações de melhoria, a equipe avalia sua aplicação aos parâmetros do processo priorizados na etapa anterior da metodologia. A pertinência das ações de melhoria a cada parâmetro enfocado deve ser analisada utilizando-se a seguinte escala: muito efetiva (9), moderada (3), pouco efetiva (1) e nenhuma efetividade (0).

1.4.4. Identificação dos postos de controle e parâmetros e características de qualidade do processo a serem monitorados

Os postos de controle são locais físicos onde são monitoradas as características de qualidade (atributos e variáveis) associadas a etapas críticas do processo. De forma mais específica, conhecendo-se as características críticas para a qualidade e onde elas são construídas no processo produtivo, é possível definir a localização dos postos de controle bem como listar parâmetros e características de qualidade do processo a serem monitorados em cada posto.

As etapas da implantação do controle estatístico de processo até agora apresentadas vêm esquematizadas na Figura 5, podendo ser assim resumidas:

- (i) desdobramento da qualidade, composta pela identificação da qualidade demandada pelo cliente, desdobramento das características de qualidade do produto, construção da matriz da qualidade e priorização das características de qualidade do produto;
- (ii) desdobramento dos processos, composto pela identificação dos parâmetros e características dos processos, construção da matriz do processo e priorização dos parâmetros e características dos processos críticos para a qualidade;
- (iii) direcionamento das possíveis ações de melhoria; e
- (iv) localização dos postos de controle e alocação dos parâmetros e características do processo em cada posto.




Figura 5. Desenho esquemático das primeiras quatro etapas do planejamento da implantação do controle estatístico de processos

Fonte: Ribeiro e Ten Caten (2011)

1.4.5. Definição de critérios de classificação dos produtos

Nesta etapa são definidos critérios de classificação (também denominados "filtros") a serem utilizados posteriormente na análise gerencial das cartas de controle do CEP. Os critérios de classificação são informações como, por exemplo, tipo de produto, turno, máquina, operador, encarregado de turno, fornecedor, matérias-primas, etc., a serem registradas conjuntamente com os dados de qualidade.

Posteriormente, já que dados de qualidade encontram-se classificados quando de seu armazenamento, informações acerca das características de qualidade podem ser recuperadas conforme critérios de classificação definidos pelo usuário. Por exemplo, podem-se recuperar (e agrupar) todos os dados sobre a característica de qualidade coletados no turno da manhã; ou seja, dados da qualidade podem ser "filtrados" relativamente a esse critério de classificação.

1.4.6. Definição dos parâmetros e características de qualidade do processo

Nessa etapa é necessário separar as avaliações referentes a parâmetros de processo (variáveis e atributos que qualificam o processo e não estão diretamente ligadas à qualidade do produto final) e aquelas referentes a características de qualidade (variáveis e atributos que configuram diretamente a qualidade do produto final).

Parâmetros de processo fora de especificação indicam uma maior probabilidade de produção de defeituosos, devendo gerar ações corretivas. Características de qualidade fora da especificação implicam, diretamente, na ocorrência de defeituosos, também devendo gerar ações corretivas.

Para cada variável (ou atributo) a ser monitorada no CEP, é necessário definir: (i) o tipo (nominal-é-melhor, maior-é-melhor ou menor-é-melhor), (ii) a unidade ou a forma de medição ou de contagem, (iii) e o valor-alvo e as especificações (para os estudos de capacidade).

1.4.7. Definição do procedimento de coleta de dados

Nesta etapa, define-se:

- quem irá coletar os dados,
- com que frequência os dados serão coletados,
- onde os dados coletados serão armazenados,
- qual o destino dos dados após a coleta dos mesmos,
- qual o tipo de carta de controle,
- qual o tamanho da amostra,
- qual a forma de registro dos dados (registro eletrônico em computador ou em planilha de papel),
- qual o sistema de medição a ser utilizado.

Os fatores mais importantes a serem considerados são: a atribuição de responsabilidades e a exatidão das informações coletadas.

1.4.8. Avaliação do sistema de medição

Após definido o sistema de medição, é necessário avaliar a sua capacidade. Um sistema de medição capaz apresenta uma variância de medição inferior a 20% da amplitude das especificações. Posteriormente, nessa obra, há um capítulo exclusivo para tratar a avaliação do sistema de medição (ASM).

1.4.9. Definição das responsabilidades

Nessa etapa, definem-se os responsáveis pelo(a):

- coleta dos dados e registro na planilha,
- digitação dos dados (no caso de armazenamento digital de dados),
- monitoramento das cartas de controle,
- cálculo dos limites de controle
- estudos de estabilidade e capacidade.
- pela identificação e execução de ações corretivas, no caso do processo sair fora do controle, e
- ações preventivas para evitar a reincidência do problema.

Esses indivíduos são chamados facilitadores do CEP, que dá apoio ao líder da equipe na busca dos melhores resultados. O facilitador também deve auxiliar a equipe de projeto no planejamento e organização da implantação. Além dos facilitadores, sugere-se a criação de um grupo de apoio à qualidade (GAQ), a ser chamado quando causas especiais não possam ser corrigidas pelo operador e supervisor.

1.4.10. Definição da documentação necessária e Treinamento

Nesta etapa são elaboradas as planilhas de coleta de dados, ou folhas de verificação, a serem utilizadas em cada posto de controle, bem como as planilhas de registro de ocorrência de causas especiais. Os dados são coletados e digitados no sistema, de forma que todo o histórico ficará disponível digitalmente. As folhas impressas, com os dados originais devem ser guardadas por um período de tempo especificado pelas normas (p. ex., as Normas ISO) e depois devem ser descartadas.

O treinamento é uma etapa muito importante, pois todos na empresa devem ser capazes de interpretar os dados coletados no CEP. O treinamento deve ser aplicado imediatamente antes da implantação efetiva do CEP, podendo ser ministrado para funcionários de diferentes níveis hierárquicos na empresa, que devem receber treinamentos diferenciados.

Por exemplo, para gerentes e diretores, é suficiente ministrar os conteúdos referentes à análise dos dados e estudos de estabilidade e capacidade de processo, dando-lhes, assim, subsídios para tomada de decisões baseadas nos dados coletados. Supervisores e engenheiros devem receber um treinamento integral em CEP, pois a estes profissionais caberá a tarefa de definir tamanhos de amostra, frequência de amostragem, limites de controle, etc. Operadores devem ser treinados no preenchimento de planilhas, na digitação dos dados e na análise das cartas de controle resultantes, com o objetivo de detectar a presença de causas especiais.

1.4.11. Implantação efetiva, acompanhamento e consolidação

Duas são as etapas da implantação efetiva do CEP:

- (a) Início do monitoramento: define-se a data de início da coleta de dados a serem utilizados no CEP, bem como os indivíduos responsáveis pela digitação dos dados de entrada no sistema. Com isso, tem-se o início da utilização prática do CEP (através do pacote computacional de apoio), sendo definidas a frequência de amostragem e entrada dos dados nas planilhas do computador. Nesta etapa, dados são coletados e plotados no gráfico, mas os limites de controle do processo ainda não são conhecidos.
- (b) Cálculo dos limites de controle: uma vez feito o cálculo dos limites de controle do processo, estes devem ser acrescentados às cartas de controle, permitindo sua utilização plena. No caso de aparecimento de causas especiais, os limites de controle devem ser recalculados, após a identificação e eliminação das causas de anomalia no processo. Limites de controle obtidos a partir de um processo sob controle estatístico, sobre o qual apenas causas comuns de variabilidade incidem, são utilizados no monitoramento futuro dos processos.

O acompanhamento e consolidação do controle estatístico de processos compreendem as seguintes etapas:

- (i) Avaliação da sistemática de ação: analisa-se e aprimora-se o sistema de controle do processo implantado através da verificação dos procedimentos de coleta de dados, registro e ação de melhorias. Esta análise deve ser realizada em conjunto com toda a equipe envolvida na implantação do CEP.
- (ii) Análise da estabilidade dos processos: avalia-se a estabilidade dos processos e, se necessário, adotam-se procedimentos de identificação e eliminação de causas especiais.
- (iii) Análise da capacidade do processo: avalia-se a capacidade dos processos e, se necessário, adotam-se estudos de otimização dos processos através de grupo de ação de melhorias da qualidade.

Nesta etapa avaliam-se os resultados da implantação do CEP e, posteriormente, identificam-se melhorias futuras advindas de sua implantação.

2. Ferramentas da Qualidade

O CEP não se baseia unicamente no uso dos gráficos de controle. Várias são as ferramentas da qualidade utilizadas durante um processo de melhoria contínua da qualidade, algumas são ferramentas estatísticas, outras não. Alguns autores dizem que as ferramentas da qualidade são sete, porém nem todos os autores apresentam as mesmas “sete ferramentas”. Nesse capítulo, serão apresentadas várias dessas ferramentas.

2.1. Fluxograma

O fluxograma é uma representação gráfica mostrando todas as fases do processo. O fluxograma do processo mostra uma visão geral de todos os passos do processo e pode ser aplicado a qualquer caso. Para elaborar um fluxograma, Brassard (2004) sugere: (i) definir claramente os limites para o processo; (ii) utilizar os símbolos mais simples possíveis; e (iii) assegurar caminhos para todas as alternativas possíveis. Como pode-se observar na Figura 6, o fluxograma utiliza símbolos diferentes para representar cada etapa do processo.





Figura 6. Funcionamento básico de um fluxograma (a) e principais símbolos utilizados (b)

Fonte: (b) Adaptado de Rocha e Nonohay (2016)

Segundo Brassard (2004), na identificação do problema no processo (*imagineering*) as pessoas com maior conhecimento das suas fases se reúnem para: desenhar o fluxograma atual do processo; desenhar o fluxograma das etapas que o processo deveria seguir se tudo ocorresse bem; e comparar os dois fluxogramas para verificar onde diferem entre si, a fim de identificar a raiz do problema. A Figura 7 apresenta dois exemplos de fluxogramas: (a) aplicado na indústria e (b) aplicado em serviços. Nota-se, no final do fluxograma (b), um círculo com um número dentro. Esse

símbolo é um conector que indica que o fluxo continua a partir desse ponto em outra parte do processo, identificado pelo mesmo círculo com o mesmo número.



2.2. Folha de Verificação

Conforme Brassard (2004), a folha de verificação é um procedimento usado para responder a pergunta: "com que frequência certos eventos acontecem?" A Figura 8 apresenta dois exemplos de folhas de verificação: (a) aplicado na indústria e (b) aplicado em serviços, enquanto que a Figura 9 apresenta o registro de defeitos ao longo dos meses em um tanque usado em uma aplicação aeroespacial.

Defeitos	Maio				Total
	6	7	8	9	
Erros de Dimensão					26
Forma					9
Profundidade					8
Peso					52
Acabamento					7
Total	20	22	25	26	102

(a) Defeitos em rolamentos

Erros	Março			Total
	1	2	3	
Tabulação				8
Palavras Erradas				23
Pontuação				40
Omissão de Palavras				4
Números Errados				10
Numeração de Páginas				4
Tabelas Erradas				13
Total	34	35	33	102

(b) Erros de datilografia

Figura 8. Ex. de folhas de verificação: (a) aplicado na indústria e (b) em serviços.

Fonte: Brassard (2004)


FOLHA DE CONTROLE DADOS DE DEFEITOS PARA 2002-2003 YTD																		
Peça No.: TAX-41 Localização: Bellevue Data Estudo: 6/5/03 Analista: TCB																		
	2002												2003					
Defeito	1	2	3	4	5	6	7	8	9	10	11	12	1	2	3	4	5	Total
Peças danificadas	1			3	1	2		1		10	3		2	2	7	2		34
Problemas de máquina			3	3				1	8		3		8	3				29
Partes fornecidas enferrujadas			1	1		2	9											13
Revestimento insuficiente		3	6	4	3	1												17
Solda desalinhada	2																	2
Processamento fora de ordem	2														2			4
Peça errada produzida	1							2										3
Carenagem sem acabamento			3															3
Falha do adesivo				1							1		2		1	1		6
Anodização com produto em pó					1													1
Pintura fora dos limites						1								1				2
Pintura danificada por produto químico			1															1
Película nas peças						3		1	1									5
Latas de primer danificadas								1										1
Porosidade na fundição									1	1								2
Composto delaminado										2								2
Dimensões incorretas											13	7	13	1		1	1	36
Procedimento de teste impróprio										1								1
Falha no spray salinizado													4			2		4
TOTAL	4	5	14	12	5	9	9	6	10	14	20	7	29	7	7	6	2	166

Figura 9. Exemplos de folha de verificação: defeitos em um tanque.
Fonte: Montgomery (2017)

Para elaborar uma folha de verificação, Brassard (2004) sugere: estabelecer qual evento está sendo estudado; definir o período durante o qual os dados serão coletados; construir um formulário claro e de fácil manuseio e utilização; coletar os dados honestamente; e utilizar um processo de amostragem eficiente. Deve-se verificar se a população (universo) é não homogênea (por exemplo, produto produzido por mais de uma máquina ou diferentes operadores). A população deve ser homogênea (uma folha para cada máquina e cada operador), caso contrário devem ser primeiramente estratificadas a fim de formar grupos homogêneos.

2.3. Diagrama de Concentração de Defeitos

Montgomery (2004) define um diagrama de concentração de defeitos (DCD) como sendo uma figura da unidade mostrando todas as partes relevantes do produto. Os defeitos, então, são assinalados na figura, conforme a sua localização. A Figura 10 apresenta dois exemplos de DCD.



(a) Defeitos na superfície de um refrigerador

(b) Defeitos no tanque

Figura 10. Exemplos de diagramas: de concentração de defeitos.

Fonte: Montgomery (2017)

Na Figura 10 (a) são apresentados os defeitos encontrados na superfície de um refrigerador, nas áreas sombreadas do DCD (no centro em volta do produto e nos cantos na parte inferior frontal). Na Figura 10 (b) é apresentado um DCD para registrar os defeitos no tanque mencionado no exemplo da Figura 9. Esse diagrama apresenta uma legenda com letras (para serem alocadas na figura) que identificam cada defeito, segundo o tipo, no entanto, é mais comum a utilização de cores na identificação dos defeitos.

2.4. Brainstorming

Brainstorming ou “tempestade de idéias” são reuniões com o pessoal envolvido com o problema em estudo a fim de se coletar o máximo de opiniões ou idéias sobre as causas, bem como todas as soluções possíveis, ainda que pareçam inviáveis a princípio. Segundo Brassard (2004), existem dois tipos de *brainstorming*:

- 1) Estruturado: Nesta forma, cada pessoa do grupo dá a sua idéia em cada rodada ou “passa a vez” até que chegue a sua próxima vez. Isto “obriga” até os mais tímidos a participarem, contudo pode criar certa pressão sobre as pessoas.
- 2) Não estruturado: Nesta forma, os membros do grupo simplesmente dão as idéias conforme elas surgem em suas cabeças. Isto cria um ambiente mais descontraído, porém existe o risco da reunião ser dominada pelos mais extrovertidos.

Num *brainstorming* nunca se deve criticar as idéias, mesmo que sejam absurdas ou inviáveis, pois isso desestimula e inibe a participação das pessoas. É aconselhado escrever em um quadro todas as idéias levantadas, segundo as palavras do participante e não a sua interpretação. A visão global das idéias serve de estímulo para novas propostas e também evita mal-entendidos. Um *brainstorming* dura, em média, de 5 a 15 minutos.

2.5. Técnica Nominal de Grupo

Quando se aborda algum problema ou a forma de atacar o problema, geralmente ocorre que a seleção do problema foi influenciada por pessoas que “falaram mais alto” ou “têm maior autoridade” na empresa. Isto pode criar o sentimento no grupo (ou setor)

de que o “seu” problema nunca será abordado, o que pode gerar uma falta de comprometimento com a solução do problema selecionado, por falta de motivação ou desânimo, e também a idéia de que foi selecionado o problema “errado”. A Técnica Nominal de Grupo (TNG) permite a todos os membros do grupo igual participação na seleção de problemas. Segundo Brassard (2004), esta técnica consiste das seguintes etapas:

- 1) Cada membro do grupo deve escrever ou falar sobre o problema que julgar mais importante. Depois que todos escreverem a sua escolha de problemas recolha o papel com os problemas.
- 2) Escreva os problemas descritos onde todos possam ver.
- 3) Se houver duplicidade combine-os em um só, mas de acordo com os autores.
- 4) Peça para cada membro do grupo ordenar os problemas pelo grau de importância crescente, segundo o critério de cada um.
- 5) O problema cuja soma dos pontos for a mais alta é o escolhido, primeiramente. Da mesma forma, se ao invés de problemas o que se pediu foi sugestões, idéias, a mais votada deve ser considerada primeiro para discussão e depois as seguintes.

Considere o exemplo do Quadro 2. Ela apresenta a relação de cinco problemas levantados e a pontuação de seis colaboradores, segundo o grau de importância (1 para o menos importante, até 5 para o mais importante). Nesse exemplo, a queda na qualidade é o problema que será tratado primeiro.

Problema	Colaborador						Total
	A	B	C	D	E	F	
Espaço	3	5	2	3	3	1	17
Segurança	1	1	1	2	1	2	08
Gerenciamento	2	2	3	1	2	3	13
Queda na Qualidade	5	4	4	5	4	5	27
Falta de manutenção	4	3	5	4	5	4	25

Quadro 2. Exemplo de aplicação da TNG

2.6. Análise do Campo de Forças

Toda vez que se pretende fazer mudanças, sejam pessoais ou organizacionais, existem forças indutoras e forças restritivas agindo a favor e contra, respectivamente. É um processo dinâmico. Forças indutoras podem estar relacionadas como as vantagens da mudança ou as desvantagens do sistema atual. Quando ocorrem mudanças é porque as "forças indutoras" são superiores às "forças restritivas". Assim, pode-se listar estas possíveis forças e analisá-las. O Quadro 3 apresenta um exemplo da Análise do Campo de Forças (ACF) para a implementação de um sistema de Controle Estatístico de Processo (CEP) em uma empresa.

FORÇAS INDUTORAS	FORÇAS RESTRITIVAS
Melhoria do monitoramento do processo	Investimento na implementação do CEP
Identificação de falhas mais rapidamente	Gastos com treinamento de funcionários
Aumento da qualidade dos produtos	Alteração de sistemas
Diminuição de perdas e do retrabalho	Comodismo
Permite prever o processo e as perdas	Resistência à mudança

Quadro 3. Exemplo de aplicação da ACF

Segundo Brassard (2004), a ACF ajuda a promover mudanças, pois: força às pessoas a pensarem juntas sobre todos os aspectos da mudança pretendida; incentiva o pensamento criativo; encoraja as pessoas a chegar a um consenso sobre a prioridade relativa às forças de um lado e do outro do campo; e é um ponto de partida para a ação.


2.7. Histograma

O histograma é uma ferramenta gráfica que permite verificar o comportamento ou o tipo de distribuição de probabilidade da variável analisada. O procedimento para montar um histograma é o mesmo procedimento para montar uma distribuição de frequências. No caso de variáveis discretas: a) estabelecer o rol (dados ordenados), e b) contar as ocorrências de cada valor.

No caso de variáveis contínuas ou quando a variável discreta assume muitos valores e precisa ser agrupada em classes:

- Estabelecer o rol
- Calcular a amplitude total: $H = X_{\max} - X_{\min}$
- Calcular o número k de classes, que pode ser obtido por $k = 1 + 3,3 \log n$, onde n é o tamanho da amostra, ou por $k = \sqrt{n}$, quando $n > 25$ ou $k = 5$, quando $n \leq 25$. O valor de k pode ser arredondado ou aproximado a um valor mais conveniente.
- Calcular a amplitude das classes: $h = H / k$, que pode ser arredondada ou aproximada a um valor mais conveniente.
- Define-se o limite inferior da primeira classe (LI), que deve ser igual ou ligeiramente inferior ao menor valor das observações;
- Definir o limite superior da primeira classe (LS) somando-se $LI + h$.
- Definir os limites das demais classes, seguindo o mesmo raciocínio.
- Conta-se a ocorrência dos valores em cada classe (frequência absoluta).
- Calcula-se a frequência absoluta acumulada, acumulando-se os valores da frequência absoluta de cada classe, de tal forma que a última classe tenha frequência acumulada igual a n .
- Calculam-se as frequências relativa e relativa acumulada, dividindo-se respectivamente, as frequências absoluta e absoluta acumulada por n .

O histograma (exemplo na Figura 11a) pode ser elaborado tanto com a frequência absoluta quanto com a frequência relativa (ou percentual). Outro gráfico relacionado é o polígono de frequências (Figura 11b), o qual pode ser elaborado tanto com a frequência absoluta quanto com a frequência relativa.



(a) histograma (b) polígono de frequências
 Figura 11. : Exemplo de histograma e polígono de frequências
 Fonte: Ribeiro e Ten Caten (2011)

A Figura 12 apresenta dois histogramas: um exemplo para indústria (densidade da impressão) e um exemplo para serviços (tempo médio de atendimento a chamada de pacientes).




Figura 12. Exemplo de histograma para indústria e serviço

Fonte: Brassard (2004)

Segundo Ribeiro e Ten Caten (2011), outra forma de verificar a distribuição das variáveis é através do papel de probabilidade que permite testar graficamente o ajuste de diferentes distribuições de probabilidade. O papel de probabilidade Normal, no caso, possui uma escala vertical transformada, de forma que, se um conjunto de dados segue a distribuição Normal, suas freqüências acumuladas aparecerão dispostas ao longo de uma linha reta. Caso contrário, quando o modelo Normal não se ajusta bem aos dados, suas freqüências acumuladas irão apresentar curvatura quando plotadas no papel de probabilidade Normal, indicando a existência de assimetria, por exemplo.

É possível verificar o ajuste de uma distribuição Normal de probabilidade através do teste gráfico que valores teóricos de Z esperados (Distribuição Normal Padronizada) para cada valor coletado ordenado (rol). Para elaborar esse teste gráfico, recomenda-se seguir os seguintes passos (RIBEIRO; TEN CATEN, 2011):

- a) estabelecer o rol;
- b) calcular a probabilidade acumulada $F(X_i) = (i - 0,5) / n$;
- c) obter o valor teórico de Z a partir de, usando a tabela da distribuição Normal acumulada;
- d) plotar um gráfico de dispersão entre o valor observado e o valor de Z ;
- e) se o ajuste Normal for adequado, os valores plotados devem aparecer seguindo, aproximadamente, uma linha reta.

Exemplo: A Tabela 3 apresenta a espessura (X_i) de 10 peças cerâmicas, o valor de $F(X_i)$ e o valor teórico de Z associado. A Figura 13 apresenta o gráfico de dispersão entre o valor observado e o valor de Z , mostrando que os valores praticamente formam uma linha reta, ou seja, os dados provêm de uma Distribuição Normal.

i	1	2	3	4	5	6	7	8	9	10
X_i	1,00	1,22	1,31	1,55	1,62	1,80	1,87	2,00	2,32	2,50
$F(X_i)$	0,05	0,15	0,25	0,35	0,45	0,55	0,65	0,75	0,85	0,95
Z	-1,64	-1,04	-0,67	-0,39	-0,13	0,13	0,39	0,67	1,04	1,64

Tabela 3. Dados de a espessura de 10 peças cerâmicas




Figura 13. Exemplo de teste de Normalidade
Fonte: Ribeiro e Ten Caten (2011)

2.8. Gráfico de Ramo-e-Folhas

O Gráfico de ramo-e-folhas é uma ferramenta simples similar ao histograma, tendo como vantagem apresentar a ordem em que os dados foram coletados dentro do “ramo”. Suponha que a característica estudada seja composta por dois dígitos (por exemplo, a dezena e a unidade). Nesse caso, a dezena representa o “ramo”, enquanto que a unidade representa a “folha”. Em geral, deve-se escolher relativamente poucos ramos em comparação com o número de observações, normalmente, entre 5 e 20 ramos.

Os dados abaixo são uma amostra dos tempos de ciclo, em dias, para o processamento e pagamento de reivindicações de seguro de saúde, feitas por 40 empregados em uma grande companhia (MONTGOMERY, 2017). A Tabela 4 e Tabela 5 apresentam exemplos de gráficos de ramo-e-folhas e a sua versão “ordenado”, respectivamente, os quais podem ser construídos para esse caso.

48	41	35	36	37	26	36	46	35	47
35	34	36	42	43	36	56	32	46	30
37	43	17	26	28	27	45	33	22	27
16	22	33	30	24	23	22	30	31	17

Ramo	Folha	Frequência
1	767	3
2	6687272432	10
3	56765546620733001	17
4	816723635	9
5	6	6

Tabela 4. Exemplo de gráfico de ramo-e-folhas
Fonte: Adaptado de Montgomery (2017)

Ramo	Folha	Frequência
1	677	3
2	2223466778	10
3	00012334555666677	17
4	123356678	9
5	6	6


Tabela 5. Exemplo de gráfico de ramo-e-folhas ordenado
Fonte: Adaptado de Montgomery (2017)

A Tabela 4 e Tabela 5 são tabelas de frequência com informações adicionais. Observa-se que os dados brutos (originais) não são perdidos, exceto a ordem em que eles foram coletados (Tabela 4), mas a opção do gráfico “ordenado” (Tabela 5) mantém a ordem de coleta deles dentro de cada ramo. Quando há muitas folhas e poucos ramos, pode-se utilizar a estratégia de divisão dos ramos, por exemplo, dividir cada ramo em uma metade inferior e uma metade superior, com as folhas 0–4 associadas à porção inferior do ramo, e as folhas 5–9 associadas à porção superior. Alguns softwares ainda oferecem outras variações desse gráfico.

2.9. Gráfico de Pareto

O gráfico (ou diagrama) de Pareto é um gráfico de barras verticais para indicar qual problema, relacionado com a variabilidade dos dados, deve ser solucionado primeiro a fim de se eliminar defeituosos e melhorar o processo. Existem muitos aspectos da produção que podem ser melhorados, tais como: número de defeituosos, tempo de execução de tarefas, etc. Devido à quantidade de pequenos problemas é difícil se saber por onde começar. O gráfico de Pareto é uma ajuda neste sentido e é o primeiro passo na direção do melhoramento do processo.

A Figura 14 apresenta a quantidade de defeitos que ocorrem em determinado processo antes (a) e depois (b) da melhoria no processo.




(a) antes da melhoria

(b) depois da melhoria

Figura 14. Exemplos de gráfico de Pareto

Fonte: Lopes (2007)

A Figura 15 apresenta o número de reclamações de clientes em serviços externos e o custo para atender essas reclamações. Dependendo do ponto de vista (quantidade ou custo), a prioridade na atuação das causas é diferente.



(a) quantidade de reclamações

(b) custo das reclamações

Figura 15. Exemplos de gráfico de Pareto

Fonte: Brassard (2004)

Passos para a construção de um gráfico de Pareto (BRASSARD, 2004):

- 1) Selecione os problemas que serão comparados e enumerados pelo grau de importância através de: *brainstorming* e dados existentes.
- 2) Selecione o padrão de comparação (unidades de medidas), por exemplo, custo mensal, frequência semanal, etc.
- 3) Selecione o período de tempo a ser estudado.
- 4) Junte dados necessários para cada categoria.
- 5) Compare a frequência ou custos de cada categoria com todas as outras.
- 6) Ordene as categorias da esquerda para a direita no eixo horizontal em ordem decrescente de frequência ou custo. As categorias contendo as menores quantidades de itens devem ser combinadas em uma categoria chamada 'outros', que é colocada no extremo direito com a última barra.
- 7) Acima de cada classificação ou categoria, desenhe um retângulo cuja altura deve representar a frequência ou custo na classificação.
- 8) Do topo da barra mais alta e movendo para cima a partir da esquerda para a direita, uma linha pode ser traçada que representa a frequência cumulativa das categorias. Isto responde questões tais como: "Quando do total é acumulado pelas primeiras três categorias?"

2.10. Diagrama de Causa e Efeito

O Diagrama de Causa e Efeito (também conhecido por espinha de peixe ou diagrama de Ishikawa, em homenagem ao seu criador) é um método gráfico para auxiliar a análise de problemas que facilita a identificação das causas de variação da característica de qualidade em questão. Este tipo de diagrama é recomendado para quando for preciso identificar, explorar e expor as possíveis causas de um problema específico ou condição. O diagrama de causa e efeito (DCE) foi desenvolvido para representar a relação entre alguns efeitos e todas as possíveis causas que o influenciam. O efeito ou problema deve ser colocado do lado direito do gráfico e as maiores influências ou causas são listadas do lado esquerdo (BRASSARD, 2004; LOPES, 2007). A Figura 16 apresenta um diagrama ilustrado de causa e efeito genérico.




Figura 16. : Diagrama ilustrado de causa e efeito
Fonte: Lopes (2007)

Conforme Lopes (2007), a configuração do DCE permite separar organizadamente as quatro principais causas de variação:

a) Materiais: A matéria-prima difere na composição conforme seja a fonte de suprimento e o fornecedor, e diferenças no tamanho podem ocorrer dentro de limites aceitáveis.

b) Maquinaria: Desgaste, uso inadequado ou falta de ajuste em ferramentas, máquinas ou equipamentos são exemplos de possíveis causas. O equipamento pode parecer estar funcionando uniformemente, mas suas partes podem estar de alguma forma com pequenos desajustes, gastas ou não ser apropriadas para aquele uso.

c) Método: O método de trabalho, embora programado de acordo com o processo prescrito, pode conduzir a variações no produto;

d) Pessoas (Mão-de-obra): Os operadores podem não estar adequadamente preparados para as tarefas.

Alguns DCE ainda consideram outras causas de variação, como, por exemplo, condições ambientais (temperatura, umidade do ar, pressão atmosférica, etc.) e medidas (calibração de ferramentas, método de medição, erro de medição, etc.), conforme mostra a Figura 17.




Figura 17. : Diagrama ilustrado de causa e efeito

Fonte: Werkema (1995)

A Figura 18 apresenta dois exemplos de DCE: (a) uma aplicação na indústria (taxa de produção baixa) e (b) uma aplicação em serviços (atrasos nos resultados de laboratório). Nota-se que há uma espinha principal, depois espinhas secundárias, terciárias, etc. Deve-se relacionar todas as possíveis causas e os possíveis motivos dessas causas.




Figura 18. : Exemplos de DCE
Fonte: Brassard (2004)

Conforme Brassard (2004), a construção de um DCE pode seguir os seguintes passos:

- 1) Para gerar as causas é necessário construir um diagrama de causa e efeito através de um dos dois meios: um *brainstorming* (mais recomendado) ou utilizar folhas de verificação simples para localizar as possíveis causas e examinar o processo de produção mais de perto.
- 2) Construa o real diagrama de causa e efeito: coloque o problema na caixa da direita; coloque as categorias tradicionais maiores de causa principal no processo de produção, ou qualquer causa que é útil na organização dos fatores mais importantes; coloque as idéias do *brainstorming* nas maiores categorias apropriadas; para cada causa pergunte, "Porque isto acontece?" e liste respostas nos ramos das causas.
- 3) Interpretação: olhe para causas que aparecem e busque consensos da equipe envolvida para definir as ações.

2.11. Gráfico de Dispersão

O Gráfico de Dispersão (ou Diagrama de Dispersão) é um gráfico que apresenta o relacionamento (ou a correlação) entre duas variáveis. Ele geralmente é utilizado para verificar a possível relação de causa e efeito entre duas variáveis, mas pode ser usado para verificar a correlação entre duas causas ou dois efeitos. A relação visualizada no gráfico expressa a magnitude e o sentido da relação entre as variáveis. Quanto mais próximos estão os pontos, maior é o grau de relacionamento (ou a correlação) entre as variáveis e vice-versa. Se o comportamento do gráfico não apresentar nenhuma tendência, então não há relação entre as variáveis. A Figura 19 apresenta exemplos de padrões comportamentais de gráficos de dispersão e a interpretação associada.




Figura 19. Exemplos de padrões comportamentais de gráficos de correlação
Fonte: Werkema (1995)

A Figura 20 apresenta dois Gráficos de Dispersão: (a) uma aplicação na indústria (estabilidade do ingrediente ativo) e (b) uma aplicação em serviços (relação entre horas extras e quantidade de erros apurados).




Figura 20. Exemplos de gráficos de dispersão
Fonte: Brassard (2004)

Para construir um gráfico de dispersão, Brassard sugere:

- 1) Coletar dados das duas variáveis a serem estudadas no processo
- 2) Plotar os resultados em um gráfico onde o eixo X representa uma variável (geralmente a causa) e o eixo Y representa a outra variável (geralmente o efeito).

Quando há relação entre causa e efeito, pode-se ainda calcular a correlação entre as variáveis e ajustar uma equação de regressão linear entre elas.

2.12. Gráfico Sequencial

Gráfico sequencial (ou carta de tendência) é recomendado para quando é preciso observar a tendência dos pontos observados sobre um especificado período de tempo. É utilizado para monitorar um processo, verificando, ao longo do tempo, se a média está mudando ou se há tendências, porém são menos sofisticados que os gráficos de controle. A Figura 21 apresenta dois gráficos sequenciais: (a) uma aplicação na indústria (percentual de aceitação no primeiro teste de placas de circuito impresso) e (b) uma aplicação em serviços (admissão à sala de emergência).

Por se tratar de uma série temporal, o gráfico pode ser decomposto em componentes de sazonalidade e tendência ou pode ser utilizado para ajustar um modelo mais sofisticado de séries temporais aos dados.





Figura 21. Exemplos de gráficos sequenciais

Fonte: Brassard (2004)

2.13. Estratificação

Conforme Brassard (2004), a estratificação é uma técnica utilizada quando os dados mascaram os fatos reais. Isso geralmente ocorre quando os dados provêm de diferentes fontes, porém são tratados sem distinção. A estratificação quebra uma representação em categorias ou classes mais significativas a fim de direcionar melhor a ação corretiva.

A Figura 22 apresenta dois gráficos (do tipo sequencial) da quantidade de acidentes de trabalho de em uma empresa. No primeiro gráfico (a) tem-se a quantidade de acidentes ao longo do tempo, mas não é possível identificar onde eles estão ocorrendo. Já no segundo gráfico (b), os dados estão estratificados segundo o departamento, onde verifica-se que ocorrem mais acidentes no departamento A.




(a) por mês (b) por mês e por departamento

Figura 22. Exemplos de estratificação

Fonte: Brassard (2004)

A Figura 23 apresenta outra forma de estratificação, onde dois gráficos de controle mostram a conservação térmica em seis horas de amostras de ampolas do tipo A0 em uma empresa de produtos térmicos. No primeiro gráfico (a), não há a identificação do fornecedor, e no segundo gráfico (b), cada símbolo diferente representa um fornecedor diferente. Pode-se verificar que alguns fornecedores proporcionam uma qualidade melhor (maior conservação térmica) do que os outros, para um mesmo produto.



(a) sem identificação do fornecedor

(b) com identificação do fornecedor

Figura 23. Exemplos de estratificação

2.14. Gráficos de Controle

O gráfico de controle (ou carta de controle) é um gráfico de acompanhamento de uma característica do processo, ao longo do tempo, composto por:

- (a) uma linha central, geralmente representada pela média do processo;
- (b) um limite superior de controle (LSC) ou limite de controle superior (LCS), e
- (c) um limite inferior de controle (LIC) ou limite de controle inferior (LCI).

Na Figura 24, pode-se visualizar um exemplo de gráfico de controle com seus limites de controle (LC) para monitorar a média do diâmetro de certo componente.





Figura 24. Exemplo de um gráfico de controle
Fonte: Ribeiro e Ten Caten (2011)


Na Figura 24, pode-se observar dois tipos de causas atuando sobre o processo: causas comuns e causas especiais. Se apenas as causas comuns estão presentes, o processo é estável e previsível, pois os pontos plotados permanecem dentro dos limites de controle e não apresenta nenhum padrão não-aleatório. Se causas especiais também estão presentes, o processo é instável e imprevisível, pois são esperados pontos fora dos limites de controle ou apresenta padrões não aleatórios na sequência de pontos, indicando a provável presença de causas especiais (RIBEIRO; TEN CATEN, 2011). Causas comuns e especiais serão estudadas com maior detalhe no próximo capítulo. A Figura 25 apresenta o comportamento de dois processos ao longo do tempo: (a) um processo estável (sob controle ou previsível) e (b) um processo instável (fora de controle ou imprevisível).



(a) processo estável (b) processo instável

Figura 25. : Distribuição de probabilidade de dois processos
Fonte: Ribeiro e Ten Caten (2011)

Normalmente, no início do monitoramento, os processos apresentam várias causas especiais, como pode ser visto na Figura 26. À medida que as causas especiais vão sendo identificadas e eliminadas através de ações corretivas e preventivas, o processo torna-se estável e previsível.



(a) processo fora de controle estatístico (b) processo sob controle estatístico

Figura 26. Exemplo de um processo antes (a) e depois (b) das ações
Fonte: Ribeiro e Ten Caten (2011)

Quando um processo se torna estável, então é possível analisar a sua capacidade (capabilidade do processo). O conceito de capacidade será apresentado na seção seguinte e os cálculos serão apresentados no próximo capítulo.

Muitas características podem ser monitoradas, por exemplo: dimensões de uma chapa de aço, número de defeitos em uma placa de circuito impresso, viscosidade de um produto químico, resistência de um material, peso de um pacote de feijão, quantidade de garrafas defeituosas, proporção de sapatos defeituosos, etc.

A Figura 27 apresenta dois gráficos de controle para (a) uma aplicação na indústria (gráficos para monitorar a média e a amplitude de uma medição do processo) e (b) uma aplicação em serviços (gráfico para monitorar o número de não-conformes da quantidade de atrasos na sala de operação por dia). Note que na Figura 27 (a) são apresentados dois gráficos de controle, um para média e outro para amplitude. Geralmente gráficos de controle para tendência central são acompanhados de gráficos de controle para variabilidade. Além disso, a Figura 27 (a) também apresenta uma planilha com os dados coletados e algumas estatísticas. Já o gráfico da Figura 27 (b) monitora uma contagem.




Figura 27. Exemplos de Gráficos de Controle

Fonte: Brassard (2004)

Devido à importância e à quantidade de gráficos de controles existentes, eles serão estudados com maior profundidade nos próximos capítulos.

2.15. Capabilidade do Processo

Como mostra a Figura 28, a presença de causas especiais torna o processo instável o que impossibilita a avaliação da sua capacidade. Quando todas as causas especiais forem eliminadas, o processo estará sob controle estatístico. Um processo em controle estatístico ou estável é aquele que possui variabilidade associada apenas às causas comuns, ou seja, ele segue um certo padrão previsível ao longo do tempo (RIBERIO; TEN CATEN, 2011).




Figura 28. Processo antes e depois da eliminação das causas especiais
Fonte: Ribeiro e Ten Caten (2011)

No entanto, esse padrão estável do processo pode ou não ser capaz de produzir peças que atendam às especificações de clientes ou de projeto. Pode-se então avaliar a real capacidade do processo comparando sua variabilidade (associada apenas às causas comuns) com as especificações. Essas especificações não são calculadas, mas determinadas pelo cliente (limites aceitáveis para manter a qualidade) ou definidas por algum órgão de controle de qualidade, por meio de normas e padrões, por exemplo, as normas da ABNT. Normalmente existem dois limites de especificação: o limite de especificação superior (LES), também chamado de limite superior de especificação (LSE), e o limite de especificação inferior (LEI), também chamado de limite inferior de especificação (LIE).

Como pode-se visualizar na Figura 29, quando o processo é instável, ou seja, apresenta causas especiais, a avaliação de sua capacidade não faz muito sentido, sendo difícil de avaliar devido à falta de confiabilidade dos dados, pois o resultado reflete apenas um determinado momento, já que o processo não apresenta um comportamento previsível. No caso do processo estável, o fato de ser capaz ou não, vai depender dos limites de especificação. No exemplo, há dois diferentes valores para os limites de especificação. Quando os valores são mais estreitos, o processo não é capaz, porém quando os valores são mais tolerantes, o processo é capaz. Entretanto, na prática, os limites de especificação não ficam variando, mas são fixados.

A Figura 30 mostra, da esquerda para a direita, um processo centralizado no valor alvo com variabilidade pequena e dentro dos limites de especificação (processo capaz), um processo não centralizado no valor alvo com variabilidade pequena, mas fora dos limites de especificação (processo não capaz), e um processo centralizado no valor alvo com variabilidade alta e fora dos limites de especificação (processo não capaz). O processo descentralizado é mais fácil de corrigir na prática, apenas ajustando o valor alvo (por exemplo, ajustando parâmetros de uma máquina) e sem “mexer” na variabilidade, tornando-o capaz, ou seja, dentro dos limites de especificação. Já no terceiro processo é necessário atuar na variabilidade do processo, o que não é tão simples na prática, pois geralmente envolve mudanças estruturais no sistema ou aquisição de novos equipamentos.




Figura 29. Avaliação da capacidade de dois processos
Fonte: Ribeiro e Ten Caten (2011)




Figura 30. Influência da média e do desvio padrão na capacidade do processo
Fonte: Montgomery (2017)

As características analisadas ou monitoradas podem ser de três tipos: nominal-é-melhor, maior-é-melhor e menor-é-melhor (RIBERIO; TEN CATEN, 2011):

- Nominal-é-melhor: tendem a apresentar uma distribuição de probabilidade aproximadamente simétrica, pois as causas de variabilidade geram valores que podem se afastar tanto para cima como para baixo do alvo. Elas apresentam limite superior de especificação (LSE) e limite inferior de especificação (LIE). Por exemplo: espessura, largura, comprimento, viscosidade, peso.
- Maior-é-melhor: tendem a apresentar uma distribuição de probabilidade assimétrica à esquerda. Elas apresentam apenas limite inferior de especificação (LIE). Por exemplo: resistência mecânica, durabilidade.
- Menor-é-melhor: tendem a apresentar uma distribuição de probabilidade assimétrica à direita. Elas apresentam apenas limite superior de especificação (LSE). Por exemplo, nível de ruído, consumo elétrico, desgaste.

Em um ambiente competitivo, só há espaço para as empresas que adotam uma ótica de melhoria contínua. Gráficos de controle e a capacidade do processo estão sempre associados no processo de melhoria contínua (vide Figura 31). Assim, periodicamente é preciso rever as especificações, reavaliar a capacidade do processo e agir sobre o sistema quando necessário. A melhora da qualidade, representada pela redução da variabilidade do processo, promove, natural e inevitavelmente, um aumento de produtividade. Com a melhora da qualidade, os custos diminuem devido à redução do retrabalho, erros e atrasos, e da melhor utilização da tecnologia e matéria-prima. Conseqüentemente, a produtividade aumenta, possibilitando a captação de mercados. Trabalhando-se continuamente pela qualidade, os novos negócios são mantidos e amplia-se a fatia de mercado (RIBEIRO; TEN CATEN, 2011).




Figura 31. Melhoria contínua do processo
Fonte: Adaptado de Ribeiro e Ten Caten (2011)

Devido à importância e à relação direta com os gráficos de controles, os cálculos da capacidade do processo serão estudados no mesmo capítulo dos gráficos de controle.

3. Gráficos de Controle e Capacidade do Processo

Como visto no Capítulo anterior, o gráfico de controle (ou carta de controle) é um gráfico de acompanhamento de uma característica do processo, composto por um limite superior de controle (LSC) e um limite inferior de controle (LIC).

Existem vários tipos de gráficos de controle para cada situação diferente. Em geral, podemos dividir os gráficos de controle em dois tipos principais: os gráficos de controle para variáveis e os gráficos de controle para atributos.

Nesse capítulo, juntamente com os gráficos de controle, também será abordada a capacidade do processo. Como visto no capítulo anterior, os gráficos de controle e a capacidade do processo fazem parte do processo de melhoria contínua da qualidade.

3.1. Tipos de Causas da Variabilidade do Processo

Antes de iniciarmos o estudo sobre os gráficos de controle, é interessante conhecer quais são os tipos de causas que podem atuar na variabilidade do processo. Todo processo que não é determinístico, ou seja, que produz sempre o mesmo resultado sob as mesmas condições, está sujeito à variabilidade. Essa variabilidade pode ser devido a três tipos de causas (ZALEWSKI; EDWARD, 2001):

- Causas Comuns: São causas naturais do processo, devido à variabilidade inerente comum do processo, que pode ser influenciada por vários fatores.
- Causas Especiais: São causas incomuns, resultantes de uma interferência incomum (não esperada) no processo.
- Causas Estruturais: São causas naturais de processos que apresentam autocorrelação (esse assunto será tratado em um capítulo à parte posteriormente).

3.1.1. Causas Comuns

Segundo Ribeiro e Ten Caten (2011), as causas comuns são as diversas fontes (ou causas) de variação que atuam de forma aleatória no processo, gerando uma variabilidade inerente (ou natural) do processo. Essa variabilidade representa o padrão natural do processo, pois é resultante do efeito cumulativo de pequenas fontes de variabilidade (causas) que acontecem diariamente, mesmo quando o processo está trabalhando sob condições normais de operação. Essa variabilidade é puramente aleatória e, portanto, pode ser prevista.

São exemplos de fatores que atuam nas causas comuns: flutuações na qualidade dos materiais usados e das variações nas condições de operação do processo de produção. Em geral, esses fatores não podem ser controlados.

Um processo que apresenta apenas as causas comuns atuando é dito um processo estável ou sob controle, pois apresenta sempre a mesma variabilidade, em torno de uma média, ao longo do tempo. A Figura 32 apresenta um Gráfico de Controle de um processo sob controle.




Figura 32. Exemplo de Gráfico de Controle de um Processo sob Controle
 Fonte: Moreira Junior (2005)

Devido à variabilidade inerente do processo, as medidas individuais de uma característica de qualidade são todas diferentes entre si, mas quando agrupadas elas tendem a formar um certo padrão de comportamento, o que determina a sua distribuição de probabilidades. A Figura 33 apresenta alguns formatos e tipos de distribuição de probabilidades.




Figura 33. Distribuição de probabilidade de um processo.
 Fonte: Ribeiro e Ten Caten (2011).

Existem vários tipos de distribuição de probabilidades, mas muitos processos, na maioria das vezes, podem ser representados por uma distribuição de probabilidade Normal, como pode-se observar na Figura 34. Alguns gráficos de controle pressupõem que a característica de monitoramento tenha Distribuição Normal.




Figura 34. Distribuição de probabilidade de um processo.

Fonte: Ribeiro e Ten Caten (2011).

Atuar sobre as causas comuns, ou seja, na variabilidade natural do processo, é muito difícil na prática. Em geral, as causas comuns só podem ser resolvidas por uma ação global sobre o sistema, e muitas vezes a atuação sobre elas não se justifica economicamente. Ou seja, atuar na redução da variabilidade do processo nem sempre é possível e exige uma decisão gerencial.

3.1.2. Causas Especiais

Segundo Ribeiro e Ten Caten (2011), as causas especiais são causas que não seguem um padrão aleatório e por isso também são chamadas de causas assinaláveis. São consideradas falhas de operação e fazem com que o processo saia do seu padrão natural de operação, ou seja, provocam alterações na forma, tendência central ou variabilidade das características de qualidade. Elas reduzem significativamente o desempenho do processo e devem ser identificadas e neutralizadas, pois sua correção se justifica economicamente.

São exemplos de situações que podem ocasionar uma causa especial: uma máquina mal ajustada com parâmetros mal regulados, falta de óleo na máquina, matéria prima de fornecedores diferentes, matéria prima com medidas de proporções erradas, operador inexperiente ou mal treinado, flutuações na corrente elétrica do equipamento, temperatura inadequada, etc.

Um processo que apresenta as causas especiais atuando é dito um processo instável ou fora de controle, pois apresenta uma variabilidade inconstante, em torno de uma média, ao longo do tempo. A Figura 35 apresenta quatro Gráficos de Controle de processos que estão fora de controle. O gráfico (a) identifica a presença de uma tendência crescente nos dados, o gráfico (b) identifica que houve uma mudança na média do processo, o gráfico (c) apresenta pontos observados fora dos limites de controle, e o gráfico (d) sinaliza uma presença cíclica no processo. A Figura 36 apresenta gráficos com indicativos de causas especiais, incluindo a presença de sete pontos em seqüência acima (ou abaixo) da linha central e sete pontos em seqüência ascendente (ou descendente). Também são relacionadas as possíveis causas que podem justificar o comportamento. Ressalta-se que nem todos os autores relacionam as mesmas regras para a identificação de causas especiais, inclusive os softwares utilizados para as análises.






Figura 35. Exemplo de Gráfico de Controle de Processos fora de controle
Fonte: Moreira Junior (2005)



7 ou mais pontos acima ou abaixo da Linha Central

Possíveis causas:


- Mudança no ajuste de máquina
- Processo, método ou material diferente
- Avaria de um componente na máquina
- Quebra de máquina
- Grande variação no material recebido



7 ou mais pontos Subindo ou Descendo

Possíveis causas:


- Desgaste de Ferramenta
- Gradual desgaste do equipamento
- Desgaste relacionado ao instrumento de medição



Pontos fora dos Limites de Controle

Possíveis causas:


- Erro na medição ou digitação
- Quebra de ferramenta
- Instrumento de medição desregulado
- Operador não consegue identificar a medida



Periodicidade dos Pontos

Possíveis causas:

- Não-uniformidade na matéria-prima recebida
- Rodízio de Operadores, Gabaritos e instrumentos
- Diferença entre turnos



Deslocamento da Média


Possíveis causas:

- Novo Método
- Nova Máquina
- Melhoria de Qualidade
- Novo Lote de Material

Quando qualquer um dos comportamentos for identificado durante o processo, o operador deve intervir no processo e registrar a ação no plano de ação para fora de controle

Figura 36. Exemplo de Causas Especiais
Fonte: Ribeiro e Ten Caten (2011).

1. Um ou mais pontos fora dos limites de controle.
2. Dois ou três pontos consecutivos fora dos limites de alerta “dois sigmas”, mas ainda dentro dos limites de controle.
3. Quatro ou cinco pontos consecutivos além dos limites de “um sigma”.
4. Uma sequência de oito pontos consecutivos de um mesmo lado da linha central.
5. Seis pontos em uma sequência sempre crescente ou decrescente.
6. Quinze pontos em sequência na zona C (tanto acima quanto abaixo da linha central).
7. Quatorze pontos em sequência alternadamente para cima e para baixo.
8. Oito pontos em sequência de ambos os lados da linha central com nenhum na zona C.
9. Um padrão não usual ou não aleatório nos dados.
10. Um ou mais pontos perto de um limite de alerta ou de controle.



Em suma, todo comportamento não aleatório, ou seja, não previsível segundo a distribuição de probabilidade da característica, pode indicar a presença de causas especiais. Atuar sobre as causas especiais, ou seja, na variabilidade eventual do processo, geralmente é mais fácil na prática. As causas especiais muitas vezes são corrigidas por ação local e, por isso, são geralmente de responsabilidade dos operadores, apesar de algumas vezes a gerência estar em melhor posição para resolver o problema.

Quando as causas especiais são identificadas, pode-se atuar sobre elas, melhorando continuamente os processos de produção e, por conseguinte, a qualidade do produto final.

3.1.3. Causas Estruturais

Segundo Moreira Junior (2005), as causas estruturais são inerentes (ou naturais) de processos que possuem autocorrelação, isto é, processos onde as observações não são independentes. Nesse caso, o uso de gráficos de controle não possui um bom desempenho (pois, como será visto posteriormente, um dos pressupostos para a utilização dos gráficos de controle é que as observações devem ser independentes), podendo surgir falsos alarmes indicando uma situação “fora de controle” quando na verdade eles são devidos a causas naturais de um processo autocorrelacionado. Nessas situações, é necessário primeiramente tratar os dados para eliminar o efeito da autocorrelação do processo, para posteriormente controlá-los estatisticamente.

Um dado está autocorrelacionado com um ou mais dados anteriores quando existe uma influência desses dados anteriores que atua no dado atual que está sendo observado. Isso pode ocorrer em processos de fabricação de envolvem parâmetros como umidade e temperatura residuais, por exemplo.

Um processo autocorrelacionado é dito um processo estável, porém sob controle, pois não se comporta de forma adequada para ser monitorado por um gráfico de controle, ao longo do tempo. A Figura 38 apresenta um Gráfico de Controle de um processo autocorrelacionado. Observa-se que, aparentemente, várias observações estão fora dos limites de controle do gráfico, entretanto, essas observações não são causas especiais, como aparentam ser, mas são causas estruturais e naturais do processo.




Figura 38. Exemplo de Gráfico de Controle de um Processo com autocorrelação
Fonte: Moreira Junior e Ten Caten (2003)

Para o tratamento dos dados autocorrelacionados, muitos métodos têm sido propostos. Eles podem ser classificados em três grupos: (i) aqueles que sugerem um ajuste por modelos ARIMA (Auto-Regressivo Integrado de Média Móvel) e posteriormente o monitoramento dos resíduos através de algum gráfico de controle, (ii) aqueles que propõem modificações nos limites dos gráficos de controle e (iii) outras técnicas específicas (MOREIRA JUNIOR, 2005).

A Tabela 6 apresenta um resumo das causas comuns, especiais e estruturais, em relação ao tipo de variação, à situação do processo e à ação requerida.

Tipo de causa	Tipo de Variação	Situação do Processo	Ação Requerida
Comum	inerente, natural e previsível	Sob controle estatístico (estável)	Nenhuma ou atuar sobre o sistema global
Especial	incomum, eventual, <i>outlier</i>	Fora de controle (instável)	Ação localizada
Estrutural	inerente, natural e previsível	Fora de controle, porém estável	Modelar a variável e depois controlar estatisticamente

Tabela 6. Resumo das causas comuns, especiais e estruturais.

3.2. Procedimentos Gerais para a Elaboração de Gráficos de Controle

Como visto na Seção 2.14, o gráfico de controle (ou carta de controle) é um gráfico de acompanhamento de uma característica do processo, composto por um limite superior de controle (LSC) e um limite inferior de controle (LIC). Existem vários tipos de gráficos de controle, os quais se classificam dentro de dois grupos: Gráficos de Controle para Variáveis (características medidas) e Gráficos de Controle para Atributos (características contadas). Todos esses gráficos estão sujeitos às mesmas fontes de variação descritas na Seção anterior. E todos esses gráficos possuem um procedimento padrão para a sua elaboração.

Sempre que for possível, deve-se optar por monitorar uma variável em vez de um atributo, pois uma medição contém muito mais informação do que a simplesmente classificar a peça como “dentro ou fora de especificação”. Como as medições fornecem mais informações, exigem uma amostra menor. Como a amostra é menor, o custo total de amostragem pode ser menor e o lapso de tempo entre a produção das peças e a ação corretiva pode ser encurtado. O processo para elaborar e implantar um gráfico de controle pode ser descrito com os seguintes passos (RIBERIO; TEN CATEN, 2011):

- 1) Coleta de dados;
- 2) Cálculo dos limites de controle;
- 3) Análise da estabilidade do processo;
- 4) Análise da capacidade do processo.

O procedimento para a coleta dos dados deve, sempre que possível, manter a mesma periodicidade na seleção da amostra (intervalo de tempo pré-definido), por exemplo, de hora em hora, uma vez por turno, uma vez por dia, etc. Essa periodicidade depende de cada processo que está sendo analisado. Já o tamanho da amostra dependerá do tipo de gráfico de controle a ser utilizado. Isso será discutido para cada caso, nesse capítulo.

Logo após, com base na amostra coletada, calculam-se as estatísticas necessárias e os limites de controle, e elabora-se o gráfico de controle, sendo que para cada tipo de gráfico de controle, há uma forma de calcular os limites de controle. Os Limites de Controle são, na verdade, intervalos de confiança (IC) em torno da média do processo. Já que a análise do processo é realizada através de amostragem, a estimativa da média e da variabilidade do processo é realizada através de um intervalo no qual se admite que

esteja a verdadeira média e variabilidade populacional. Como não é possível saber com certeza onde estará o verdadeiro parâmetro populacional, deve ser atribuir uma probabilidade ao intervalo em que o verdadeiro valor possa estar. Esse intervalo chama-se intervalo de confiança, e a confiança associada é $1 - \alpha$. A interpretação é a seguinte: o intervalo possui uma probabilidade igual a $1 - \alpha$ de conter a verdadeira média populacional. No CEP, usualmente utiliza-se intervalos de confiança de 99,73%, valor relacionado a três desvios padrões em relação à média.

Existem dois tipos de erros (Tabela 7) no monitoramento de uma carta de controle: Erro Tipo I e Erro Tipo II. A quantidade α (Erro Tipo I) é a probabilidade do erro, ou seja, é a probabilidade do intervalo não conter a verdadeira média populacional. No contexto do CEP, Erro Tipo I é a probabilidade (α) de considerar o processo fora de controle quando na verdade ele está sob controle. Como usualmente utiliza-se intervalos de confiança de 99,73%, consequentemente, a probabilidade de erro é 0,27%. Isso significa que, ao longo de um monitoramento de uma característica que está sob controle estatístico, a probabilidade de uma causa comum aparecer fora dos LC é 0,27%, ou seja, é esperado que isso ocorra cerca de 27 vezes a cada 10.000 valores monitorados. O Erro Tipo II é a probabilidade (β) de considerar o processo sob controle quando na verdade ele está fora de controle e depende do deslocamento da média (d) e dos limites de controle adotados.

		Realidade desconhecida	
		H0 Verdadeira (processo está sob controle)	H0 Falsa (processo não está sob controle)
Decisão	Aceitar H0	Decisão Correta ($1 - \alpha$)	Erro Tipo II (β)
	Rejeitar H0	Erro Tipo I (α)	Decisão Correta ($1 - \beta$)

Tabela 7. Tipos de erro em CEP.

Construído o gráfico de controle, analisa-se a estabilidade do processo, ou seja, verifica-se se existem causas especiais. Se não houver causas especiais, então o processo está sob controle e a sua capacidade pode ser avaliada. Geralmente, no início do monitoramento, os processos apresentam várias causas especiais. Dessa forma, essas devem ser sendo identificadas e as suas causas controladas para que não venha a ocorrer novamente. Os limites de controle devem recalculados eliminando-se as amostras que são causas especiais (elas são eliminadas do cálculo, mas permanecem no gráfico de controle, embora nem todo *software* permita fazer isso) e verifica-se se aparecem outras causas especiais. Esse processo iterativo acontece no início, pois os limites de controle devem estar associados apenas às causas comuns de variabilidade, já que as causas especiais tendem a afastar os LC, pois aumenta a variabilidade.

Com o processo sob controle, avalia-se a sua capacidade. Para cada tipo de gráfico de controle e variável, existe uma forma para avaliar a capacidade, o que será visto posteriormente nesse Capítulo.

Mesmo com o processo sob controle, periodicamente, os limites de controle devem ser recalculados e, sempre que houver evidências, estreitados. Dessa forma, as cartas de controle continuarão servindo como uma ferramenta eficaz no gerenciamento da variabilidade, separando as causas comuns das causas especiais e auxiliando na busca da melhoria contínua. O CEP deve ser entendido como uma atividade dinâmica. Se ações de melhoria estão sendo tomadas, o processo deve apresentar um desempenho mais consistente, com redução da variabilidade. Se os limites de controle não forem recalculados e estreitados, os gráficos de controle consideram causas especiais como

3.3.1. Gráfico de Controle para a Média e para a Amplitude

Os gráficos de controle para a média ($\bar{\bar{x}}$) e amplitude (R), são as aplicações mais tradicionais do CEP.

Os dados devem ser coletados em pequenos subgrupos (amostras) de tamanho constante. Vale lembrar que quanto maior o tamanho da amostra maior a sensibilidade dos gráficos, ou seja, eles detectam melhor pequenas mudanças no processo. No entanto, aumentar o tamanho da amostra representa aumentar o custo de amostragem. Na prática, 3 a 6 observações consecutivas formam uma amostra adequada. Por serem consecutivas, essas observações são coletadas em condições muito similares e, portanto, a variabilidade dentro de cada subgrupo será primariamente devido às causas comuns de variabilidade. Os subgrupos devem ser coletados a uma frequência periódica, por exemplo, 1 subgrupo a cada 10 minutos, ou 3 subgrupos por lote. A frequência de amostragem deve ser definida de forma que exista uma chance potencial de mudança dos resultados (causa especial) de um subgrupo para o outro. A frequência das amostras deve ser selecionada de forma a maximizar a chance de ocorrer diferenças entre amostras.

O formulário da carta de controle, seja em papel ou em planilha/janelas de computador, deve conter:

- a) espaço para a completa identificação da característica que está sendo medida;
- b) tabela para as anotações dos valores individuais medidos, com espaço para cálculo da média e da amplitude de cada subgrupo;
- c) espaço para a carta de médias;
- d) espaço para a carta de amplitudes.
- e) informações como: nome do colaborador que está coletando, turno, data e hora.

Quando a variação de uma característica da qualidade é gerada pela soma (ou média) de um grande número de erros infinitesimais independentes devido a diferentes fatores, como é o caso das médias amostrais, a distribuição da característica de qualidade se torna, em muitos casos, aproximadamente uma distribuição Normal (KUME, 1993).

O gráfico de controle para média utiliza o Teorema do Limite Central (TLC), que prova que a soma, e consequentemente, a média, de n valores individuais tende a seguir a Distribuição Normal, independentemente da distribuição de probabilidade dos valores individuais. Essa aproximação melhora na medida em que n aumenta. Ribeiro e Ten Caten (2011) mencionam que se as distribuições dos valores individuais não forem muito diferentes da Normal, basta $n = 4$ ou 5 para se obter uma boa aproximação. Porém se as distribuições dos valores individuais forem muito diferentes da Normal, então será necessário $n = 15$ ou mais para se obter uma boa aproximação pela Normal. A Figura 40 mostra um desenho esquemático de como funciona o TLC.




Figura 40. Desenho esquemático de como funciona o TLC.
Fonte: Ribeiro e Ten Caten (2011)

Para exemplificar essa situação, considere o lançamento de um dado honesto (com Distribuição Uniforme Discreta) e a média de n lançamentos de todas as situações possíveis desse dado. À medida que $n \rightarrow \infty$, a distribuição amostral da média torna-se mais parecida com a Distribuição Normal, conforme mostra a Figura 41.




Figura 41. Distribuição amostral da média do lançamento de dados

O controle estatístico do processo, em geral trabalha com a média das amostras, pois independente da distribuição dos valores individuais, a média desses valores irá seguir aproximadamente a distribuição Normal, segundo o TLC. Portanto, sempre que for possível, deve-se optar monitorar a média.

A partir do TLC, sabe-se que a distribuição amostral das médias apresenta os seguintes parâmetros:

média: $\bar{\bar{x}} = \mu$, e

desvio padrão: $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$,

onde:

$\bar{\bar{x}}$ é a média das médias amostrais,

μ é a média dos valores individuais da população,

$\sigma_{\bar{x}}$ é o desvio padrão das médias amostrais,

σ é o desvio-padrão dos valores individuais da população, e

n é o tamanho da amostra.

Observa-se que a média das médias amostrais é igual a média dos valores individuais da população e o desvio-padrão das médias é menor do que o desvio-padrão dos valores individuais da população na proporção de $1/\sqrt{n}$.

Os limites da distribuição dos valores individuais são chamados de limites naturais (LN) e os limites da distribuição de probabilidade das médias são chamados de limites de controle (LC). Como observa-se na Figura 42, para um $n > 1$, a variabilidade

da distribuição amostral das médias sempre terá menor variabilidade do que a distribuição dos valores individuais, quando esses possuem distribuição Normal




Figura 42. Relação entre a Distribuição de probabilidade dos valores individuais (σ) e a distribuição de probabilidade das médias ($\sigma_{\bar{x}}$)

Fonte: Ribeiro e Ten Caten (2011)

Para construir um intervalo de confiança de 99,73% para a média, é necessário achar os limites L e U, tais que $P(L \leq \mu \leq U) = 0,9973$. Os limites de confiança de $100(1 - \alpha)\%$ são calculados usando-se a distribuição Normal:

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

onde:

$z_{\alpha/2}$ representa a variável Z da Distribuição Normal Padronizada correspondente à probabilidade do erro $\alpha/2$.

No caso do CEP, que utiliza intervalo de confiança de 99,73%, o valor da variável Z da Distribuição Normal Padronizada correspondente à probabilidade do erro $0,0027/2 = 0,00135$ é 3. Ou seja, como mostra a Figura 43, três desvios padrões para cima ou para baixo fornecem o IC:

$$\bar{x} - 3 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + 3 \frac{\sigma}{\sqrt{n}}$$

ou

$$\bar{x} - 3\sigma_{\bar{x}} \leq \mu \leq \bar{x} + 3\sigma_{\bar{x}}.$$




Figura 43. Distribuição de probabilidade das médias

Fonte: Ribeiro e Ten Caten (2011)

O cálculo preliminar dos limites de controle pode ser feito após a coleta de umas 20 ou 30 amostras (subgrupos) sem indícios de uma situação fora do controle. Ou seja, coleta-se de 20 a 30 amostras, calcula-se os limites de controle para a média e amplitude e compara-se essas mesmas amostras com os limites de controle calculados.

A fim de calcular os limites de controle, inicialmente calcula-se a amplitude e a média para cada amostra. Logo após, calcula-se a média das amplitudes, por:

$$\bar{R} = \frac{\sum_{i=1}^k R_i}{k} = \frac{R_1 + R_2 + \dots + R_k}{k},$$

onde:

k é a quantidade de amostras (ou de subgrupos), e

R_i é a amplitude da amostra i , ou seja:

$$R_i = X_j(MAX) - X_j(MIN).$$

Também calcula-se a média das médias das amostras, por:

$$\bar{\bar{x}} = \frac{\sum_{i=1}^k \bar{x}_i}{k} = \frac{\bar{x}_1 + \bar{x}_2 + \dots + \bar{x}_k}{k},$$

onde:

n é o tamanho da amostra (ou do subgrupo), e

$\bar{x}_i$ é a média da amostra i , ou seja:

$$\bar{x}_i = \frac{\sum_{j=1}^n x_j}{n}.$$

Observa-se que a variabilidade é estimada usando-se a média das amplitudes dentro de cada amostra para garantir que ela esteja associada apenas às causas comuns. Logo, não está correto estimar a variabilidade usando a fórmula tradicional de desvio-padrão (s) aplicada sobre o conjunto de todos os dados, pois desta forma a estimativa da variabilidade poderia estar associada com causas comuns (dentro das amostras) e causas especiais (entre amostras) (RIBEIRO; TEN CATEN, 2011).

Uma vez calculados $\bar{R}$ e $\bar{\bar{x}}$, calcula-se os limites de controle considerando-se a amplitude de seis desvios-padrões (três para cima e três para baixo), que, segundo a distribuição Normal compreende 99,73% dos valores de médias amostrais. Baseada nos IC vistos anteriormente, a fórmula para obter os LC é:

$$LC = \bar{\bar{x}} \pm 3 \frac{\sigma}{\sqrt{n}}.$$

Como a variabilidade dos valores individuais é estimada a partir da média das amplitudes dos subgrupos, utiliza-se a relação:

$$\sigma = \frac{\bar{R}}{d_2},$$

onde d_2 é uma constante que depende do tamanho da amostra (vide Anexo C). Segundo Montgomery (2004), a constante d_2 é a média (esperança) da variável conhecida como “amplitude relativa”, que é a razão entre a amplitude e o desvio padrão.

Substituindo-se essa expressão na equação dos LC, obtém-se:

$$LC = \bar{\bar{x}} \pm \frac{3\bar{R}}{d_2\sqrt{n}}.$$

Substituindo-se $A_2 = 3/(d_2\sqrt{n})$ na equação anterior, onde A_2 é uma constante (vide Anexo C), tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI):

$$LCS = \bar{\bar{x}} + A_2\bar{R}, \text{ e}$$

$$LCI = \bar{\bar{x}} - A_2 \bar{R}.$$

Para obter os LC para a amplitude, considerando o IC de 99,73%, tem-se:

$$LC = \bar{R} \pm 3\sigma_R,$$

onde

$$\sigma_R = d_3 \sigma,$$

onde d_3 é uma constante que depende do tamanho n da amostra (vide Anexo C). Segundo Montgomery (2004), a constante d_3 é o desvio padrão da variável conhecida como “amplitude relativa”, que, como mencionado anteriormente, é a razão entre a amplitude e o desvio padrão.

Assim como na situação anterior, a variabilidade dos valores individuais é estimada a partir da média das amplitudes dos subgrupos. Dessa forma, utiliza-se a mesma relação vista anteriormente:

$$\sigma = \frac{\bar{R}}{d_2},$$

obtendo-se os LC:

$$LC = \bar{R} \pm 3d_3 \frac{\bar{R}}{d_2} = \bar{R} \left(1 \pm 3 \frac{d_3}{d_2} \right).$$

Substituindo-se $D_4 = 1 + 3(d_3/d_2)$ e $D_3 = 1 - 3(d_3/d_2)$ na equação anterior, onde D_4 e D_3 são constantes (vide Anexo C), tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI):

$$LCS = D_4 \bar{R}, \text{ e}$$

$$LCI = D_3 \bar{R}.$$

O gráfico de médias monitora a variabilidade entre as médias amostrais ao longo do tempo e o gráfico de amplitude monitora a variabilidade dentro da amostra, ou seja, a variabilidade em um determinado período tempo. O monitoramento das cartas de controle é um teste de hipótese (TH) a cada nova amostra coletada. A hipótese nula que está sendo testada a cada amostra coletada é de que a média ou a variabilidade do processo continuam as mesmas (processo estável), tendo como hipótese alternativa que elas mudaram devido à presença de uma causa especial (processo instável). Antes de investigar uma causa especial, é interessante verificar se não houve erro na plotagem do ponto ou problemas no sistema de medição (RIBEIRO; TEN CATEN, 2011).

Resumo dos Limites de Controle

p/ Média	p/ Amplitude
$LCS = \bar{\bar{x}} + A_2 \bar{R}$ $LC = \bar{\bar{x}}$ $LCI = \bar{\bar{x}} - A_2 \bar{R}$ $\bar{\bar{x}} = \frac{\sum_{i=1}^k \bar{x}_i}{k} = \frac{\bar{x}_1 + \bar{x}_2 + \dots + \bar{x}_k}{k}$ $\bar{x}_i = \frac{\sum_{j=1}^n x_j}{n}$	$LCS = D_4 \bar{R}$ $LC = \bar{R}$ $LCI = D_3 \bar{R}$ $\bar{R} = \frac{\sum_{i=1}^k R_i}{k} = \frac{R_1 + R_2 + \dots + R_k}{k}$ $R_i = X_j(MAX) - X_j(MIN)$

Exemplo 1 (Fonte: adaptado de Ribeiro e Ten Caten, 2011): Considere os seguintes dados, referentes a 15 amostras de tamanho igual a 5 cada uma. Calculando-se os limites de controle para monitorar a média e a amplitude, obtêm-se os gráficos da Figura 44 e da Figura 45, respectivamente, elaborados pelo pacote qcc (SCRUCCA, 2004) do software R (R CORE TEAM, 2019).

Amostra	Medidas				
	Obs1	Obs2	Obs3	Obs4	Obs5
1	65	70	75	60	80
2	75	70	80	90	70
3	80	70	70	80	80
4	65	65	65	80	65
5	80	60	80	80	75
6	75	70	60	85	75
7	80	75	65	75	70
8	70	65	75	65	85
9	85	85	75	65	80
10	65	65	65	80	60
11	75	60	75	85	90
12	85	65	75	75	80
13	70	75	75	70	70
14	70	65	85	60	75
15	75	80	85	80	90
16	80	85	90	90	85




Figura 44. Gráfico de Controle para a Média do Exemplo 1

Conforme o gráfico para a média na Figura 44, observa-se um ponto fora de controle (amostra 16), acima do LCS. Por outro lado, o gráfico para a amplitude na Figura 45 não apresenta pontos fora de controle. Suponha que foi verificado na prática que realmente a amostra 16 foi afetada por uma causa especial, deve-se eliminar esse ponto da análise e refazer os gráficos, recalculando os LCs.




Figura 45. Gráfico de Controle para a Amplitude do Exemplo 1

Após a eliminação da causa especial, os limites de controle foram recalculados e gráficos de controle foram refeitos. Conforme o gráfico para a média na Figura 46, observa-se que nenhum outro ponto fora de controle apareceu, com exceção daquele já existente (amostra 16). Salienta-se que os limites de controle foram recalculados sem considerar a amostra 16, no entanto, a observação histórica da amostra 16 não é eliminada no gráfico, pois, de fato, ela ocorreu. O gráfico para a amplitude na Figura 47 não apresenta nenhum ponto fora de controle.




Figura 46. Gráfico de Controle para a Média do Exemplo 1




Figura 47. Gráfico de Controle para a Amplitude do Exemplo 1

Observa-se que agora esse processo é estável, já que nenhuma nova causa especial foi detectada. Como visto no capítulo anterior, quando o processo está estável (sem causas especiais), pode-se avaliar a capacidade do processo, que está associada com as causas comuns de variabilidade. O mesmo processo pode ser considerado capaz ou não dependendo das especificações do cliente (vide Figura 48).




Figura 48. Mesmo processo com especificações diferentes

Fonte: Ribeiro e Ten Caten (2011)

A avaliação da capacidade do processo é realizada com a distribuição dos valores individuais, pois o cliente espera que todas as peças produzidas estejam dentro das especificações. Dessa forma, é necessário conhecer a distribuição de probabilidade dos valores individuais da variável que está sendo monitorada e estimar a média, a variabilidade e os limites naturais do processo. Uma forma de conhecer a distribuição de probabilidade da variável é através do histograma dos dados coletados, ferramenta vista no capítulo anterior. Outras formas de conhecer a distribuição de probabilidade são através do papel de probabilidade, do teste gráfico de valores teóricos de Z ou da utilização do teste Qui-quadrado de ajuste de distribuições.

Uma vez identificada a distribuição dos valores individuais calcula-se os limites naturais (LN) da distribuição. Caso a distribuição dos valores individuais seja Normal, os limites naturais são calculados considerando-se a extensão de seis desvios-padrões (6σ), ou seja, três desvios padrões acima e abaixo da média. Dessa forma, os limites naturais compreendem 99,73% dos valores, ou seja, teoricamente 99,73% das peças produzidas estarão dentro dos limites naturais e 0,27% estarão fora dos limites naturais (RIBEIRO; TEN CATEN, 2011).

Os LN inferior e superior são calculados respectivamente por:

$$LNI = \mu - 3\sigma \text{ e}$$

$$LNS = \mu + 3\sigma .$$

A média da distribuição dos valores individuais é estimada pela média das médias $\bar{\bar{x}}$, enquanto que o desvio-padrão é estimado a partir da média das amplitudes das amostras, como visto anteriormente:

$$\hat{\sigma} = \frac{\bar{R}}{d_2}$$

ou a partir do desvio-padrão das amostras:

$$\hat{\sigma} = \frac{\bar{s}}{c_4} ,$$

onde c_4 é uma constante que depende do tamanho da amostra (vide Anexo C).

Uma maneira de expressar a capacidade do processo é utilizar os índices de capacidade que comparam os limites naturais do processo com a amplitude das especificações exigidas para o processo. Há vários tipos de índice de capacidade. Os cálculos dos índices de capacidade apresentados a seguir supõem que as variáveis provêm de uma distribuição Normal.

Existem duas medidas principais para calcular os índices de capacidade: o C_p , que avalia a capacidade potencial do processo, e o C_{pk} , que avalia a capacidade real ou atual do processo.

Segundo Ribeiro e Ten Caten (2011), o C_p é um índice usado com frequência para avaliação de características do tipo nominal-é-melhor é, e é dado por:

$$C_p = \frac{LES - LEI}{6\hat{\sigma}} ,$$

onde:

LES é o Limite de Especificação Superior, e

LEI é o Limite de Especificação Inferior.

O índice C_p avalia a capacidade potencial do processo, que pode ser atingida se o processo estiver centrado.

A capacidade real do processo para características do tipo nominal-é-melhor é estimada pelo índice C_{pk} que considera a média do processo e é dado por:

$$C_{pk} = \min \left\{ \frac{LES - \bar{\bar{x}}}{3\hat{\sigma}}, \frac{\bar{\bar{x}} - LEI}{3\hat{\sigma}} \right\}.$$

O índice C_{pk} é sempre menor ou igual ao índice C_p . O índice C_{pk} é menor do que o índice C_p quando o processo está descentrado e é igual ao C_p quando o processo está centrado.

A Tabela 8 apresenta a avaliação da capacidade, conforme o valor de C_{pk} , o percentual fora das especificações e a contemplação em termo de desvios padrões em relação à média. O processo é considerado capaz se $C_{pk} \geq 1$.

Avaliação	C_{pk} (capacidade real)	Contemplação (nível sigma)	% fora de especificação*
Muito incapaz	0,33	$\pm 1\sigma$	31,73%
Incapaz	0,66	$\pm 2\sigma$	4,55%
Capaz	1,00	$\pm 3\sigma$	0,27%
Muito capaz	1,33	$\pm 4\sigma$	0,0063%
Altamente capaz	1,67	$\pm 5\sigma$	0,000057%
Extremamente capaz	2,00	$\pm 6\sigma$	0,000000002%

Tabela 8. Escala para a avaliação da capacidade
(*) percentual considerado para processos centralizados.

A Figura 49 compara quatro processos hipotéticos que possuem as mesmas especificações, sendo dois capazes (acima) e dois não capazes (abaixo), e dois centralizados (esquerda) e dois não centralizados (direita).




Figura 49. Processo Capaz e Não Capaz
Fonte: Ribeiro e Ten Caten (2011)

A Figura 50 compara quatro processos hipotéticos, que possuem diferentes variabilidades, com seus limites de especificação e a respectiva avaliação da capacidade.




Figura 50. Processos Capazes e Não Capazes

Fonte: Ribeiro e Ten Caten (2012)

A Figura 51 apresenta três processos com diferentes capacidades e as possíveis causas que explicariam a falta de capacidade.




Figura 51. Capacidade de processos e causas

Fonte: Ribeiro e Ten Caten (2012)

A Figura 52 apresenta seis processos, sendo três processos centralizados (acima) e três não centralizados (abaixo), com três diferentes variabilidades e suas relações com os índices de capacidade.




Figura 52. Exemplos de processos capazes e não capazes
Fonte: Ribeiro e Ten Caten (2012)

Exemplo: Utilizando-se os dados do exemplo anterior, a Figura 53 apresenta os valores obtidos para os índices C_p e C_{pk} , considerando $LEI = 30$ e $LES = 90$. Observa-se que o processo não é capaz ($C_{pk} = \min\{0,67; 1,82\} = 0,67$), ou seja, não atende às especificações atribuídas. Entretanto, ele pode se tornar capaz ($C_p = 1,25$), se for centralizado. Esse é um processo que, com pouco investimento consegue-se torná-lo capaz, pois centrar o processo geralmente é uma tarefa fácil. Nesse caso, o alvo do processo seria o valor médio entre os limites de especificação, ou seja, 60.




Figura 53. Exemplo de Capacidade do Processo

Caso a características de qualidade for do tipo maior-é-melhor, o valor do limite de especificação superior é teoricamente infinito, logo a avaliação da capacidade do processo será realizada apenas com o C_{pk} inferior. Caso a característica for do tipo menor-é-melhor, o valor do limite de especificação inferior é teoricamente zero, logo a avaliação da capacidade do processo será realizada apenas com o C_{pk} superior.

O valor de C_{pk} pode auxiliar na decisão sobre onde concentrar os esforços de engenharia sendo que processos com menor C_{pk} devem ser priorizados nas ações de melhoria.

Uma informação importante pode ser obtida pela estimativa do percentual de peças produzidas dentro das especificações e do percentual de refugo e retrabalho, pois dessa forma tem-se uma estimativa dos custos associados à má qualidade. O cálculo do percentual de peças fora de especificação é estimado pela probabilidade associada ao valor da variável Z (distribuição normal padronizada), por meio dos seguintes cálculos:

$$z_s = \frac{LES - \bar{\bar{x}}}{\hat{\sigma}}$$

e

$$z_l = \frac{LEI - \bar{\bar{x}}}{\hat{\sigma}}$$

onde

z_s é o valor de Z associado ao LES, e

z_l é o valor de Z associado ao LEI.

Com base nos valores de calculados de z_s e z_l , pode-se obter os percentuais acima e abaixo dos limites de especificação, respectivamente, ao consultar as probabilidades na tabela da distribuição normal padronizada.

Exemplo: Utilizando-se os dados do exemplo anterior, obtém-se uma média igual a 73,8 e desvio-padrão igual a 8,0252. Considerando o *LEI*, o valor calculado de z é -5,45. Logo, $P(Z < -5,45) = 0,0000$, ou seja, o percentual de peças produzidas abaixo do *LEI* é praticamente zero. Considerando o *LES*, o valor calculado de z é 2,02. Logo, $P(Z > 2,02) = 0,0218$, ou seja, o percentual de peças produzidas acima do *LES* é de 2,18%. Esses percentuais também são apresentados na Figura 53. Consequentemente, o percentual de peças dentro das especificações é de 97,82%. Como 97,82% é menor que 99,73%, o processo não é capaz. Essa diferença (menor que 2%) pode parecer pouco, mas o processo está operando com uma quantidade 8 vezes maior de produtos não conforme do que deveria para ser considerado capaz. Pode-se verificar que, se o processo for centralizado, praticamente 100% das peças estarão dentro das especificações e, consequentemente, o processo será capaz.

Caso os dados não sigam a distribuição Normal, uma alternativa é utilizar uma transformação nos dados. Outra alternativa é calcular o percentual de peças fora de especificação usando os percentis da distribuição original dos valores individuais. Uma vez calculado o percentual de peças fora de especificação, deve-se identificar um valor de C_p que possua um percentual equivalente de peças fora de especificação. Dessa forma, pode-se ter o mesmo índice para avaliar a capacidade de todos os processos, o que permite compará-los e priorizar os esforços de melhoria naqueles que possuem o menor índice C_{pk} .

3.3.2. Gráfico de Controle para a Média e para o Desvio Padrão

Existem situações onde o monitoramento do desvio padrão (s) pode ser mais apropriado que o monitoramento da amplitude (R), além de ser um indicador mais eficiente da variabilidade. Ribeiro e Ten Caten (2011) e Montgomery (2017) recomendam o uso do gráfico de s quando: a) os dados forem coletados por computador e for fácil de implementar uma rotina de cálculo, b) os processos forem sofisticados, controlados por especialistas, c) as amostras forem grandes (subgrupos de tamanho $n > 10$) ou d) o tamanho da amostra for variável (vai depender se o software aceita e como ele trata). Tradicionalmente, o gráfico R tem sido preferido em relação ao gráfico s , devido à facilidade do cálculo de R e à dificuldade do cálculo de s para cada subgrupo. Entretanto, a integração de computadores nos processos de monitoramento tem eliminado essa dificuldade. Além disso, a utilização da amplitude para estimar o desvio padrão perde a eficiência estatística para tamanhos de amostras moderados ou grandes.

Para obter os LC para o gráfico de controle da média, procede-se da mesma forma vista na Seção 3.3.1, levando em consideração o IC de 99,73%, e o TLC. Dessa forma, obtém-se:

$$LC = \bar{\bar{x}} \pm 3 \frac{\sigma}{\sqrt{n}} = \bar{\bar{x}} \pm 3\sigma_{\bar{x}}.$$

Porém, diferentemente do que foi visto na Seção 3.3.1, a variabilidade do processo será obtida por meio do desvio padrão. O desvio padrão estimado (s_i) de cada subgrupo pode ser calculado por:

$$s_i = \sqrt{\frac{\sum_{j=1}^n (x_j - \bar{x})^2}{n-1}},$$

ou por:

$$s_i = \sqrt{\frac{\sum_{j=1}^n x_j^2 - (n\bar{x}^2)}{n-1}}.$$

Se os dados forem muito volumosos para serem colocados na planilha, os valores individuais serão registrados em uma folha separada, e na planilha do gráfico de controle irá aparecer apenas o valor calculado de $\bar{x}$ e s para cada subgrupo.

A média dos desvios padrões de cada amostra (subgrupo) é dada por:

$$\bar{s} = \frac{\sum_{i=1}^k s_i}{k},$$

onde:

k é a quantidade de subgrupos.

Segundo Montgomery (2004), o desvio padrão s não é um estimador não viciado para σ , já que a média (esperança) de s , ou seja, $\bar{s}$, não é igual a σ . A média de s , ($\bar{s}$) é dada por:

$$\bar{s} = c_4 \sigma,$$

onde:

c_4 é uma constante que depende do tamanho n da amostra.

Substituindo-se essa relação na expressão dos LC, tem-se:

$$LC = \bar{\bar{x}} \pm \frac{3\bar{s}}{c_4\sqrt{n}}.$$

Substituindo-se $A_3 = 3/(c_4\sqrt{n})$ na equação anterior, onde A_3 é uma constante (vide Anexo C), tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI) para a média:

$$LCS = \bar{\bar{x}} + A_3\bar{s}, \text{ e}$$

$$LCI = \bar{\bar{x}} - A_3\bar{s}.$$

Para obter os LC para o gráfico de controle do desvio padrão, considerando o IC de 99,73%, tem-se:

$$LC = \bar{s} \pm 3\sigma_s.$$

Segundo Montgomery (2004), o desvio padrão do desvio padrão s é dado por:

$$\sigma_s = \sigma\sqrt{1-c_4^2}.$$

Sabendo-se que $\bar{s} = c_4\sigma$, tem-se:

$$\sigma_s = \frac{\bar{s}}{c_4}\sqrt{1-c_4^2}.$$

Substituindo-se essa relação na expressão dos LC, tem-se:

$$LC = \bar{s} \pm 3\frac{\bar{s}}{c_4}\sqrt{1-c_4^2} = \bar{s}\left(1 \pm \frac{3}{c_4}\sqrt{1-c_4^2}\right).$$

Substituindo-se $B_4 = 1 + \frac{3}{c_4}\sqrt{1-c_4^2}$ e $B_3 = 1 - \frac{3}{c_4}\sqrt{1-c_4^2}$ na equação anterior,

onde B_4 e B_3 são constantes que dependem do tamanho da amostra (vide Anexo C), tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI) para a média:

$$LCS = B_4\bar{s}, \text{ e}$$

$$LCI = B_3\bar{s},$$

Resumo dos Limites de Controle

p/ Média	p/ Desvio Padrão
$LCS = \bar{\bar{x}} + A_3\bar{s}$ $LC = \bar{\bar{x}}$ $LCI = \bar{\bar{x}} - A_3\bar{s}$ $\bar{\bar{x}} = \frac{\sum_{i=1}^k \bar{x}_i}{k} = \frac{\bar{x}_1 + \bar{x}_2 + \dots + \bar{x}_k}{k}$ $\bar{x}_i = \frac{\sum_{j=1}^n x_j}{n}$	$LCS = B_4\bar{s}$ $LC = \bar{s}$ $LCI = B_3\bar{s}$ $\bar{s} = \frac{\sum_{i=1}^k s_i}{k} = \frac{s_1 + s_2 + \dots + s_k}{k}$ $s_i = \sqrt{\frac{\sum_{j=1}^n (x_j - \bar{x})^2}{n-1}}$

Exemplo: Utilizando os dados do exemplo anterior (apenas para fins didáticos, pois $n < 10$) e calculando-se os limites de controle para monitorar a média e o desvio padrão, obtém-se os gráficos da Figura 54.




Figura 54. Gráfico de Controle para Média do Exemplo 1

Conforme o gráfico para a média na Figura 54, observa-se um ponto fora de controle (amostra 16), acima do LCS, como já era esperado conforme visto no exemplo anterior. Por outro lado, o gráfico para o desvio padrão na Figura 55 não apresenta pontos fora de controle. Suponha que foi verificado na prática que realmente a amostra 16 foi afetada por uma causa especial, deve-se eliminar esse ponto da análise e refazer os gráficos, recalculando os LCs.




Figura 55. Gráfico de Controle para o Desvio Padrão do Exemplo 1

Após a eliminação da causa especial, os limites de controle foram recalculados e gráficos de controle foram refeitos. Conforme o gráfico para a média na Figura 56, observa-se que nenhum outro ponto fora de controle apareceu, com exceção daquele já existente (amostra 16). Salienta-se que os limites de controle foram recalculados sem considerar a amostra 16, no entanto, a observação histórica da amostra 16 não é eliminada no gráfico, pois, de fato, ela ocorreu. O gráfico para o desvio padrão na Figura 57 não apresenta nenhum ponto fora de controle.




Figura 56. Gráfico de Controle para a Média do Exemplo 1




Figura 57. Gráfico de Controle para o Desvio Padrão do Exemplo 1

Observa-se que agora esse processo é estável, já que nenhuma nova causa especial foi detectada. Como visto no capítulo anterior, quando o processo está estável (sem causas especiais), pode-se avaliar a capacidade do processo, que está associada com as causas comuns de variabilidade.

Exemplo: Utilizando-se os dados do exemplo anterior, a Figura 58 apresenta os valores obtidos para os índices C_p e C_{pk} , considerando $LEI = 30$ e $LES = 90$. Observa-se que o processo não é capaz ($C_{pk} = \min\{0,67;1,79\} = 0,67$), como já foi visto no exemplo anterior, ou seja, não atende às especificações atribuídas. Entretanto, ele pode se tornar capaz ($C_p = 1,25$), se for centralizado, o que já foi visto que geralmente é uma tarefa fácil. Nesse caso, o alvo do processo seria o valor médio entre os limites de especificação, ou seja, 60.




Figura 58. Exemplo de Capacidade do Processo

Exemplo: Utilizando-se os dados do exemplo anterior, obtém-se uma média igual a 73,8 e desvio-padrão igual a 8,0286. Considerando o LEI , o valor calculado de z é -5,45. Logo, $P(Z < -5,45) = 0,0000$, ou seja, o percentual de peças produzidas abaixo do LEI é praticamente zero. Considerando o LES , o valor calculado de z é 2,02. Logo, $P(Z > 2,02) = 0,0218$, ou seja, o percentual de peças produzidas acima do LES é de 2,18%. Esses percentuais (mesmos obtidos no exemplo anterior) também aparecem na Figura 58. Consequentemente, tem-se 97,82% das observações dentro das especificações. Como 97,82% é menor que 99,73%, o processo não é capaz. Essa diferença (menor que 2%) pode parecer pouco, mas o processo está operando com uma quantidade 8 vezes maior de produtos não conforme do que deveria para ser considerado capaz. Pode-se verificar que, se o processo for centralizado, praticamente 100% das peças estarão dentro das especificações e o processo será capaz.

3.3.3. Gráfico de Controle para Valores Individuais e Amplitude Móvel

Em algumas situações, o CEP deve ser aplicado para valores individuais. Ribeiro e Ten Caten (2011) e Montgomery (2017) recomendam gráfico para valores individuais quando:

- a) taxa de produção muito baixa ou lenta,
- b) testes muito caros, destrutivos ou que exijam a parada da produção,
- c) características muito homogêneas, que variam muito pouco,
- d) toda unidade fabricada é inspecionada (portanto, não faz sentido utilizar o gráfico para monitorar médias).

As cartas dos valores individuais não se beneficiam do TLC, logo Ribeiro e Ten Caten (2011) recomendam alguns cuidados com a sua aplicação:

- a) se a distribuição não for simétrica, a interpretação das cartas deve levar isso em conta,
- b) as cartas de valores individuais não são tão sensíveis a mudanças no processo como as cartas de médias,
- c) os pontos da carta da amplitude móvel são correlacionados, e essa correlação pode induzir um padrão ou ciclos na carta de amplitude, e
- d) as cartas de valores individuais não permitem avaliar diretamente a dispersão do processo. Para contornar isso, em geral, se usa uma amplitude móvel calculada como a diferença entre cada par de leituras sucessivas, onde, geralmente o tamanho de amostra é considerado $n = 2$.

Para obter os LC para os valores individuais, procede-se da mesma forma vista no início do Capítulo 3, levando-se em consideração o IC de 99,73%. Dessa forma, obtém-se:

$$LC = \bar{x} \pm 3\sigma,$$

onde

$\bar{x}$ é a média de todos os valores individuais.

Como a variabilidade dos valores individuais é estimada a partir da média das amplitudes dos subgrupos, utiliza-se a mesma relação vista na Seção 3.3.1:

$$\sigma = \frac{\bar{R}}{d_2},$$

onde

$\bar{R}$ é a média de todas as amplitudes móveis calculadas, e

d_2 é uma constante que depende do tamanho n da amplitude móvel (vide Anexo C).

Substituindo-se essa expressão na equação dos LC, tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI):

$$LCS = \bar{x} + 3\frac{\bar{R}}{d_2}, \text{ e}$$

$$LCI = \bar{x} - 3\frac{\bar{R}}{d_2}.$$

O Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI) para a amplitude móvel, como visto anteriormente, são dados, respectivamente, por:

$$LCS = D_4\bar{R}, \text{ e}$$

$$LCI = D_3\bar{R}.$$

Resumo dos Limites de Controle

p/ Valores Individuais	p/ Amplitude Móvel
$LCS = \bar{x} + 3\frac{\bar{R}}{d_2}$ $LC = \bar{x}$ $LCI = \bar{x} - 3\frac{\bar{R}}{d_2}$ $\bar{x} = \frac{\sum_{i=1}^k x_i}{k}$	$LCS = D_4\bar{R}$ $LC = \bar{R}$ $LCI = D_3\bar{R}$ $\bar{R} = \frac{\sum_{i=1}^{k-n+1} R_i}{k-n+1}$ $R_i = x_i - x_{i+n-1} $

Exemplo: Os dados abaixo representam medidas diárias de viscosidade de bateladas químicas durante um período de 30 dias. (Fonte: Ribeiro e Ten Caten, 2011):

6	6,5	6	5	6,2	4,5	6	5,4	5	6,5
6,1	5,6	5,5	4,5	4,2	4,7	7,8	4,5	6	7
6	6	5,5	6,5	6	6,5	5	6,5	6	6,5

Utilizando-se uma amplitude móvel com $n = 2$, foram calculados os LC. A Figura 59 apresenta-o gráfico para os valores individuais sem causas especiais e o gráfico de amplitude móvel com uma causa especial. No entanto, como o gráfico principal (valores individuais) não apresentou causas especiais, deve-se ser verificada essa situação na prática. Nesse caso, não se encontrou motivo para a causa especial, mas ela pode ter ocorrido porque o gráfico de amplitude móvel é autocorrelacionado, sendo considerada, assim, como um alarme falso. Como pode ser observado, no gráfico da amplitude, os pontos são correlacionados, devido à forma com que se realiza o cálculo da amplitude entre amostras.




Figura 59. Exemplo de gráfico para valores individuais e para a amplitude

Observa-se que agora esse processo é estável, já que nenhuma nova causa especial foi detectada. Como visto no capítulo anterior, quando o processo está estável (sem causas especiais), pode-se avaliar a capacidade do processo, que está associada com as causas comuns de variabilidade.

Exemplo: Utilizando-se os dados do exemplo anterior, a Figura 60 apresenta os valores obtidos para os índices C_p e C_{pk} , considerando $LEI = 4$ e $LES = 8$ e valor alvo igual a 6, para uma variável do tipo nominal-é-melhor. Observa-se que o processo não é capaz ($C_{pk} = \min\{0,86; 0,69\} = 0,69$), e não será capaz ($C_p = 0,78$) mesmo se for centralizado, ou seja, não atende e não continuará atendendo às especificações atribuídas. Nesse caso, é necessário atuar na variabilidade do processo, o que não é tão trivial de implementar, pois requer investimento ou troca de sistema, etc.




Figura 60. Exemplo de Capacidade do Processo

Exemplo: Utilizando-se os dados do exemplo anterior, obtém-se uma média igual a 5,78 e desvio-padrão igual a 0,86. Considerando o LEI , o valor calculado de z é -2,07. Logo, $P(Z < -2,07) = 0,0192$, ou seja, o percentual produção abaixo do LEI é 1,92%. Considerando o LES , o valor calculado de z é 2,58. Logo, $P(Z > 2,58) = 0,0049$, ou seja, o percentual de produção acima do LES é de 0,49%. Esses percentuais também aparecem na Figura 60. Consequentemente, tem-se 2,42% das observações fora das especificações e 97,58% das observações dentro das especificações. Como 97,58% é menor que 99,73%, o processo não é capaz. Essa diferença (um pouco maior que 2%) pode parecer pouco, mas o processo está operando com uma quantidade 9 vezes maior de produtos não conforme do que deveria para ser considerado capaz. Pode-se verificar que, se o processo for centralizado, cerca de 98% da produção estará dentro das especificações e o processo continuará sendo não capaz.

3.4. Gráficos de Controle para Atributos

Dentro do contexto do CEP, atributos são características de qualidade que são obtidas por meio de uma contagem condicionada à uma comparação com um certo padrão (especificações) e por isso podem assumir apenas valores discretos (classificação como conforme ou não-conforme, ou uma certa contagem de defeitos).

São exemplos de atributo: existência de manchas ou risco, diferença na cor segundo a especificação, número de defeitos em um circuito elétrico, número de reclamações, número de reclamações por cliente, número de clientes reclamantes, percentual de clientes reclamantes. Ou seja, por resultarem de uma contagem, obrigatoriamente os atributos são as variáveis quantitativas discretas.

Há muitas aplicações para esse tipo de gráfico de controle, pois os atributos existem na maioria dos processos técnicos ou administrativos. Muitos costumam sumarizar os resultados utilizando dados do tipo atributo, por isso, muitas vezes, os dados históricos existentes já são do tipo atributo. Além disso, em geral os atributos não requerem muita especialização para a coleta dos dados. O monitoramento usando atributos pode ser uma etapa intermediária, anterior a monitorização de variáveis (RIBEIRO; TEN CATEN, 2012).

Os atributos podem ser divididos em não-conformes (produto defeituoso) e não-conformidades (defeitos em um produto). Existem quatro tipos de gráficos por atributos, bastante conhecidos e disponíveis em basicamente todos os softwares estatísticos que possuem as análises de CEP implementadas:

- Os não-conformes seguem uma distribuição de probabilidade Binomial e se referem à contagem do número ou da quantidade de unidades de produtos ou peças defeituosas ou clientes reclamantes, por exemplo, e podem ser monitoradas:
 - a proporção ou fração (p) ou
 - a contagem do número ou da quantidade (np).
- As não-conformidades seguem uma distribuição de probabilidade Poisson e se referem à contagem do número ou da quantidade de defeitos ou reclamações, por exemplo (uma unidade pode ter mais de um defeito ou um cliente pode ter mais de uma reclamação), e podem ser monitoradas:
 - a contagem do número ou da quantidade (c) ou
 - a contagem do número ou da quantidade por unidade (u).

Da mesma forma que ocorre nos gráficos de controle para variáveis, se houverem causas especiais (pontos fora de controle, tendências, mudança na média, etc.), elas deverão ser investigadas e solucionadas e os limites de controle deverão ser recalculados desconsiderando essas observações.

A frequência de amostragem deve ter intervalos constantes, por exemplo, 1 amostra por lote, 1 amostra por turno, 1 amostra a cada troca de setup, 1 amostra por dia, etc. Ao contrário dos gráficos de controle para variáveis, os gráficos de atributo para não-conformes exigem subgrupos de tamanho considerável (em geral, 50 a 200 unidades ou mais) para serem eficientes na detecção de alterações no processo. Diferentemente dos gráficos de controle para variáveis, não se costuma monitorar a variabilidade dos atributos, apenas a quantidade ou a proporção.

Nem sempre os gráficos p , np , c e u serão adequados para todas as situações. Se a variabilidade da proporção (ou do número) de amostra para amostra for maior do que poderia ser plausivelmente explicada pelo modelo de probabilidade Binomial (ou Poisson, se for o caso), então o analista deve determinar o modelo de probabilidade subjacente correto, e basear o gráfico de controle naquela distribuição.

3.4.1. Gráfico de Controle para a Proporção de Não-Conformes: Gráfico p

Os itens podem ter várias características da qualidade que são examinadas simultaneamente. Se o item não satisfaz o padrão em uma ou mais dessas características, é classificado como não-conforme. O Gráfico de Controle para a Proporção de Não-conformes (p) mede a fração de produtos defeituosos ou produtos não-conformes em uma amostra (subgrupo). Alguns especialistas recomendam $n\bar{p} > 5$ para que seja possível uma análise eficiente de padrões. O tamanho dos grupos (n) pode ser variável, mas é mais prático trabalhar com subgrupos de tamanho constante.

O procedimento para calcular os LC é o seguinte:

1) Para cada subgrupo i (amostra), anotam-se os seguintes valores:

n_i : número de itens inspecionados (tamanho da amostra)

d_i : número de itens defeituosos (não-conformes)

2) Para cada subgrupo i (amostra), calcula-se a proporção de não-conformes, dada por:

$$p_i = \frac{d_i}{n_i}.$$

3) Se as amostras tiverem tamanhos diferentes, a proporção média de não-conformes é calculada da seguinte forma:

$$\bar{p} = \frac{\sum_{i=1}^k d_i}{\sum_{i=1}^k n_i} = \frac{d_1 + d_2 + \dots + d_k}{n_1 + n_2 + \dots + n_k}.$$

onde:

d_i é o número de não-conformes no subgrupo i ,

n_i é o tamanho da amostra do subgrupo i , e

k é o número de subgrupos.

Se as amostras forem todas do mesmo tamanho, a proporção média de não-conformes pode ser calculada pela expressão apresentada acima ou pela média da proporção de não-conformes de cada amostra, ou seja:

$$\bar{p} = \frac{\sum_{i=1}^k p_i}{k}.$$

Esses cálculos devem ser feitos com um número grande de subgrupos, por exemplo, $k > 25$, e em uma situação de processo sob controle.

4) Segue-se a mesma lógica dos gráficos de controle para variáveis, ou seja, considerando um intervalo de confiança de 99,73% para a proporção, que implica num intervalo de três desvios padrões para cima e para baixo do valor médio. Se as amostras forem de tamanhos diferentes, os LCS e LCI são dados, respectivamente, por:

$$LCS = \bar{p} + 3\sigma_{p_i} \text{ e}$$

$$LCI = \bar{p} - 3\sigma_{p_i},$$

onde:

$$\sigma_{p_i} = \frac{\sqrt{\bar{p}(1-\bar{p})}}{\sqrt{n_i}},$$

já que a proporção (p) pode ser obtida da distribuição de probabilidades Binomial.

Se o tamanho da amostra é variável, isto implica que os LCS e LCI terão valores diferentes para cada amostra, ou seja, os LC não serão fixos.

Por outro lado, se as amostras forem do mesmo tamanho, ou se a diferença nos tamanhos de amostras for pequena ($< 25\%$), os LCS e LCI são dados respectivamente por:

$$LCS = \bar{p} + 3\sigma_{\bar{p}} \text{ e}$$

$$LCI = \bar{p} - 3\sigma_{\bar{p}},$$

onde:

$$\sigma_p = \frac{\sqrt{\bar{p}(1-\bar{p})}}{\sqrt{\bar{n}}},$$

onde:

$\bar{n}$ é a média do tamanho das amostras, ou seja:

$$\bar{n} = \frac{\sum_{i=1}^k n_i}{k} = \frac{n_1 + n_2 + \dots + n_k}{k}.$$

No entanto, hoje em dia, com os recursos computacionais disponíveis, não faz sentido utilizar limites fixos quando diferença nos tamanhos de amostras for pequena ($< 25\%$), o que pode resultar em pequenos erros que poderão resultar em falsos alarmes. Sendo assim, o procedimento dos cálculos para LC fixos é mais adequado quando o tamanho da amostra for constante, ou seja, $\bar{n} = n$.

Consequentemente os LCS e LCI terão os mesmos valores para cada amostra, ou seja, os LC serão fixos. Tanto num caso, como no outro, se o limite inferior resultar em um valor negativo, então ele deve ser fixado em zero, pois não existe contagem ou proporção negativa.

Como no caso dos gráficos para variáveis, se o processo está em controle estatístico, a probabilidade de um ponto fora dos limites de controle é muito pequena, de forma que, caso isso aconteça, deve-se assumir a presença de causas especiais. Para atributos, um ponto acima do LCS indica que o processo piorou, porém um ponto abaixo do LCI indica uma melhora no processo. Ambos devem ser investigados, pois são causas não naturais ao processo. Vale ressaltar que, antes de disparar a investigação, deve-se verificar se o ponto não foi mal plotado ou se não há um problema no sistema de medição (RIBEIRO; TEN CATEN, 2012).

Mesmo com todos os pontos dentro dos limites de controle, pode haver evidências de que o processo sofreu alteração. Ribeiro e Ten Caten (2011) recomendam verificar (para $n\bar{p} > 9$) se existe a presença de sete pontos em sequência (acima ou abaixo da linha central) ou sete pontos em sequência ascendente ou descendente. Corridas ascendentes ou corridas acima da média indicam que o desempenho do processo piorou, porém corridas descendentes ou corridas abaixo da média indicam que o processo melhorou.

Quando um resultado fora do controle é identificado, o processo deve ser estudado para determinar a causa. No caso de pontos acima do limite de controle superior, a causa deve ser corrigida e as ações devem ser tais que impeçam a sua recorrência. No caso de pontos abaixo do limite inferior, as causas devem ser padronizadas, pois representam uma melhora no processo. Para o estudo das causas especiais, as análises de Pareto e diagramas de causa e efeito, vistas no capítulo anterior, são recomendadas (RIBEIRO; TEN CATEN, 2012).

Se ações de melhoria estão sendo tomadas, o processo deve apresentar um desempenho mais consistente, com redução da proporção média de não-conformes.

Assim, periodicamente os limites de controle devem ser reavaliados e, sempre que houver evidência para tanto, estreitados. Esse enfoque dinâmico mantém as cartas de controle atualizadas e eficazes na tarefa de continuar revelando fontes de variabilidade (RIBEIRO; TEN CATEN, 2012).

Em geral, expressamos a fração não-conforme como um número decimal, embora o percentual não-conforme (que é simplesmente 100% vezes a fração não conforme) possa ser usado. Além disso, pode-se monitorar também a fração conforme, obtida por $1 - p_i$, resultando em um gráfico de controle do rendimento do processo, o qual pode ser mais intuitivo e entendível para as pessoas (MONTGOMERY, 2017). No entanto, os softwares não oferecem esse tipo de monitoramento.

Se a verdadeira fração não conforme (p) for conhecida ou for um valor-padrão especificado, então $\bar{p}$ será substituído por p no cálculo dos limites de controle. Se p está sendo estimado pela primeira vez, então os limites de controle calculados inicialmente são chamados de limites de controle “tentativos” (MONTGOMERY, 2017).

Uma vez que o processo esteja sob controle e o valor de p for definido, novas amostras são coletadas para dar continuidade ao monitoramento, porém p não será estimado até que sejam revistos (recalculados) os limites de controle.

Resumo dos Limites de Controle

Se n for variável $LCS = \bar{p} + 3\sigma_{p_i}$ $LC = \bar{p}$ $LCI = \bar{p} - 3\sigma_{p_i}$ onde $\sigma_{p_i} = \frac{\sqrt{\bar{p}(1-\bar{p})}}{\sqrt{n_i}}$ $\bar{p} = \frac{\sum_{i=1}^k d_i}{\sum_{i=1}^k n_i} = \frac{d_1 + d_2 + \dots + d_k}{n_1 + n_2 + \dots + n_k}$	Se n for constante (ou com diferenças pequenas) $LCS = \bar{p} + 3\sigma_{\bar{p}}$ $LC = \bar{p}$ $LCI = \bar{p} - 3\sigma_{\bar{p}}$ onde: $\sigma_p = \frac{\sqrt{\bar{p}(1-\bar{p})}}{\sqrt{\bar{n}}}, \text{ com } \bar{n} = \frac{\sum_{i=1}^k n_i}{k} = \frac{n_1 + n_2 + \dots + n_k}{k}$ $\bar{p} = \frac{\sum_{i=1}^k d_i}{\sum_{i=1}^k n_i} = \frac{d_1 + d_2 + \dots + d_k}{n_1 + n_2 + \dots + n_k} \text{ ou}$ $\bar{p} = \frac{\sum_{i=1}^k p_i}{k}, \text{ onde } p_i = \frac{d_i}{n_i}$
--	---

Exemplo: Os dados abaixo representam o número de embalagens defeituosas de 30 lotes onde cada lote tem 50 embalagens, cujo gráfico p está representado na Figura 61. (Fonte: Montgomery, 2017).

12	15	8	10	4	7	16	9	14	10
5	6	17	12	22	8	10	5	13	11
20	18	24	15	9	12	7	13	9	6

Observa-se esse processo não está sob controle, já que apresenta dois pontos fora dos limites de controle, acima do LCS, indicando duas amostras que registraram mais defeitos do que deveriam ter.




Figura 61. Exemplo de gráfico p – processo não está sob controle
Fonte: Montgomery (2017)

Constatou-se que as embalagens defeituosas da amostra 15 foram afetadas por uma nova matéria prima utilizada, o que pode ter causado desestabilidade no processo. Já os defeitos da amostra 23 foram causados por um operário inexperiente que teve que operar provisoriamente aquela máquina no momento da produção daquelas embalagens. Dessa forma, constatadas e tratadas as causas especiais, os limites de controle foram recalculados com os dados das outras 28 amostras e o gráfico de controle foi refeito, conforme mostra a Figura 62. Observa-se que apareceu outra amostra com valor acima do LCS (21). Mas como essa amostra não apresentou nenhum motivo anormal para ter esse valor, decidiu-se não tratá-la como causa especial (há uma probabilidade de 0,27% que isso ocorra), concluindo-se que o processo está sob controle.




Figura 62. Exemplo de gráfico p – processo sob controle
Fonte: Montgomery (2017)

Agora que o processo encontra-se sob controle, novas amostras podem ser coletadas e monitoradas, como observa-se na Figura 63. Note que foram feitos ajustes na máquina a partir da amostra 31 e apareceu uma sequência não aleatória (vários

pontos seguidos abaixo da média do processo), caracterizando ocorrência de causa especial. Considerando que o ajuste resultou numa melhoria, os limites de controle foram recalculados com as novas amostras (de 31 a 54), o que resultou em novos limites de controle, conforme mostra a Figura 64 (LIC passou a ser zero). Posteriormente, novas amostras foram coletadas (Figura 65) e o processo continuou sob controle.




Figura 63. Exemplo de gráfico p – processo sob controle com novas amostras
Fonte: Montgomery (2017)




Figura 64. Exemplo de gráfico p – processo sob controle com LC recalculados
Fonte: Montgomery (2017)




Figura 65. Exemplo de gráfico p – LC recalculados e novas amostras coletadas
Fonte: Montgomery (2017)

3.4.2. Gráfico de Controle para o Número de Não-Conformes: Gráfico np

O Gráfico de Controle para o Número de Não-conformes (np) segue a mesma lógica do gráfico p , mas, agora, ao invés da fração de não-conformes, monitora-se o número (quantidade) de não-conformes d_i . Dessa forma, o gráfico np é mais apropriado quando o número de não-conformes tem um maior significado do que a proporção, por exemplo, quando o tamanho das amostras for constante.

O procedimento para calcular os LC é o seguinte:

- 1) Para cada subgrupo (amostra), anotam-se o número de itens não-conformes d_i , que é a variável que será monitorada.
- 2) Calcula-se o número (quantidade) médio de não-conformes da seguinte forma:

$$n\bar{p} = \frac{\sum_{i=1}^k d_i}{k} = \frac{d_1 + d_2 + \dots + d_k}{k}.$$

onde:

d_i é o número de não-conformes no subgrupo i , e

k é o número de subgrupos.

Alternativamente, o número médio de não-conformes também pode ser obtido por meio das proporções de cada amostra. Se as amostras tiverem tamanhos diferentes, a proporção média de não-conformes é calculada da seguinte forma:

$$n\bar{p} = \bar{n} \frac{\sum_{i=1}^k d_i}{\sum_{i=1}^k n_i} = \frac{d_1 + d_2 + \dots + d_k}{n_1 + n_2 + \dots + n_k}.$$

onde:

d_i é o número de não-conformes no subgrupo i ,

n_i é o tamanho da amostra do subgrupo i ,

k é o número de subgrupos, e

$\bar{n}$ é a média do tamanho das amostras, ou seja:

$$\bar{n} = \frac{\sum_{i=1}^k n_i}{k} = \frac{n_1 + n_2 + \dots + n_k}{k}.$$

Se as amostras forem todas do mesmo tamanho, a proporção média de não-conformes pode ser calculada pela expressão apresentada acima ou pela média da proporção de não-conformes de cada amostra, ou seja:

$$n\bar{p} = n \frac{\sum_{i=1}^k p_i}{k}.$$

- 3) Segue-se a mesma lógica dos gráficos de controle para variáveis, ou seja, considerando um intervalo de confiança de 99,73% para o número de não-conformes, que implica num intervalo de três desvios padrões para cima e para baixo do valor médio. Se as amostras forem de tamanhos diferentes, os LCS e LCI são dados, respectivamente, por:

$$LCS = n\bar{p} + 3\sigma_{np_i}, \text{ e}$$

$$LCI = n\bar{p} - 3\sigma_{np_i},$$

onde:

$$\sigma_{np_i} = \sqrt{n_i \bar{p}(1 - \bar{p})},$$

já que o número de não-conformes (np) pode ser obtido a partir da distribuição de probabilidades Binomial.

Se o tamanho da amostra é variável, isto implica que os LCS e LCI terão valores diferentes para cada amostra, ou seja, os LC não serão fixos.

Por outro lado, se as amostras forem do mesmo tamanho (n), ou se a diferença nos tamanhos de amostras for pequena ($< 25\%$), os LCS e LCI são dados respectivamente por:

$$LCS = n\bar{p} + 3\sigma_{np}, \text{ e}$$

$$LCI = n\bar{p} - 3\sigma_{np},$$

onde:

$$\sigma_{np} = \sqrt{n\bar{p}(1 - \bar{p})}.$$

onde:

$\bar{n}$ é a média do tamanho das amostras, como já foi definido, ou $\bar{n} = n$, se o tamanho das amostra for constante.

Observa-se que esses limites de controle são os mesmos do gráfico p , porém multiplicados por n . Ou seja, equivale a monitorar a soma das proporções de cada subgrupo. O desvio padrão é calculado dessa forma, já que a quantidade (np) pode ser obtida da distribuição de probabilidades Binomial.

O gráfico np terá o mesmo comportamento do gráfico p , caso o tamanho da amostra seja constante. No caso em que as amostras não forem de tamanho constante, o comportamento do gráfico np será diferente do gráfico p , mas as interpretações serão as mesmas vistas anteriormente na Seção 3.4.1.

Resumo dos Limites de Controle

Se n for variável $LCS = n\bar{p} + 3\sigma_{np_i}$ $LC = n\bar{p}$ $LCI = n\bar{p} - 3\sigma_{np_i}$ onde $\sigma_{np_i} = \sqrt{n_i \bar{p}(1 - \bar{p})}, \text{ com}$ $n\bar{p} = \frac{\sum_{i=1}^k d_i}{k} = \frac{d_1 + d_2 + \dots + d_k}{k} \text{ ou}$ $n\bar{p} = \bar{n} \frac{\sum_{i=1}^k d_i}{\sum_{i=1}^k n_i} = \frac{d_1 + d_2 + \dots + d_k}{n_1 + n_2 + \dots + n_k},$ $\bar{n} = \frac{\sum_{i=1}^k n_i}{k} = \frac{n_1 + n_2 + \dots + n_k}{k}$	Se n for constante (ou com diferenças pequenas) $LCS = n\bar{p} + 3\sigma_{np}$ $LC = n\bar{p}$ $LCI = n\bar{p} - 3\sigma_{np}$ onde: $\sigma_{np} = \sqrt{n\bar{p}(1 - \bar{p})}, \text{ com}$ $\bar{n} = \frac{\sum_{i=1}^k n_i}{k} = \frac{n_1 + n_2 + \dots + n_k}{k} \text{ ou } \bar{n} = n$ $n\bar{p} = \frac{\sum_{i=1}^k d_i}{k} = \frac{d_1 + d_2 + \dots + d_k}{k} \text{ ou}$ $n\bar{p} = n \frac{\sum_{i=1}^k p_i}{k}, \text{ onde } p_i = \frac{d_i}{n_i}.$
--	--

Exemplo: Utilizando-se os dados do exemplo anterior (das embalagens), obtém-se o gráfico np , apresentado na Figura 66.




Figura 66. Exemplo de gráfico np – processo não está sob controle

Observa-se que os resultados são os mesmos do caso anterior (gráfico p). Dessa forma, constatadas e tratadas as causas especiais, e recalculando-se os limites de controle com os dados das outras 28 amostras, o gráfico de controle foi refeito, conforme mostra a Figura 67. Observa-se que apareceu o mesmo novo ponto fora de controle, que já foi visto no exemplo anterior que não era uma causa especial. Assim, o processo está sob controle e pode ser utilizado para monitorar novas observações, como aconteceu no exemplo anterior.




Figura 67. Exemplo de gráfico np – processo sob controle

3.4.3. Gráfico de Controle para o Número de Não-Conformidades: Gráfico c

O Gráfico de Controle para o Número de Não-conformidades (c) monitora o número de não-conformidades (defeitos) verificado em um grupo. O gráfico c é mais apropriado quando os defeitos estão dispersos em um meio contínuo (por exemplo, número de falhas por área de tecido, número de imperfeições por comprimento de pavimento) e quando um produto pode apresentar mais de um tipo de defeito.

Como o monitoramento é realizado considerando o número (quantidade) de defeitos, deve-se especificar o tamanho da amostra constante, ou seja, o mesmo número de unidades, ou o mesmo tamanho da área ou comprimento analisado a cada amostra. O procedimento para calcular os LC é o seguinte:

- 1) Anota-se o número de não-conformidades verificado em cada amostra.
- 2) Calcula-se o número médio de não-conformidades por:

$$\bar{c} = \frac{\sum_{i=1}^k c_i}{k} = \frac{c_1 + c_2 + \dots + c_k}{k}$$

onde:

c_i é o número de não-conformidades na amostra i , e

k é o número de subgrupos.

- 3) Segue-se a mesma lógica dos gráficos de controle para variáveis, ou seja, considerando um intervalo de confiança de 99,73% para a quantidade de defeitos, que implica num intervalo de três desvios padrões para cima e para baixo do valor médio. Assim, os LCS e LCI são dados respectivamente por:

$$LCS = \bar{c} + 3\sigma_c \text{ e}$$

$$LCI = \bar{c} - 3\sigma_c,$$

onde

$$\sigma_c = \sqrt{\bar{c}},$$

já que o número de não-conformidades (c) segue uma distribuição de probabilidades Poisson com média (e, consequentemente, variância) igual a $\bar{c}$.

Se o verdadeiro número de não conformidades (c) for conhecido ou for um valor-padrão especificado, então $\bar{c}$ será substituído por c no cálculo dos limites de controle. Se p está sendo estimado pela primeira vez, então os limites de controle calculados inicialmente são chamados de limites de controle “tentativos” (MONTGOMERY, 2017).

Resumo dos Limites de Controle

$LCS = \bar{c} + 3\sigma_c$ $LC = \bar{c}$ $LCI = \bar{c} - 3\sigma_c$	onde: $\sigma_c = \sqrt{\bar{c}}$ $\bar{c} = \frac{\sum_{i=1}^k c_i}{k} = \frac{c_1 + c_2 + \dots + c_k}{k}$
--	--

Exemplo: Os dados abaixo representam o número de não-conformidades (defeitos) em 26 amostras de 100 placas de circuito impresso, cujo gráfico c está representado na Figura 68 (Fonte: Montgomery, 2017).

21	24	16	12	15	5	28	20	31	25
20	24	16	19	10	17	13	22	18	39
30	24	16	19	17	15				




Figura 68. Exemplo de gráfico c – processo não está sob controle
Fonte: Montgomery (2017)

Observa-se esse processo não está sob controle, já que apresenta dois pontos fora dos limites de controle, um acima do LCS, indicando uma amostra que registrou mais defeitos do que deveria ter e outra que registrou menos. Constatou-se que a contagem dos defeitos da amostra 6 foi feita por um novo inspetor que não reconheceu vários tipos de não-conformidades que poderiam estar presentes. Já o excesso de defeitos da amostra 20 foi causado por um problema no controle da temperatura da máquina. Dessa forma, constatadas e tratadas as causas especiais, os limites de controle foram recalculados com os dados das outras 24 amostras e o gráfico de controle foi refeito, conforme mostra a Figura 69. Observa-se que o processo está sob controle.




Figura 69. Exemplo de gráfico c – processo sob controle

3.4.4. Gráfico de Controle para o Número de Não-Conformidades por Unidade: o Gráfico u

O Gráfico de Controle para o Número de Não-conformidades por Unidade (u) monitora o número de não-conformidades (defeitos) por unidade produzida. É similar ao gráfico c , exceto que o número de não-conformidade é expresso em relação a cada unidade. O gráfico u é útil quando a amostra contém mais de uma unidade (o valor de u tem um significado mais facilmente apreendido). O tamanho dos subgrupos (n) pode ser variável, mas é mais prático trabalhar com subgrupos de tamanho constante. O procedimento para calcular os LC é o seguinte:

- 1) Anota-se o número de não-conformidades (c_i) verificado em cada subgrupo i , ou seja, a quantidade total de defeitos em toda a amostra do subgrupo, considerando que cada unidade pode ter mais de um defeito.
- 2) Calcula-se o número médio de não-conformidades (u_i) por unidade em cada amostra, que é a variável que será monitorada, por:

$$u_i = \frac{c_i}{n_i},$$

- 3) Se as amostras tiverem tamanhos diferentes, o número médio de não-conformidades é calculado da seguinte forma:

$$\bar{u} = \frac{\sum_{i=1}^k c_i}{\sum_{i=1}^k n_i} = \frac{c_1 + c_2 + \dots + c_k}{n_1 + n_2 + \dots + n_k}$$

onde:

c_i é o número de não-conformidades na amostra i , e

n_i é o tamanho da amostra do subgrupo i , e

k é o número de subgrupos.

Se as amostras forem todas do mesmo tamanho, o número médio de não-conformidades pode ser calculado por essa expressão apresentada acima ou pela média do número médio de não-conformidades por unidade de cada amostra, ou seja:

$$\bar{u} = \frac{\sum_{i=1}^k u_i}{k}$$

- 4) Segue-se a mesma lógica dos gráficos de controle para variáveis, ou seja, considerando um intervalo de confiança de 99,73% para a proporção, que implica num intervalo de três desvios padrões para cima e para baixo do valor médio. Se as amostras forem de tamanhos diferentes, os LCS e LCI são dados, respectivamente, por:

$$LCS = \bar{u} + 3\sigma_{u_i} \text{ e}$$

$$LCI = \bar{u} - 3\sigma_{u_i},$$

onde:

$$\sigma_{u_i} = \sqrt{\frac{\bar{u}}{n_i}}.$$

Isto implica que os LCS e LCI terão valores diferentes para cada amostra, ou seja, os LC não serão fixos.

Por outro lado, se as amostras forem do mesmo tamanho ou, alguns autores consideram ainda que, se a diferença nos tamanhos de amostras for pequena (< 25%), os LCS e LCI são dados respectivamente por:

$$LCS = \bar{u} + 3\sigma_u \text{ e}$$

$$LCI = \bar{u} - 3\sigma_u,$$

onde

$$\sigma_u = \sqrt{\frac{\bar{u}}{\bar{n}}},$$

onde:

$\bar{n}$ é a média do tamanho das amostras (se n for constante, $\bar{n} = n$).

Consequentemente os LCS e LCI terão os mesmos valores para cada amostra, ou seja, os LC serão fixos. Tanto num caso, como no outro, se o limite inferior resultar em um valor negativo, então ele deve ser fixado em zero.

Observa-se que o gráfico u está relacionado com o gráfico c , ou seja, é decorrente do gráfico c . Esses limites de controle são os mesmos do gráfico c , porém divididos por n . O desvio padrão é calculado dessa forma, já que a quantidade (u) pode ser obtida da distribuição de probabilidades Poisson. O gráfico u será proporcional ao gráfico c (caso o tamanho da amostra seja constante), e as interpretações e a capacidade do processo são as mesmas vistas anteriormente na Seção 3.4.3.

Resumo dos Limites de Controle

Se n for variável $LCS = \bar{u} + 3\sigma_{u_i}$ $LC = \bar{u}$ $LCI = \bar{u} - 3\sigma_{u_i}$ onde: $\sigma_{u_i} = \sqrt{\frac{\bar{u}}{n_i}}$ $\bar{u} = \frac{\sum_{i=1}^k c_i}{\sum_{i=1}^k n_i} = \frac{c_1 + c_2 + \dots + c_k}{n_1 + n_2 + \dots + n_k}$ $u_i = \frac{c_i}{n_i}$	Se n for constante $LCS = \bar{u} + 3\sigma_u$ $LC = \bar{u}$ $LCI = \bar{u} - 3\sigma_u$ onde: $\sigma_u = \sqrt{\frac{\bar{u}}{\bar{n}}}, \text{ com } \bar{n} = n$ $\bar{u} = \frac{\sum_{i=1}^k c_i}{\sum_{i=1}^k n_i} = \frac{c_1 + c_2 + \dots + c_k}{n_1 + n_2 + \dots + n_k} \text{ ou}$ $\bar{u} = \frac{\sum_{i=1}^k u_i}{k}, \text{ com } u_i = \frac{c_i}{n_i}$
---	--

Exemplo (amostras com tamanho variável): Os dados abaixo representam o número de defeitos observados em sapatos (Fonte: Ribeiro e Ten Caten, 2011), cujo gráfico u está representado na Figura 70.

Lote	1	2	3	4	5	6	7	8	9	10
Tamanho das amostras n_i	10	10	10	12	12	10	10	12	8	8
nº de não conformidades	13	11	8	20	15	10	13	19	15	9




Figura 70. Exemplo de gráfico u com n variável– processo está sob controle
Fonte: adaptado de Ribeiro e Ten Caten (2011)

Observa-se que não há causas especiais, portanto o processo está sob controle.

Exemplo (amostras com tamanho fixo):: Os dados abaixo representam o número de não-conformidades em 20 amostras de 5 computadores, cujo gráfico u está representado na Figura 71 (Fonte: Montgomery, 2004).

10	12	8	14	10	16	11	7	10	15
9	5	7	11	12	6	8	10	7	5




Figura 71. Exemplo de gráfico u com n fixo – processo está sob controle
Fonte: adaptado de Montgomery (2004)

Observa-se que não há causas especiais, portanto o processo está sob controle.

4. A Função de Perda Quadrática

De acordo com Conforme Ribeiro e Ten Caten (2011), a abordagem tradicional de qualidade está fortemente vinculada com a idéia de atender às especificações. Sob esse enfoque, se um produto atende às especificações ele possui boa qualidade, caso contrário, ele é um produto defeituoso. Na abordagem de Taguchi, a qualidade, ou melhor a falta de qualidade, pode ser avaliada através da: “perda imposta por um produto à sociedade,” onde sociedade é um termo abrangente que inclui fabricante, consumidor e todo o restante da população. Assim, o objetivo é minimizar as perdas impostas a este conjunto. Segundo Ross (1991), essa perda é causada por um produto durante seu ciclo de vida, de tal forma que, um produto com qualidade superior causará perda mínima para sociedade no decorrer da sua utilização. Para Fiod Neto (1997), a produção de itens fora das especificações ocasiona elevação do custo, o que reflete no preço final do produto. Para Taguchi, qualquer variação nas dimensões da característica da qualidade, para um produto ou serviço, envolve um determinado custo adicional.

Conforme Ribeiro e Ten Caten (2011), as perdas devido à má qualidade podem ser de três tipos:

- 1) O fabricante perde: sucata, retrabalho, perda de fatia de mercado, etc.
- 2) O cliente perde: insatisfação em relação ao desempenho do produto, indisponibilidade do produto, perda de tempo.
- 3) Perdas mútuas (fabricante e cliente): gastos adicionais com reposição ou reparo do produto.

Na verdade, sempre que ocorre má qualidade, todos perdem; e, em todos os casos, a perda pode ser expressa em unidades monetárias. Ou seja, há um custo associado à má qualidade, e é importante considerar esse custo em todas as decisões gerenciais (RIBEIRO; TEN CATEN, 2011).

Na abordagem tradicional do CEP, considera-se todas as unidades fabricadas dentro dos limites de especificação como boas, e aquelas fabricadas fora dos limites como defeituosas. A abordagem proposta por Taguchi utiliza a função de perda quadrática (FPQ) para avaliar o processo (RIBEIRO; TEN CATEN, 2011). A Figura 72 apresenta a comparação entre a estimativa de perdas usando a abordagem tradicional e usando a função de perda quadrática de Taguchi em características de qualidade do tipo nominal-é-melhor.




Figura 72. Comparação entre a abordagem tradicional (esquerda) e a FPQ (direita).

Fonte: ESSS¹

¹ <https://www.esss.co/blog/conheca-as-duas-ferramentas-mais-eficazes-para-reduzir-custos-com-garantia/>

4.1. A Função de Perda Quadrática para Características da Qualidade do Tipo Nominal-é-Melhor

A função de perda quadrática é empregada para quantificar a perda que um produto impõe à sociedade pela falta de qualidade. Em muitos casos, essa perda resulta aproximadamente proporcional ao quadrado do desvio da meta estabelecida para uma certa característica de qualidade tipo nominal-é-melhor (Figura 73), ou seja:

$$L(y_i) = k(y_i - m)^2,$$

onde:

$L(y_i)$ é a perda financeira, associada ao desvio da meta, para a unidade i ;

y_i é o valor medido na unidade i para a característica de qualidade em estudo;

m é a meta para a respectiva característica de qualidade; e

k é o coeficiente de perda da qualidade, que converte o desvio do alvo em unidade financeira.

Para se determinar o valor de k , basta que se conheça a perda associada a um certo valor da característica de qualidade y . É comum usar o custo de reparo ou substituição para determinar o valor de k :

$$k = A_0 / \Delta^2,$$

onde:

A_0 é o custo de reparo ou substituição do produto;

Δ é o desvio da meta que exigiria reparo ou substituição.




Figura 73. FPQ para característica tipo nominal-é-melhor.

Fonte: Ribeiro e Ten Caten (2012)

Na concepção clássica, os procedimentos de melhoria terminam quando se atinge a condição de produzir todas as unidades dentro das especificações. Na concepção de Taguchi, os procedimentos de melhoria irão continuar até que se atinja a perfeição, ou seja, processo exatamente centrado e com variabilidade zero. O uso da função de perda implica uma filosofia de melhoria contínua da qualidade (RIBEIRO; TEN CATEN, 2011).

A perda média por unidade para um lote de n produtos é dada por:

$$L = \frac{1}{n} \sum_{i=1}^n k(y_i - m)^2.$$

Essa perda média pode ser calculada em termos de média e desvio padrão do lote. Desenvolvendo o termo quadrático dessa expressão, obtém-se:

$$L = k \left\{ \frac{\sum_{i=1}^n y_i^2}{n} - \frac{2m \sum_{i=1}^n y_i}{n} + \frac{\sum_{i=1}^n m^2}{n} \right\}.$$

Adicionando e subtraindo um termo quadrático e organizando os termos da equação, obtém-se:

$$L = k \left\{ \left(\frac{\sum_{i=1}^n y_i}{n} \right)^2 - \frac{2m \sum_{i=1}^n y_i}{n} + \frac{\sum_{i=1}^n m^2}{n} + \frac{\sum_{i=1}^n y_i^2}{n} - \left(\frac{\sum_{i=1}^n y_i}{n} \right)^2 \right\}.$$

Como os primeiros três somatórios referem-se ao desvio da meta e os dois últimos referem-se à variabilidade, as expressões podem ser simplificadas, obtendo-se perda média por unidade:

$$L = k \{ (\bar{y} - m)^2 + s^2 \}.$$

Ou seja, conhecidos k e m (coeficiente de perda e meta), basta computar a média ($\bar{y}$) e a variância (s^2) de um lote de tamanho n para estimar a perda média por unidade. Observa-se que há duas parcelas que contribuem para a perda de qualidade: o desvio da meta ($\bar{y} - m$) e a variabilidade ou falta de homogeneidade (s).

Ribeiro e Ten Caten (2011) firmam que, em geral, na prática, é muito mais fácil corrigir desvios da meta do que dispersão.

A natureza dos problemas de qualidade pode ser identificada pela estatística:

$$Q = \frac{(\bar{y} - m)}{s}.$$

Se Q for maior que 1 ou menor que -1, a perda devido ao desvio da meta é preponderante e, provavelmente, será possível efetuar uma melhora significativa no processo com facilidade. Se Q for próximo de zero, o processo já está centrado e os problemas de qualidade são basicamente devidos à dispersão. Na prática, esse caso é mais difícil de resolver pois, em geral, irá exigir ação sobre as causas comuns. Para calcular a parcela da perda que está associada com o desvio da meta, utiliza-se:

$$\frac{(\bar{y} - m)^2}{(\bar{y} - m)^2 + s^2}, \text{ e}$$

para calcular a parcela da perda que está associada com a variabilidade, utiliza-se

$$\frac{s^2}{(\bar{y} - m)^2 + s^2}.$$

Resumo das fórmulas

$k = A_0 / \Delta^2$ $L(y_i) = k(y_i - m)^2$ $L = \frac{1}{n} \sum_{i=1}^n k(y_i - m)^2$ ou $L = k \{ (\bar{y} - m)^2 + s^2 \}$	$Q = \frac{(\bar{y} - m)}{s}$ $\frac{(\bar{y} - m)^2}{(\bar{y} - m)^2 + s^2}$ e $\frac{s^2}{(\bar{y} - m)^2 + s^2}$
---	--

² A variância (s^2) do lote é calculada pela fórmula populacional (σ^2), ou seja, usando o denominador n .

4.2. A Função de Perda Quadrática para Características da Qualidade do Tipo Maior-é-Melhor

Em características de qualidade do tipo maior-é-melhor (Figura 74), a função de perda quadrática é dada por:

$$L(y_i) = \frac{k}{y_i^2}.$$

Observa-se que a perda diminui à medida que y_i aumenta. Se a perda é conhecida para um ponto qualquer y_0 , podemos determinar o valor de k :

$$k = L(y_0)y_0^2.$$

O ponto y_0 pode ser determinado como o ponto onde o produto irá exigir reparo ou substituição a um custo A_0 , ou seja, Δ . Assim, k pode ser calculado por:

$$k = A_0\Delta^2.$$




Figura 74. Exemplo de FPQ para característica do tipo maior-é-melhor.
Fonte: Ribeiro e Ten Caten (2012)

No caso de um lote com muitas unidades do mesmo produto, a perda média unitária para o esse lote é dada por:

$$L = \frac{1}{n} \sum_{i=1}^n k \left(\frac{1}{y_i^2} \right).$$

Desenvolvendo-se essa expressão, chega-se a:

$$L = k \left(\frac{1}{\bar{y}^2} \right) \left(1 + \frac{3s^2}{\bar{y}^2} \right).$$

Resumo das fórmulas

$L(y_i) = \frac{k}{y_i^2}$ $k = L(y_0)y_0^2 \quad \text{ou} \quad k = A_0\Delta^2$	$L = \frac{1}{n} \sum_{i=1}^n k \left(\frac{1}{y_i^2} \right)$	$L = k \left(\frac{1}{\bar{y}^2} \right) \left(1 + \frac{3s^2}{\bar{y}^2} \right)$
--	---	--

4.3. A Função de Perda Quadrática para Características da Qualidade do Tipo Menor-é-Melhor

Em características de qualidade do tipo menor-é-melhor (Figura 75), a função de perda quadrática é dada por:

$$L(y_i) = k \cdot y_i^2.$$

Observa-se que a perda diminui a medida que y_i diminui. Se a perda é conhecida para um ponto qualquer y_0 , podemos determinar o valor de k :

$$k = \frac{L(y_0)}{y_0^2}.$$

O ponto y_0 pode ser determinado como o ponto onde o produto irá exigir reparo ou substituição a um custo A_0 , ou seja, Δ . Assim, k pode ser calculado por:

$$k = \frac{A_0}{\Delta^2}.$$




Figura 75. Exemplo de FPQ para característica do tipo menor-é-melhor.
Fonte: Ribeiro e Ten Caten (2012)

No caso de um lote com muitas unidades do mesmo produto, a perda média unitária para o esse lote é dada por:

$$L = \frac{1}{n} \sum_{i=1}^n k \cdot y_i^2.$$

Desenvolvendo-se essa expressão, chega-se a:

$$L = k(\bar{y}^2 + s^2).$$

Resumo das fórmulas

$L(y_i) = k \cdot y_i^2$ $k = \frac{L(y_0)}{y_0^2} \quad \text{ou} \quad k = \frac{A_0}{\Delta^2}$	$L = \frac{1}{n} \sum_{i=1}^n k \cdot y_i^2$ $L = k(\bar{y}^2 + s^2)$
--	---

4.4. Utilidade da Função de Perda Quadrática

Conforme Ribeiro e Ten Caten (2012), a função de perda pode ser usada para monitorar melhorias no processo.

- É um índice mais consistente do que os índices usuais de capacidade, ou seja, C_p e C_{pk} . Isso porque a função de perda considera tanto a perda devido à dispersão como a perda devido a desvios da meta. Os índices usuais de capacidade não consideram diretamente o desvio da meta. De forma que é possível ter processos bastante descentrados e ainda assim com um índice de capacidade alto.
- Muitas vezes é difícil computar o verdadeiro valor de k , mas para efeitos comparativos (monitoramento, avaliação de melhorias) pode-se usar $k = 1$ nas situações a serem comparadas, pois considera o mesmo custo e as mesmas especificações.
- Uma redução de 10% no valor de L , por exemplo, implica uma redução de 10% nos custos da má qualidade, mesmo que não se conheça com exatidão esse valor.
- Também é possível usar a função de perda para comparar processos distintos, mesmo sem conhecer o valor exato de k . Nesse caso, atribui-se que o custo do processo para unidades que estejam sobre o limite de especificação seja $A_0 = 1$ nas situações a serem comparadas, e calcula-se o valor de k em cada caso, pois as especificações dos processos são diferentes.
- A função de perda também serve para auxiliar na definição das tolerâncias da produção, que podem ser diferentes das tolerâncias do cliente.

5. Análise de Sistemas de Medição

Um sistema de medição é um sistema capaz de medir, localizar ou contar coisas ou eventos. Para que as análises relativas ao desempenho do processo sejam válidas, é essencial que o sistema de medição seja adequado. Esse capítulo está baseado na obra de Ribeiro e Ten Caten (2011).

É importante entender qual a precisão associada ao sistema de medição, a qual está relacionada com o próprio instrumento de medição e também com outras fontes de variação. Ao especificar ou analisar um sistema de medição, nós estamos preocupados com a sua discriminação, ou seja, com a sua capacidade de detectar mesmo pequenas mudanças na característica em estudo. A Figura 76 fornece indicações sobre a aplicabilidade de um sistema de medição, em função do número de categorias que ele pode discriminar.




Discriminação	Observações
 1 Categoria	Só pode ser usado para controle em condições especiais, por exemplo, no caso de um processo muito capaz, com função de perda achatada no intervalo das especificações. Não pode ser usado para estimar parâmetros e índices do processo.
 ~ 3 categorias	Pode ser usado no controle de características que não são críticas e onde o processo tem boa capacidade. Fornecer apenas estimativas grosseiras dos parâmetros e índices do processo.
 + de 5 categorias	Pode ser usado no controle de características críticas. Fornecer estimativas precisas dos parâmetros e índices do processo.

Figura 76. Indicações sobre a aplicabilidade de um sistema de medição

Fonte: Ribeiro e Ten Caten (2011)

Os sistemas de medição podem ser analisados quanto:


- Estabilidade;
- Tendência;
- Linearidade;
- Repetitividade;
- Reprodutibilidade.

5.1. Estabilidade

A estabilidade de um sistema de medição refere-se ao seu desempenho ao longo do tempo. Em geral, a estabilidade não é quantificada, mas ela pode ser avaliada

usando-se gráficos de controle. Por exemplo, uma mesma peça é medida ao longo do tempo e os resultados são plotados em um gráfico de controle. Como trata-se da mesma peça, as leituras deveriam ser sempre as mesmas, mas isso não acontece, devido à variabilidade no próprio sistema de medição (vide Figura 77). Se houver problemas no sistema de medição, isso irá aparecer como um ponto fora dos limites de controle, o que revela falta de estabilidade no sistema de medição.

Boa
estabilidade



Problemas de
estabilidade




Figura 77. Exemplo de estabilidade no sistema de medição

Fonte: Ribeiro e Ten Caten (2011)

Se a estabilidade for ruim, existem várias causas possíveis, por exemplo:

- Existem fatores que atuam ao longo do dia (temperatura) ou ao longo da semana (umidade), que influenciam significativamente o instrumento de medição, causando descalibragem ou afrouxamento;
- Instrumento de medição perde a calibragem com facilidade;
- Os operadores não estão suficientemente treinados no uso do instrumento;
- Os operadores estão expostos a fadiga que prejudica a leitura;

5.2. Tendência

A tendência é definida como a diferença entre a média observada e o valor de referência. A média observada é a média de um conjunto de leituras (por exemplo, 10 observações) feitas pelo conjunto dispositivo / operador que queremos avaliar. O valor de referência é o valor suposto correto, obtido no laboratório de metrologia.

A tendência, e outras medidas que vão aparecer na sequência, podem ser expressas em termos percentuais, onde a base de comparação é a variação total do processo (em geral usa-se 5,15 sigma associado a 99% de variação) ou a tolerância (amplitude do intervalo de especificação)

O estudo de tendência também pode ser feito usando os dados do estudo de estabilidade. Nesse caso, a tendência é dada pela diferença entre a média das médias amostrais e o valor pontual de referência.

Se a tendência é relativamente grande, as causas podem ser as seguintes:

- Dispositivo de medição mal calibrado;
- Dispositivo de medição desgastado, exigindo manutenção;
- Falta de treinamento ou conhecimento no uso do dispositivo de medição;
- Valor de referência mal definido;

5.3. Linearidade

O estudo da linearidade do dispositivo de medição verifica o desempenho do dispositivo ao longo de toda a sua faixa de uso. Muitas vezes o dispositivo é usado em uma faixa ampla, e o fato dele estar calibrado e funcionando adequadamente em um extremo da faixa, não assegura seu funcionamento adequado no centro ou no outro extremo da faixa.

Para fazer um estudo de linearidade, é preciso utilizar várias peças cujos valores de referência contemplem a faixa de uso do dispositivo. Primeiro verifica-se o valor de referência de cada peça de acordo com um equipamento devidamente calibrado. Então, se efetuam medições sobre cada peça e registra-se a tendência observada, verificando, através de um estudo de regressão, se a tendência é função do valor de referência. A Figura 78 apresenta a linearidade de dois sistemas de medição.




Figura 78. Exemplo de linearidade
Fonte: Ribeiro e Ten Caten (2011)

5.4. Repetitividade

A repetitividade (VE) ou variação do dispositivo de medição é observada quando um mesmo operador mede a mesma peça mais de uma vez. Para que não haja influência sobre a medição, os operadores não devem saber que estão medindo a mesma peça. A Repetitividade, com um intervalo que abrange 99% da variação esperada para uma distribuição normal é obtida por:

$$VE = 5,15\sigma_e,$$

onde

σ_e é o desvio-padrão do dispositivo de medição, dado por:

$$\sigma_e = \frac{\bar{R}}{d_2},$$

onde

$\bar{R}$ é a amplitude média observada nas diversas medições efetuadas pelos operadores,

d_2 é uma constante tabelada obtida na Tabela 11 (vide Anexo D), sendo m o número de medições por peça por operador e g o número de peças vezes o número de operadores.

5.5. Reprodutibilidade

A reprodutibilidade (VO) ou variação do operador refere-se a diferenças que podem existir entre as medidas de diferentes operadores, em geral resultado de procedimentos específicos adotados por cada operador.

Como a reprodutibilidade está contaminada pela variação devido ao dispositivo de medição, ela deve ser ajustada subtraindo-se uma fração que corresponde à repetitividade. Dessa forma, a reprodutibilidade, com um intervalo que abrange 99% da variação esperada para uma distribuição normal é dada por:

$$VO = \sqrt{(5,15\sigma_o)^2 - \frac{(5,15\sigma_e)^2}{nr}},$$

onde:

n = número de peças,

r = número de ciclos de medição e

σ_o é o desvio padrão dos operadores, dado por:

$$\sigma_o = \frac{R_o}{d_2},$$

onde:

R_o é a diferença entre as médias dos operadores (a maior menos a menor).

Como foi visto, a reprodutibilidade está contaminada pela variação devido ao dispositivo de medição, dessa forma, o desvio-padrão ajustado dos operadores é:

$$\sigma_{o_{ajustado}} = \frac{VO}{5,15}$$

5.6. R&R

Conhecida a variabilidade devido a repetitividade (equipamento) e a reprodutibilidade (operadores), a variabilidade do sistema de medição (R&R) é dada por:

$$R \& R = \sqrt{VE^2 + VO^2}.$$

Em termos de desvio padrão, tem-se:

$$\sigma_m = \sqrt{\sigma_e^2 + \sigma_o^2}.$$

Exemplo: Calcule a variabilidade do sistema de medição dos seguintes dados referentes à medição de 5 peças realizada por dois operadores.

Peças \ Repetições	Operador 1			Operador 2		
	1	2	3	1	2	3
1	25,2	27,1	25,6	25,4	26,7	24,7
2	22,1	21,6	24,1	23,3	23,8	24,0
3	25,4	24,7	25,0	24,4	25,0	26,9
4	23,6	25,2	25,2	25,1	23,5	26,8
5	28,2	27,1	26,0	27,3	27,8	29,7

Respostas: $VE = 5,93$, $VO = 1,32$, $R\&R = 6,08$ e $\sigma_m = 1,18$.

5.7. Variação Peça-a-Peça

A variação total da peça (VP), com um intervalo que abrange 99% da variação esperada para uma distribuição normal é estimada por:

$$VP = 5,15\sigma_p,$$

onde:

σ_p é o desvio-padrão das peças (variabilidade entre peças) que pode ser determinado através de um estudo independente de capacidade do processo ou pode ser obtido a partir dos dados do estudo do sistema de medição, por:

$$\sigma_p = \frac{R_p}{d_2},$$

onde:

R_p é a amplitude das médias, ou seja, a diferença entre a peça com a maior média e a peça com a menor média, e

d_2 é uma constante (vide Anexo D) obtida usando m = número de peças e $g = 1$.

5.8. Variação Total do Processo

A variabilidade total do processo (VT) é calculada somando-se a variabilidade do sistema de medição com a variabilidade das peças:

$$VT = \sqrt{R\&R^2 + VP^2}.$$

Em termos de desvio padrão, tem-se:

$$\sigma_t = \sqrt{\sigma_m^2 + \sigma_p^2}.$$

Exemplo: Utilizando os dados do exemplo anterior, obtenha a variação peça-a-peça e a variação total do processo. Respostas: $VP = 9,40$ e $VT = 11,19$, $\sigma_t = 2,18$.

5.9. Avaliação do Sistema de Medição

O sistema de medição é avaliado em termos percentuais. Existem duas formas de fazer essa avaliação, em relação à VT ou em relação à tolerância. Em relação à VT, quantifica-se o percentual da VT do processo que é devida ao sistema de medição, ou seja:

$$R \& R\% = 100 \frac{R \& R}{VT}.$$

Em relação à tolerância, que determina o intervalo das especificações, calcula-se qual a parte é devida ao sistema de medição, ou seja:

$$R\&R\% = 100 \times R\&R / \text{Tolerância}$$

Quando esse percentual é baixo, digamos inferior a 20%, o sistema de medição tem bom poder discriminatório, ou seja, discrimina entre peças boas e ruins.

O número de níveis distintos (N_c de categorias do produto) que pode ser identificado com clareza é determinado usando:

$$N_c = 1,41 \frac{\sigma_p}{\sigma_m}.$$

Se N_c é menor que dois, o sistema de medição não tem utilidade para o controle do processo, não se consegue distinguir uma peça da outra, tudo pode ser erro de medição. Se N_c é igual a dois ou três, os dados podem ser classificados em duas categorias (alto/baixo, centrado/fora do centro). Nesse caso, o que se tem é apenas uma avaliação qualitativa, tipo atributo (bom ou ruim, dentro ou fora). N_c deve ser maior que cinco para que o sistema de medição seja aceitável (efetivo) no controle do processo, capaz de identificar várias categorias.

A contribuição percentual da repetitividade e da reprodutividade são dadas respectivamente por:

$$VE\% = 100 \frac{VE}{VT} \text{ e}$$

$$VO\% = 100 \frac{VO}{VT}.$$

A contribuição percentual referente à variação peça-a-peça é dada por:

$$VP\% = 100 \frac{VP}{VT}.$$

As parcelas de contribuição percentual da repetitividade e da reprodutividade e da variação peça-a-peça também podem ser calculadas em relação à tolerância.

Exemplo: Avalie o sistema de medição do exemplo anterior, supondo que intervalo das especificações tenha amplitude igual a 20.

Respostas: $R\&R\% = 54,33\%$ ou $30,40\%$, $N_c = 2,19$, $VE\% = 53,0\%$, $VO\% = 11,8\%$, $VP\% = 84,0\%$ O sistema de medição do exemplo consegue classificar as peças em duas categorias (boas e ruins) mas essa classificação não é boa (erros na classificação), pois o sistema tem baixo poder discriminatório.

5.10. Métodos de Estudos de R&R

Nessa seção serão apresentados os três métodos que podem ser usados para um estudo de R&R. Esses métodos são os seguintes:

- O Método da amplitude
- O Método da média e amplitude
- O Método da ANOVA

O primeiro método tem uma coleta de dados simplificada; os outros dois métodos seguem basicamente o mesmo procedimento de coleta de dados, o que muda é o formulário de análise.

5.10.1. O Método da amplitude

O método da amplitude fornece uma primeira avaliação do sistema de medição, sem chegar a decompor a variabilidade em R&R. Usualmente, esse método é empregado usando-se dois operadores e 5 a 10 peças, sendo que cada operador realiza uma única medida sobre cada peça. O valor de R&R é dado por:

$$R \& R = 5,15\sigma_m,$$

onde

$$\sigma_m = \frac{\bar{R}}{d_2},$$

onde:

d_2 é uma constante (vide Anexo D) obtida usando m = número de operadores e g = número de peças.

É usual considerar o seguinte:

Se $R\&R\% < 10\% \implies$ sistema é aceito

Se $10 < R\&R\% < 30\% \implies$ sistema pode ser aceito

Se $R\&R\% > 30\% \implies$ sistema é rejeitado

Nesse método a amplitude R registrada contém tanto o erro do instrumento + operador (repetitividade) como o erro entre operadores (reprodutibilidade). Nesse estudo rápido não se pode distinguir entre essas fontes de variabilidade.

Exemplo: Dois operadores medem as mesmas 5 peças cada um, uma única vez. As medições, para cada peça, foram as seguintes:

Operador A: 2,12; 2,15; 2,08; 2,10 e 2,10.

Operador B: 2,16; 2,17; 2,08; 2,12 e 2,11.

Avaliar o sistema de medição pelo método da amplitude.

Respostas: $R\&R = 38,9\%$ (o sistema não é bom)

5.10.2. O Método da média e amplitude

O método da média e amplitude permite distinguir entre as duas fontes de variação (Repetitividade e Reprodutibilidade), quantificando a contribuição de cada uma delas para a variabilidade total. Para que isso possa ser feito, cada operador deve executar mais de uma medição sobre a mesma peça (em geral duas ou três medições).

É importante investigar a causa da variabilidade, pois isso irá orientar a respeito das medidas a serem tomadas para a melhoria do sistema de medição. Por exemplo, se a repetitividade for ruim, talvez seja necessário um treinamento geral dos operadores, ou a aquisição de instrumentos mais precisos, de leitura mais fácil. Por outro lado, se a reprodutibilidade for ruim, talvez seja necessário padronizar os procedimentos de medição ou fornecer treinamento específico a alguns dos operadores.

Esse método já foi apresentado e utiliza os mesmos cálculos vistos entre as Seções 5.4 e 5.9. As fórmulas utilizadas para esse método encontra-se no Anexo E.

Exemplo: Analise o sistema de medição pelo método da média e amplitude dos seguintes dados referentes à medição de 10 peças realizada por dois operadores, com duas repetições de medição para cada peça.

Peça	Operador A		Operador B		Operador C		Ti..
	1	2	1	2	1	2	
1	50	50	51	49	47	47	
2	52	51	54	52	48	45	
3	47	48	47	49	46	47	
4	46	46	48	47	46	44	
5	47	49	50	47	44	45	
6	50	50	49	48	47	48	
7	45	47	46	47	46	45	
8	46	45	47	46	45	44	
9	54	54	53	55	52	52	
10	46	48	47	47	47	45	
T.j.							

Respostas: VE = 5,48, VO = 6,49, VP = 12,68, R&R = 8,49 e VT = 15,26.

5.10.3. O Método da ANOVA

A análise de variância (ANOVA) é uma técnica estatística que pode ser usada para o estudo da variabilidade de um sistema de medição. Usando a ANOVA, a variabilidade pode ser decomposta em quatro fontes: peças, operadores, interação entre peças x operadores e erro de replicação devido ao dispositivo de medição. Essa é uma ANOVA de dois fatores (peças e operadores).

As vantagens da ANOVA são que ela pode lidar com qualquer arranjo experimental, permite uma estimativa mais precisa das variâncias e permite extrair mais informação. Para esse procedimento, recomenda-se que o usuário conheça noções básicas de análise de variância.

Os dados devem ser coletados de maneira aleatória, obtendo-se uma planilha similar àquela do método da média e amplitude. A Figura 79 apresenta um exemplo de planilha supondo 10 peças, 3 operadores e 2 repetições da medição.

Peças	Operadores						Totais T _{i..}
	1		2		3		
1	x	x	x	x	x	x	T _{1..}
2	x	x	x	x	x	x	T _{2..}
:	:	:	x _{ij1}	x _{ij2}	:	:	:
:	:	:	:	:	:	:	:
10	x	x	x	x	x	x	T _{10..}
Totais T _{.j.}	T _{.1.}		T _{.2.}		T _{.3.}		T...

Figura 79. Disposição dos dados para ANOVA
Fonte: Ribeiro e Ten Caten (2011)

A ANOVA resultará uma tabela assim:

Fontes de Variação	SQ	GL	MQ = SQ/GL	F calculado
Peças	SQp	n-1	MQp	MQp/MQpo
Operadores	SQo	k-1	MQo	MQo/MQpo
Peças X Operadores	SQpo	(n-1)(k-1)	MQpo	MQpo/MQe
Dispositivo (erro)	SQe	nk(r-1)	MQe	
Total	SQT	nkr-1		

As Somas Quadradas (SQ) de cada componente da tabela são obtidas pelas seguintes fórmulas:

$$SQp = \frac{\sum T_{i..}^2}{kr} - TC,$$

$$SQo = \frac{\sum T_{.j.}^2}{nr} - TC,$$

$$SQpo = \frac{\sum T_{ij.}^2}{r} - SQp - SQo - TC,$$

$$SQT = \sum x_{ijk}^2 - TC \text{ e}$$

$$SQe = SQT - SQp - SQo - SQpo,$$

onde

$$TC = \frac{T^2}{nkr},$$

n é o número de peças,

k é o número de operadores, e

r é o número de repetições.

A interpretação é a seguintes: se os valores calculados de F forem maiores que os valores tabelados de F, então a variabilidade provocada pelo termo correspondente é significativa. Dessa forma, pode-se obter os seguintes resultados:

- Peças significativo: Esse é um resultado desejável, indica que a variabilidade entre peças é maior que aquela devida ao dispositivo de medição.
- Operadores significativo: Esse resultado não é bom ou ruim, mas indica que a variabilidade entre operadores é maior que aquela devida ao dispositivo de medição.
- Interação significativo: Esse resultado não é esperado, pois em um estudo deste tipo não há motivos para existir uma interação significativa entre peças e operadores. É preciso investigar o que ocorreu e talvez o estudo tenha que ser refeito.

Normalmente a interação não significativa. Se isso ocorrer, é fortemente recomendado agregar a soma quadrada da interação ao erro, criando um termo de erro mais forte estatisticamente, com um maior número de graus de liberdade. Dessa forma, a Tabela ANOVA resultará:

Fontes de Variação	SQ	GL	MQ = SQ/GL	F calculado
Peças	SQp	n-1	MQp	MQp/MQagr
Operadores	SQo	k-1	MQo	MQo/MQagr
Dispositivo + interação (erro)	SQagr	nkr-n-k+1	MQagr	
Total	SQT	nkr-1		

A nova configuração apresenta uma nova fórmula dada por:

$$SQagr = SQe + SQpo.$$

A interpretação dos resultados para peças e operadores segue a mesma lógica vista acima. A partir das Médias dos Quadrados (MQ) é possível estimar os componentes de variação. Para o caso em que a interação é significativa, tem-se:

$$\begin{aligned}
VE &= 5,15\sqrt{MQe}, \\
VO &= 5,15\sqrt{\frac{MQo - MQpo}{nr}}, \\
VP &= 5,15\sqrt{\frac{MQp - MQpo}{kr}}, \\
Interação &= 5,15\sqrt{\frac{MQpo - MQe}{r}}, \\
R \& R &= \sqrt{VE^2 + VO^2 + I^2}, \text{ e} \\
VT &= \sqrt{R \& R^2 + VP^2}.
\end{aligned}$$

Para o caso em que a interação não é significativa, tem-se:

$$\begin{aligned}
VE &= 5,15\sqrt{MQagr}, \\
VO &= 5,15\sqrt{\frac{MQo - MQagr}{nr}}, \\
VP &= 5,15\sqrt{\frac{MQp - MQagr}{kr}}, \\
R \& R &= \sqrt{VE^2 + VO^2}, \text{ e} \\
VT &= \sqrt{R \& R^2 + VP^2}.
\end{aligned}$$

Se a estimativa de algum componente de variação resultar negativa, adota-se que seu valor é igual a zero. A contribuição percentual de cada parcela pode ser avaliada conforme visto antes, ou seja, dividindo pela variação total do processo ou pela tolerância.

Exemplo: Analise o sistema de medição do exemplo anterior pelo método da ANOVA, utilizando um nível de significância de 5%.

Resposta: F calculado p/peças (18,3), operadores (18,2) e interação (1,7). Agrupando-se, tem-se, F calculado p/peças (24,6), operadores (24,4). $VE = 6,12$, $VO = 6,63$, $VP = 12,14$, $R\&R = 9,02$ e $VT = 15,12$.

5.11. Sistemas de Medição para Atributos

Um estudo do sistema de medição para atributos utiliza um método diferente de avaliação, utilizando percentuais. O procedimento é o seguinte:

- Selecionando-se uma amostra aleatória de peças (50 ou mais)
- Dois ou mais operadores inspecionam esse conjunto de peças em duas ou mais oportunidades.
- Anota-se apenas as observações classificadas em ao menos uma oportunidade como defeituosas.
- Conta-se as discrepâncias de cada operador e entre os operadores.

O tamanho da amostra deve ser tal que apareçam ao menos 10 defeituosos. O percentual de discrepâncias de repetitividade é calculado pela razão entre o número de discrepâncias observadas e o número total possível de discrepâncias. O percentual de discrepâncias de reprodutibilidade é calculado pela razão entre a soma das amplitudes entre as contagens de defeituosos feitas por cada operador sobre cada peça e a soma do

número total possível dessas amplitudes. De forma geral, se os erros de repetitividade ou de reprodutibilidade não ultrapassarem a 20%, o sistema é aceito.

A análise das discrepâncias nos julgamentos irá revelar se há problemas no sistema de medição. Os problemas mais comuns em sistemas de medição de atributos são os seguintes:

- A definição de não-conformidade e não-conforme é deficiente, deixando margem para dúvidas.
- Os operadores não estão suficientemente treinados a respeito da definição.
- Há diferenças entre os gabaritos usados por diferentes operadores.

Exemplo: A tabela a seguir ilustra como deve ser feita a análise para o caso de três operadores avaliando duas vezes cada unidade. São apresentadas apenas as peças onde foram encontradas discrepâncias nas medições, sendo que nas colunas dos operadores, 1 representa a classificação da peça como defeituosa.

Operador 1			Erros		Operador 2		Erros		Operador 3		Erros		Erros	
p			Repet			Repet			Repet			Repro		
7			1			1			1			0		
23			0			0			1			1		
29			1			1			0			0		
51			1			0			0			2		
75			1			1			1			0		
121			1			0			1			0		
124			1			1			1			0		
152			1			0			0			2		
160			1			1			1			0		
178			1			0			1			0		
179			1			1			1			0		
191			1			0			1			0		
T			5			5			4					
T												14		
												7		

Foram encontradas 14 discrepâncias de repetitividade, quando o máximo seria 36 (3 operadores x 12 peças = 36). Assim, o percentual de discrepâncias de repetitividade é estimado por $14 / 36 = 39\%$. As discrepâncias de reprodutibilidade, avaliadas como a amplitude entre as contagens de defeituosos feitas por cada operador sobre cada peça somadas alcançaram o valor de 7. O máximo possível seria 24 (12 peças x número de ciclos que geram o número de discrepância nas observações = 24). Assim, o percentual de discrepâncias de repetitividade é estimado por $7 / 24 = 29\%$. Neste exemplo, tanto a repetitividade como a reprodutibilidade ultrapassaram 20%; portanto, o sistema de medição precisa ser melhorado nesses dois aspectos.

6. Gráficos de Controle Especiais

Os principais tipos de gráficos de controle foram apresentados no Capítulo 3. Entretanto existem outros tipos de gráficos de controle mais sofisticados. Alguns deles serão apresentados nesse capítulo.

Os gráficos de controle tradicionais de Shewhart para monitorar a média ou as observações individuais de um processo são eficazes para detectar mudanças na média maiores que $1,5\sigma$. Essa seção apresenta alguns gráficos de controle indicados para detectar pequenas mudanças na média do processo ($<1,5\sigma$).

Nessa seção também serão abordados gráficos para o caso em que os dados não são independentes (presença de correlação serial) e para monitorar mais de uma variável (caso multidimensional).

6.1. Gráfico de Controle de Somas Acumuladas (CUSUM).

Gráfico de Controle de Somas Acumuladas - CUSUM (*Cumulative Sum*) tem como característica o fato de ser mais sensível para detectar mudanças pequenas na média do processo, ou seja, ele detecta essas mudanças, mais rapidamente do que o gráfico tradicional de Shewhart. Entretanto, para detectar mudanças menores, o seu desempenho não é bom. Page (1961) apresenta o gráfico CUSUM, que utiliza somas acumuladas dos desvios das observações do valor alvo μ_0 . Segundo Moreira Junior (2005), esses gráficos são mais sensíveis que os gráficos de Shewhart para detectar mudanças pequenas na média do processo, pelo fato de incorporar todas as informações da sequência de observações.

A estimativa da soma acumulada até a i -ésima observação é dada por

$$C_i = \sum_{j=1}^i (\bar{x}_j - \mu_0)$$

onde

$\bar{x}_j$ é a média da j -ésima amostra, no caso de um gráfico CUSUM para monitorar a média (nesse caso, σ é substituído por $\sigma_{\bar{x}} = \sigma/\sqrt{n}$), ou é a j -ésima observação no caso de um gráfico CUSUM para monitorar as observações individuais.

Para ilustrar a eficiência do gráfico CUSUM, Montgomery (2004) realizou um estudo com 30 dados simulados de uma distribuição normal, sendo as 20 primeiras observações com média 10 e desvio padrão 1, e as 10 últimas com média 11 e desvio padrão 1, ou seja, uma mudança na média do processo em 1 desvio padrão. A Figura 80 apresenta o gráfico tradicional de Shewhart para observações individuais.




Figura 80. Gráfico tradicional de Shewhart para observações individuais
Fonte: adaptado de Montgomery (2004)

Como pode-se notar, não há, aparentemente, evidência de que o processo esteja fora de controle. Por outro lado, o gráfico CUSUM apresentado na Figura 81, mostra uma forte tendência positiva nas últimas observações. Uma tendência positiva indica que a média do processo é maior que o valor alvo; e uma tendência negativa indica que a média do processo é menor que o valor alvo.




Figura 81. Gráfico CUSUM
Fonte: adaptado de Montgomery (2004)

Pode-se notar que o gráfico da Figura 81 não é um gráfico de controle por não possuir limites de controle. Entretanto, existem alguns tipos de esquemas de gráficos CUSUM que utilizam limites de controle. Montgomery (2004) apresenta dois tipos de gráficos CUSUM: o CUSUM tabular (ou algorítmico) e a máscara V (V-mask).

O gráfico CUSUM tabular monitora duas somas em um único gráfico de controle. Essas somas são dadas pelas estatísticas C_i^+ e C_i^- , chamadas de unilaterais superior e inferior, respectivamente, e calculadas assim:

$$C_i^+ = \max[0, C_{i-1}^+ + (x_i - \mu_0) - K], \text{ e}$$

$$C_i^- = \max[0, C_{i-1}^- - (x_i - \mu_0) - K],$$

onde os valores iniciais são $C_0^+ = C_0^- = 0$, e K é o valor de referência.

O valor de referência K é a metade do tamanho da mudança na média que se quer detectar, em unidades de desvio padrão. Como $\mu_1 = \mu_0 + \delta\sigma$, então

$$K = \frac{\delta}{2}\sigma = \frac{|\mu_1 - \mu_0|}{2}$$

Se C_i^+ ou C_i^- exceder o intervalo de decisão H , então o processo estará fora de controle. Nesse caso, deve ser realizada uma ação corretiva, e então reinicializar o monitoramento do gráfico CUSUM do início. Segundo Montgomery (2004), um valor razoável para H é 5σ . A Figura 82 ilustra um gráfico CUSUM tabular para o exemplo anterior. Nesse caso, $K = 0,5$, pois a mudança que se quer detectar na média é de 1 desvio padrão, e $H = 5$, pois $\sigma = 1$.




Figura 82. Gráfico CUSUM Tabular
Fonte: adaptado de Montgomery (2004)

Apesar das fórmulas apresentadas anteriormente não admitirem valores negativos, o gráfico é feito dessa forma, com os valores de C_i^+ , acima do eixo das abscissas, e os valores de C_i^- , abaixo do eixo. Pode-se notar que as observações 29 e 30 apresentam-se fora de controle, sugerindo que há uma mudança positiva na média. Para identificar quando ocorreu a mudança na média, olha-se a primeira observação fora de controle (29), e diminui-se da quantidade de valores consecutivos de C_i^+ ou C_i^- depois do último valor zero. Nesse caso, o último valor zero para C_i^+ ocorreu na observação 22. Assim, a mudança de 1 desvio padrão na média ocorreu entre as observações 22 e 23 ($29 - 7 = 22$).

Outra variante desse gráfico é o CUSUM tabular padronizado. Kemp (1961) mostrou que esse gráfico é equivalente ao gráfico da máscara V . Este gráfico recebeu o nome de Esquema do Intervalo de Decisão (DIS – *Decision Interval Scheme*) e é construído pelo cálculo das estatísticas

$$C_i^+ = \max[0, C_{i-1}^+ + z_i - K], \text{ e}$$

$$C_i^- = \max[0, C_{i-1}^- - z_i - K],$$

onde $z_t = \frac{x_t - \mu_0}{\sigma_x}$ é a padronização da variável x_t que possui distribuição normal com

média μ_0 e desvio padrão σ_x para a variável z_t que possui distribuição normal com média 0 e desvio padrão 1.

As vantagens em utilizar o CUSUM padronizado são que muitos gráficos podem ter os mesmos valores H e K , já que esses não dependem de σ ; e que há uma condução natural para um CUSUM para controlar variabilidade.

Nota-se que tanto o CUSUM tabular quanto o CUSUM padronizado são para monitoramentos bilaterais (*two-sided*). C_i^+ monitora se há um aumento na média do processo, e C_i^- monitora se há uma diminuição. Essas estatísticas também podem ser monitoradas separadamente quando não houver interesse em monitorar as duas conjuntamente, sendo então chamadas de monitoramentos unilaterais (*one-sided*).

Para melhorar o desempenho do gráfico CUSUM para mudanças grandes na média, Lucas (1982) propõe o uso de um procedimento combinado de CUSUM e Shewhart. Nesse caso, os limites de controle de Shewhart devem ser colocados em aproximadamente $3,5 \sigma$ do valor alvo μ_0 .

Outra adaptação é a utilização do método FIR (*Fast Initial Response*), proposto por Lucas e Crosier (1982), que tem como objetivo melhorar a sensibilidade do gráfico CUSUM no início do processo. Consiste em apenas alterar os valores iniciais de C_0^+ e C_0^- para algum valor diferente de zero, geralmente $H/2$. Assim, se o processo começa sob controle em relação ao valor alvo, as somas irão rapidamente para zero e o método terá um pequeno efeito no desempenho do procedimento CUSUM. Entretanto, se o processo começa num valor diferente do valor alvo, o método detectará mais rapidamente a mudança na média. O gráfico da Figura 83 apresenta o método FIR aplicado ao CUSUM do exemplo anterior. Nesse caso, o gráfico não apresenta grandes alterações, e as conclusões são as mesmas obtidas anteriormente. Observa-se que as variações situam-se nas primeiras observações. Com o passar do tempo, esse gráfico vai tomando a forma do anterior, pois o método FIR se caracteriza por ser sensível no início do processo, onde, nesse caso, não há mudanças na média.




Figura 83. Gráfico CUSUM Tabular com o método FIR

Fonte: adaptado de Montgomery (2004)

Não será abordado o uso do gráfico CUSUM máscara V , pelo fato de ter desempenho semelhante ao CUSUM tabular, além de possuir algumas desvantagens, segundo Montgomery (2004), tais como, não é útil em processos unilaterais, o método FIR não pode ser usado e há dificuldades na interpretação.

6.2. Gráfico de Controle de Médias Móveis Exponencialmente Ponderadas (MMEP).

Com desempenho semelhante ao gráfico CUSUM, existe também a opção da utilização do Gráfico de Controle da Média Móvel Exponencialmente Ponderada (MMEP), ou EWMA (*Exponentially Weighted Moving Average*). O gráfico de controle MMEP é outra alternativa quando se deseja detectar mudanças pequenas na média do processo. O gráfico EWMA para valores individuais é definido pela estatística

$$z_i = \lambda x_i + (1 - \lambda)z_{i-1},$$

onde $0 < \lambda \leq 1$ é uma constante, e o valor inicial é dado pelo alvo

$$z_0 = \mu_0$$

ou, às vezes, estimado pela média dos dados

$$z_0 = \bar{x}$$

Não existe uma regra específica para a escolha apropriada do valor de λ para otimizar o desempenho do gráfico MMEP. Entretanto, Montgomery (2004) destaca que, para $0,05 \leq \lambda \leq 0,25$, há bons resultados na prática, e salienta que, uma boa estratégia para a escolha desse parâmetro seria utilizar valores pequenos de λ para detectar mudanças pequenas na média do processo.

O desvio padrão da estatística z_i é dado por

$$\sigma_{z_i} = \sqrt{\sigma^2 \left(\frac{\lambda}{2 - \lambda} \right) [1 - (1 - \lambda)^{2i}]}$$

Os limites de controle superior, central e inferior para o gráfico de controle EWMA são calculados, respectivamente, por

$$LCS = \mu_0 + L\sigma \sqrt{\frac{\lambda}{2 - \lambda} [1 - (1 - \lambda)^{2i}]},$$

$$LC = \mu_0, \text{ e}$$

$$LCI = \mu_0 - L\sigma \sqrt{\frac{\lambda}{2 - \lambda} [1 - (1 - \lambda)^{2i}]},$$

onde L é o fator de “alargamento” dos limites de controle. Montgomery (2004) salienta que $L = 3$ (usuais limites de controle 3σ) resulta em bons resultados principalmente se o valor de λ for grande, entretanto, quando λ for pequeno, há vantagens em reduzir os valores de L entre 2,6 e 2,8.

Nota-se que, a medida que o tamanho da amostra i aumenta, o termo $[1 - (1 - \lambda)^{2i}]$ se aproxima de 1. Dessa forma, os limites de controle superior e inferior convergem para um determinado valor.

No caso de monitoramento de médias através do gráfico MMEP, x_i deve ser substituído por $\bar{x}_i$ e σ deve ser substituído por $\sigma_{\bar{x}} = \sigma/\sqrt{n}$.

Utilizando-se os dados do exemplo da seção anterior, ao gráfico de controle MMEP, obtém-se o gráfico da Figura 84. Para esse exemplo foi utilizado o valor de

$\lambda = 0,1$ porque a intenção é detectar mudanças de um desvio padrão da média, e $L = 2,7$, pois o valor de λ é baixo.




Figura 84. Gráfico EWMA
Fonte: adaptado de Montgomery (2004)

O gráfico da Figura 84 sinaliza uma situação fora de controle na 28ª observação, indicando que o processo não está estável.

Existem ainda, variações do gráfico de controle MMEP. Por exemplo, o gráfico de controle combinado MMEP-Shewhart (CES), proposto por Lucas e Saccucci, segundo Dyer *et al.* (2003), consiste em aplicar os limites de controle do gráfico tradicional de Shewhart ao gráfico de controle MMEP.

6.3. Gráfico de Controle para Médias Móveis

Os gráficos de controle de médias móveis (M_t) também são indicados para detectar pequenas mudanças na média e para o controle automatizado, porém ele não é tão eficiente quanto os gráficos CUSUM e EWMA (MOREIRA JUNIOR, 2005). É recomendado o uso simultâneo de gráficos de controle de médias móveis com médias simples ou valores individuais (RIBEIRO; TEN CATEN, 2011).

A média móvel é recalculada a cada nova amostra (subgrupo), incorporando a amostra mais recente e descartando a amostra mais antiga. A média móvel de passo w (quantidade de observações consecutivas que irá compor a média a ser monitorada) é definida como:

$$M_t = \frac{\bar{x}_t + \bar{x}_{t-1} + \dots + \bar{x}_{t-w+1}}{w},$$

e a variância da média móvel é definida como:

$$\sigma_{M_t} = \frac{\sigma}{\sqrt{nw}}.$$

O nome “média móvel” se caracteriza pelo fato da média ser recalculada a cada observação (ou amostra, no caso de médias), de modo que ela assimila o próximo valor e despreza o último, calculando, assim, o valor a ser monitorado resultante de uma

média sempre de w observações, com exceção dos primeiros $w-1$ valores da série

Uma vez calculados M_t e σ_{M_t} , calcula-se os limites de controle considerando-se a amplitude de seis desvios-padrões (três para cima e três para baixo), que, segundo a distribuição Normal compreende 99,73% dos valores de médias amostrais. Baseada nos IC vistos anteriormente, a fórmula para obter os LC é:

$$LC = \bar{\bar{x}} \pm 3 \frac{\sigma}{\sqrt{nw}}.$$

Seguindo-se o mesmo raciocínio do tradicional gráfico de controle para a média, considerando que a variabilidade dos valores individuais é estimada a partir da média das amplitudes dos subgrupos, utiliza-se a relação:

$$\sigma = \frac{\bar{R}}{d_2},$$

Substituindo-se essa expressão na equação dos LC, obtém-se:

$$LC = \bar{\bar{x}} \pm \frac{3\bar{R}}{d_2\sqrt{nw}}.$$

Substituindo-se $A_2 = 3/(d_2\sqrt{nw})$ na equação anterior, tem-se, respectivamente o Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI), que são os mesmos do gráfico de controle para a média:

$$LCS = \bar{\bar{x}} + A_2\bar{R}, \text{ e}$$

$$LCI = \bar{\bar{x}} - A_2\bar{R}.$$

Nota-se que as primeiras $w-1$ observações não podem ser geradas pela expressão da média móvel de w passos. Dessa forma, as primeiras estimativas serão geradas pela média ponderada das primeiras observações até a observação de número w . Assim, esses limites de controle servirão para monitorar apenas a partir da observação w . Para as observações anteriores existem duas alternativas: uma consiste em simplesmente não monitorá-las, e a outra consiste em substituir nos limites de controle o valor de w por i .

Utilizando-se os dados do exemplo anterior, o gráfico de controle de média móvel é apresentado na Figura 85. Para esse exemplo foi utilizado um passo $w = 4$.




Figura 85. Gráfico de Controle para a Média Móvel
Fonte: adaptado de Montgomery (2004)

Observando o gráfico da Figura 85, há indícios de que pode ter ocorrido uma mudança na média do processo, pois aparecem 8 observações consecutivas acima da linha central. Porém o gráfico não apresenta pontos fora de controle, o que fortalece o fato do gráfico de médias móveis ser menos eficiente que os gráficos CUSUM e EWMA para detectar mudanças pequenas na média do processo.

6.4. Gráfico de Controle para a Mediana e para a Amplitude

Algumas vezes, monitorar a mediana ($\tilde{x}$) em vez da média pode trazer vantagens, pois a mediana é mais fácil de calcular que a média e não é influenciada quando existem dados atípicos (*outlier*).

Para calcular a mediana, deve-se colocar os dados em ordem crescente e identificar o valor central. Em função disso, muitas vezes o monitoramento da mediana é feito plotando em um gráfico de controle todos os valores individuais (os quais ficam automaticamente em ordem crescente) e assinalando o valor mediano. Para esse procedimento ser prático, recomenda-se que o subgrupo seja pequeno e de tamanho ímpar (3, 5 ou 7).

O Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI) para a mediana são dados, respectivamente, por:

$$LCS = \bar{\tilde{x}} + \tilde{A}_2 \bar{R}, \text{ e}$$

$$LCI = \bar{\tilde{x}} - \tilde{A}_2 \bar{R},$$

onde

$\bar{\tilde{x}}$ é a média das medianas de cada subgrupo, e

$\tilde{A}_2$ é uma constante que depende do tamanho da amostra, conforme mostra a tabela abaixo (Fonte: Ribeiro e Ten Caten, 2011):

n	2	3	4	5	6	7	8	9	10
$\tilde{A}_2$	1,88	1,19	0,80	0,69	0,55	0,51	0,43	0,41	0,36

O Limite de Controle Superior (LCS) e o Limite de Controle Inferior (LCI) para a amplitude, como visto anteriormente no Capítulo 3, são dados, respectivamente, por:

$$LCS = D_4 \bar{R}, \text{ e}$$

$$LCI = D_3 \bar{R}.$$

Exemplo: Considere os seguintes dados, referentes a 15 amostras de tamanho igual a 5 cada uma. Calculando-se os limites de controle para monitorar a média e a amplitude, obtêm-se os gráficos da Figura 86. (Fonte: Ribeiro e Ten Caten, 2011).

Amostra	Obs1	Obs2	Obs3	Obs4	Obs5
1	65	70	75	60	80
2	75	70	80	90	70
3	80	70	70	80	80
4	65	65	65	80	65
5	80	60	80	80	75
6	75	70	60	85	75
7	80	75	65	75	70
8	70	65	75	65	85
9	85	85	75	65	80
10	65	65	65	80	60
11	75	60	75	85	90
12	85	65	75	75	80
13	70	75	75	70	70
14	70	65	85	60	75
15	75	80	85	80	90





Figura 86. Exemplo de gráfico para mediana e para a amplitude
Fonte: Ribeiro e Ten Caten (2011)

Observa-se que não há causas especiais, portanto o processo está sob controle.

6.5. Gráficos para dados autocorrelacionados.

Os gráficos de controle tradicionais pressupõem que as observações sejam independentes. Entretanto, na prática, existem processos onde as observações não são independentes. Como foi visto anteriormente, o uso de gráficos de controle não possui um bom desempenho quando os dados possuem correlação serial (causas estruturais), podendo surgir falsos alarmes indicando uma situação “fora de controle” quando na verdade eles são devidos a causas naturais de um processo autocorrelacionado. Nessas situações, é necessário primeiramente tratar os dados para eliminar o efeito da autocorrelação do processo, para posteriormente controlá-los estatisticamente.

Para o tratamento dos dados autocorrelacionados, muitos métodos têm sido propostos. Eles podem ser classificados em três grupos: (i) aqueles que sugerem um ajuste por modelos ARIMA (Auto-Regressivo Integrado de Média Móvel) e posteriormente o monitoramento dos resíduos através de algum gráfico de controle tradicional (para observações individuais, CUSUM, EWMA, etc.), (ii) aqueles que propõem modificações nos limites dos gráficos de controle e (iii) outras técnicas específicas (MOREIRA JUNIOR, 2005).

6.5.1. Metodologia Box-Jenkins aplicada ao CEP

Um dos tratamentos sugeridos e mais utilizados para o tratamento dos processos com dados autocorrelacionados é o ajuste de um modelo adequado de série temporal ARIMA (modelos Box-Jenkins) que remova a autocorrelação dos dados, para posterior monitoramento dos resíduos através de algum gráfico de controle tradicional. O ajuste por um modelo ARIMA adequado tem por objetivo separar as causas estruturais, identificadas no modelo estimado, das causas comuns e especiais, observadas no gráfico de resíduos. Nisso consiste a metodologia Box-Jenkins para modelos ARIMA, desenvolvida por Box e Jenkins (1970) e voltada para a área de séries temporais, geralmente focadas para análise de dados econômicos. A Figura 87, apresentada por Makridaskis et al. (1998), sumariza as etapas do desenvolvimento dessa metodologia.

Um modelo ARIMA pode ser identificado através da análise visual de dois gráficos de correlogramas:

- Função de Autocorrelação (ACF ou FAC) e
- Função de Autocorrelação Parcial (PACF ou FACP).

Através de padrões de comportamento desses gráficos de correlogramas, descrito no Quadro 4, pode-se identificar um modelo ARIMA(p,d,q) adequado, onde:

p é a quantidade de termos autoregressivos,

q é a quantidade de termos de média móvel e

o valor de d indica quantas vezes a série teve que ser diferenciada, se necessário, para se obter estacionariedade nos dados.

Em geral, a falta de estacionariedade, isto é, a média, a variância, ou ambas não são constantes no processo, pode ser evidenciada quando o correlograma da FAC apresenta uma queda lenta para zero (Figura 88). Fischer (1982) apresenta algumas dicas para a obtenção do valor de d . Segundo ele, na prática, a maioria das séries não estacionárias pode ser modelada por um $d = 1$ ou um $d = 2$, os quais caracterizam a série quanto ao nível e/ou quanto à inclinação. Necessita-se de $d = 1$ quando a série é não estacionária quanto ao nível do processo, isto é, quando o comportamento da série oscila em torno de uma média durante um certo período de tempo e depois ocorre uma mudança na média da série que passa a oscilar em torno dessa nova média, sem que haja

uma troca significativa na direção da série. Nesse caso, diz-se que a série é não estacionária de grau um ou que apresenta uma tendência estocástica em relação ao nível da série. Por outro lado, necessita-se de $d = 2$ quando a série é não estacionária também quanto à inclinação, ou seja, quando o comportamento da série oscila em uma direção por um certo período, e depois muda para outra direção. Também pode-se fazer um teste específico para verificar a falta de estacionaridade nos dados.




Figura 87. Metodologia Box-Jenkins para modelos ARIMA
Fonte: Makridaskis et al. (1998)

Após a preparação dos dados e a identificação dos modelos candidatos por meio das análises dos correlogramas, é feito o ajuste desses modelos. É analisado se os parâmetros dos modelos são significativos, e outros critérios são avaliados, tais como o AIC - *Akaike Information Criterium*, o BIC - *Bayesian Akaike Information Criterium* e a variância residual. Após isso, um modelo é selecionado e os seus resíduos são analisados por meio de uma nova análise de correlogramas para verificar se toda a autocorrelação foi removida. Se o modelo teve um bom ajuste, os resíduos não serão autocorrelacionados, ou seja, eles serão considerados “ruído branco”, isto é, *iid*

(independentes e identicamente distribuídos). Em outras palavras, eles não possuem autocorrelação e possuem a mesma distribuição de probabilidade. Então, no contexto de séries temporais, o modelo pode ser utilizado para fazer previsões. No contexto do CEP, para a aplicação de um gráfico de controle tradicional, por exemplo, para valores individuais, os resíduos devem ter distribuição normal. Um teste de normalidade pode ser aplicado aos resíduos para verificar isso.

Modelo ARIMA	Comportamento do correlograma da FAC	Comportamento do correlograma da FACP
(p,d,0)	decai exponencialmente, alternando ou não o sinal, ou com um padrão de onda senoidal amortecida.	As p primeiras defasagens são significativamente diferentes de zero.
(0,d,q)	As q primeiras defasagens são significativamente diferentes de zero.	decai exponencialmente, alternando ou não o sinal, ou com um padrão de onda senoidal amortecida.
(p,d,q)	decai exponencialmente, alternando ou não o sinal.	decai exponencialmente, alternando ou não o sinal.

Quadro 4. Padrões de comportamento dos correlogramas da FAC e

Fonte: adaptado de Tolo e Morettin (1985)




Figura 88. Comportamentos típicos de correlogramas de séries não-estacionárias

Fonte: Software NCSS

A Figura 89 apresenta um Gráfico de Controle Tradicional para monitorar a média. Observa-se que um que, aparentemente, várias observações estão fora dos limites de controle do gráfico, entretanto, essas observações não são causas especiais, como aparentam ser, mas são causas estruturais e naturais do processo.

Foram obtidos os correlogramas da FAC (Figura 90) e da FACP (Figura 91), os quais sugerem, pelo seu padrão de comportamento, que os dados possam ser ajustados por um Modelo ARIMA(1,0,0) ou AR(1). Dessa forma é feito um ajuste no Modelo proposto (Figura 92) e são obtidos os correlogramas da FAC (Figura 93) e da FACP (Figura 94) dos resíduos para verificar a independência dos dados. Após constatar a remoção da autocorrelação, o gráfico de controle pode ser aplicado nos resíduos (Figura 95), lembrando que os resíduos são valores individuais.




Figura 89. Gráfico de Controle de um Processo com autocorrelação

V1




Figura 90. Correlograma da FAC




Figura 91. Correlograma da FACP




Figura 92. Gráfico do Modelo ajustado AR(1) com previsão




Figura 93. Correlograma da FAC dos resíduos




Figura 94. Correlograma da FACP dos resíduos

O gráfico da Figura 95 apresenta o monitoramento dos resíduos (que são valores individuais) através do gráfico de controle para valores individuais do CEP tradicional. A aplicação de alguns testes estatísticos mostrou que esses resíduos são *iid*, isto é, são independentes e identicamente distribuídos com Distribuição Normal. Esse gráfico não apresenta causas especiais. Dessa forma, conclui-se que as causas especiais apontadas

anteriormente na análise preliminar eram alarmes falsos. Portanto, o processo está sob controle estatístico.




Figura 95. Gráfico de Controle dos Resíduos

6.6. Gráficos de Controle Multivariados

Os gráficos de controle vistos até o momento abordavam o monitoramento do processo sob uma perspectiva univariada, ou seja, para o caso onde há somente uma variável de saída do processo, isto é, apenas uma característica da qualidade de interesse. No entanto, na prática, os cenários de monitoramento geralmente envolvem várias variáveis relacionadas. Embora seja possível monitorar cada característica individualmente (um ou mais gráficos de controle para cada variável), esse procedimento pode levar a conclusões errôneas.

Por exemplo, suponha que a produção de certo componente precisa monitorar duas variáveis relacionadas, de tal forma que o componente só pode ser aproveitado se houver uma coerência entre a observação monitorada nessas duas variáveis. Tal condição não é possível de detectar em gráficos de controle univariados. Por exemplo, considere um processo de fabricação de um mancal onde os diâmetros interno (x_1) e externo (x_2) determinam o aproveitamento da peça (MONTGOMERY, 2004). Ambas as características podem ser monitoradas independentemente por meio de um gráfico de controle para a média, conforme mostra a Figura 96. Como pode-se observar, os dois processos parecem estar sob controle.




Figura 96. Gráficos de Controle para a média dos diâmetros interno (x_1) e externo (x_2)

Fonte: Montgomery, 2004.

Entretanto, posteriormente a essa monitoração constatou-se que uma dessas amostras produziu peças que não puderam ser aproveitadas na prática, embora nada tenha sido detectado no monitoramento do processo. Isso ocorreu porque essas variáveis são correlacionadas diretamente, ou seja, se a medida do diâmetro interno for grande e a do externo for pequena (ou vice-versa), a peça produzida não será boa. Ao observar-se um gráfico de dispersão entre essas variáveis, pode-se notar que existe um par de observações que parece ter um comportamento diferente em relação às demais observações, conforme mostra a Figura 97. No entanto, é praticamente impossível detectar-se uma causa atribuível como essa, mantendo-se gráficos de controle individuais. Dessa forma, uma alternativa para situações desse tipo seria a utilização de gráficos de controle multivariados, os quais criam uma estatística única para ser monitorada.




Figura 97. Uma elipse de controle para duas variáveis dependentes
Fonte: Montgomery, 2004.

Observa-se que, se algum ponto no gráfico de correlação estiver fora dos limites da chamada “elipse de controle”, o processo está fora de controle. Entretanto, essa elipse de controle possui duas desvantagens: (1) perde-se a sequência temporal dos dados, e (2) não se consegue monitorar mais de duas variáveis. Uma alternativa é a utilização do gráfico de controle T^2 de Hotelling.

Existem vários tipos de gráficos de controle multivariados. Nessa seção será abordado o gráfico de controle T^2 de Hotelling, que pode ser utilizado para monitorar a média ou as observações individuais. Aqui será apresentada a versão para monitorar a média das observações. Nesse gráfico de controle, os dados originais das características monitoradas não são utilizados diretamente. O que será monitorada é a estatística T^2 a qual depende dos dados originais para ser calculadas. Para o caso de duas variáveis monitoradas (caso bidimensional, ou seja, $p = 2$, supondo que as variáveis tenham distribuições normais), a estatística T^2 é dada por:

$$T_i^2 = \frac{n}{\bar{S}_1^2 \bar{S}_2^2 - \bar{S}_{12}^2} \left[\bar{S}_2^2 (\bar{x}_{i1} - \bar{\bar{x}}_1)^2 + \bar{S}_1^2 (\bar{x}_{i2} - \bar{\bar{x}}_2)^2 - 2\bar{S}_{12} (\bar{x}_{i1} - \bar{\bar{x}}_1)(\bar{x}_{i2} - \bar{\bar{x}}_2) \right],$$

onde:

n é o tamanho do subgrupo ou amostra i ,

i é o subgrupo ou amostra, variando de 1 até m ,

T_i^2 possui distribuição qui-quadrado com dois graus de liberdade,

$\bar{\bar{x}}_1$ é a média das médias da variável 1,

$\bar{\bar{x}}_2$ é a média das médias da variável 2,

$\bar{x}_{i1}$ é a média da amostra i da a variável 1,

$\bar{x}_{i2}$ é a média da amostra i da a variável 2,

$\bar{S}_1^2$ é a média da variância da variável 1,

$\bar{S}_2^2$ é a média da variância da variável 2, e

$\bar{S}_{12}$ é a média da covariância entre as variáveis 1 e 2.

Para o cálculo dos limites de controle, há duas fases distintas. Na primeira fase, o objetivo é obter um conjunto de observações sob controle, de modo que os limites de controle possam ser estabelecidos para a segunda fase (monitoramento da produção futura). Os LC para o gráfico de controle T^2 de Hotelling na fase 1 são dados por:

$$LSC = \frac{p(m-1)(n-1)}{mn-m-p+1} F_{\alpha, p, mn-m-p+1}, e$$

$$LIC = 0.$$

Os LC para o gráfico de controle T^2 de Hotelling na fase 2 são dados por:

$$LSC = \frac{p(m+1)(n-1)}{mn-m-p+1} F_{\alpha, p, mn-m-p+1}, e$$

$$LIC = 0.$$

A Figura 98 apresenta um gráfico de controle T^2 de Hotelling (fase 1), considerando $\alpha = 0,001$. Observa-se que, nesse caso, não há pontos fora de controle.




Figura 98. Exemplo de um gráfico de controle T^2 de Hotelling

Fonte: Montgomery, 2004.

Os gráficos de controle multivariados tradicionais perdem eficiência se o número de variáveis a serem monitoradas for grande (geralmente, acima de 10). Uma alternativa possível seria reduzir a quantidade de variáveis, por exemplo, através do uso da técnica multivariada de componentes principais.

6.7. Outros Gráficos de Controle

Existem vários outros gráficos além dos gráficos de controles apresentados aqui. O leitor poderá verificar essa informação por meio de buscas de artigos científicos sobre o assunto. Merecem destaques, por exemplo, os gráficos de controle de regressão (PEDRINI; TEN CATEN, 2011; JACOBI; SOUZA; PEREIRA, 2002) e os gráficos de controle para “produções pequenas” (PEREIRA; REQUEIJO, 2011).

Referências

BRASSARD, M. **Qualidade. Ferramentas para uma Melhoria Contínua**. Rio de Janeiro: Qualitymark, 2004.

DYER, J. N.; ADAMS, B. M.; CONERLY, M. D. The Reverse Moving Average Control Chart for Monitoring Autocorrelated Processes. **Journal of Quality Technology**, v. 35, n. 2, p. 139-152, 2003.

FIOD NET, M. **Taguchi e a Melhoria da Qualidade: Uma Releitura Crítica**. Florianópolis: Editora da UFSC, 1997.

FISCHER, S. **Séries Univariantes de Tempo** – metodologia de Box & Jenkins. Porto Alegre, FEE, 1982.

JACOBI, L. F.; SOUZA, A. M.; PEREIRA, J. E. S. Gráfico de controle de regressão aplicado na monitoração de processos. **Revista Produção**, v. 12, n. 1, p. 46-59, 2002.

KEMP, K. W. The average run length of a cumulative sum chart when V-mask is used. **Journal of Royal Statistics Society B**, 23, pp.149-153, 1961.

KUME, H. **Métodos Estatísticos para Melhoria da Qualidade**. São Paulo: Editora Gente, 1993.

LOPES, L. F. D. **Controle Estatístico de Processo**. Apostila do Curso de Especialização em Estatística e Modelagem Quantitativa da UFSM. Santa Maria, 2007.

LUCAS, J. M. Combined Shewhart-CUSM quality control schemes. **Journal of Quality Technology**, v. 14, p. 51-59, 1982.

LUCAS, J. M.; CROSIER, R. B. Fast Initial Response for CUSUM Quality Control Schemes: Give Your CUSUM a Head Start. **Technometrics**, 24, 199–205, 1982.

MAKRIDASKIS, S. et al. **Forecasting – Method and Applications**. 3ª Edição. New York: John Wiley & Sons, 1998.

MONTGOMERY, D. C. **Introdução ao Controle Estatístico da Qualidade**. 4. Ed. Rio de Janeiro: Editora LTC, 2004.

MONTGOMERY, D. C. **Introduction to Statistical Quality Control**. 6. Edição. Hoboken: John Wiley & Sons, 2009.

MONTGOMERY, D. C. **Introdução ao Controle Estatístico da Qualidade**. 7. Ed. Rio de Janeiro: Editora LTC, 2017.

MOREIRA JUNIOR, F. J. **Proposta de um Método para Controle Estatístico de Processo para Observações Autocorrelacionadas**. Dissertação de Mestrado do Programa de Pós-Graduação em Engenharia de Produção – Escola de Engenharia, Universidade Federal do Rio Grande do Sul. Porto Alegre, 2005

MOREIRA JUNIOR, F. J.; TEN CATEN, C. S. Estudo sobre o efeito da Correlação Serial de Modelos AR(1) no Controle Estatístico de Processo. In: **III Semana da Engenharia de Produção**, PPGE/UFRGS. Porto Alegre, 2003.

PAGE, E. S. Cumulative Sum Charts. **Technometrics**, v. 3, n. 1, p. 1-9, 1961.

PEDRINI, D. C.; TEN CATEN, S. C. Método para aplicação de gráficos de controle de regressão no monitoramento de processos. **Produção**, v. 21, n. 1, p. 106-117, jan./mar. 2011

PEREIRA, Z. L.; REQUEIJO, J. G. **Controle Estatístico do Processo aplicado às “pequenas produções”**. Santa Maria: Faculdade de Ciências e Tecnologia, universidade Nova de Lisboa, 2011.

RIBEIRO, J. L. D.; TEN CATEN, C. **Controle Estatístico do Processo**. Série monográfica Qualidade. Fundação Empresa Escola de Engenharia da UFRGS, Universidade Federal do Rio Grande do Sul, Escola de Engenharia, Programa de Pós Graduação em Engenharia de Produção. Porto Alegre, RS, 2011.

RIBEIRO, J. L. D.; TEN CATEN, C. **Controle Estatístico do Processo**. Série monográfica Qualidade. Fundação Empresa Escola de Engenharia da UFRGS, Universidade Federal do Rio Grande do Sul, Escola de Engenharia, Programa de Pós Graduação em Engenharia de Produção. Porto Alegre, RS, 2012.

R CORE TEAM. **R: A language and environment for statistical computing**. R Foundation for Statistical Computing, Vienna, Austria, 2019. URL <https://www.R-project.org/>.

ROCHA, H. M.; NONOHAY, R. G. **Administração da Produção**. Porto Alegre: Sagah Educação S. A, 2016.

ROSS, P. J. **Aplicações das Técnicas de Taguchi na Engenharia da Qualidade**. Rio de Janeiro: Makron Books, 1991.

SCRUCCA, L. qcc: an R package for quality control charting and statistical process control. **R News**, 4/1, 11-17, 2004.

TOLOI, C. M; C.; MORETTIN, P. A. **Previsão de Séries Temporais**. São Paulo: Atual Editora, 1985.

WERKEMA, M. C. C. **As ferramentas da qualidade no gerenciamento de processos**. Belo Horizonte: Editora de Desenvolvimento Gerencial, 1995.

ZALEWSKI, D. J.; MYKYTKA, E. F. A Management Framework for Process Control and Capability in the Presence of Autocorrelation. **International Association for Management of Technology**, 2001.

Anexos

A – Guia para seleção da técnica de acordo com a questão que se deseja trabalhar

B – Fluxograma auxiliar para a escolha do Gráfico de Controle

C – Valores das Constantes utilizadas no CEP

D – valores da constante d_2

E – Fórmulas para o estudo de R&R pelo método da média e amplitude

ANEXO A

Questão	Técnica
1. Decidir que o problema deverá ser resolvido primeiro	• Fluxograma • <i>Brainstorming</i> • Folha de verificação • Gráfico de Pareto • Técnica de grupo
2. Checar a uma declaração que descreve o problema em termos de o que é especificamente, onde ocorre, quando acontece a sua extensão	• Folha de verificação • Gráfico de Pareto • Gráfico seqüencial • Histograma • Gráfico de setores • Estratificação
3. Desenvolver uma fotografia completa de todas as possíveis causas do problema	• Folha de verificação • Gráfico de Pareto • Técnica de grupo • Diagrama de dispersão • <i>Brainstorming</i>
4. Concordância sobre as causas do problema	• Folha de verificação • Gráfico de Pareto • Técnica de grupo • Diagrama de dispersão • <i>Brainstorming</i>
5. Desenvolver uma efetiva e implementável solução e um plano de ação	• <i>Brainstorming</i> • Análise de força de campo • Apresentação a gerência • Gráfico de setores • Gráfico de barras
6. Implementar a solução e estabelecer necessidade de procedimentos de monitoração e gráficos	• Gráfico de Pareto • Histograma • Gráfico de controle • Capabilidade do processo

Tabela 9. Guia para seleção da técnica de acordo com objetivo da análise

Fonte: Lopes (2007)

ANEXO B




Figura 99. Fluxograma auxiliar para a escolha do Gráfico de Controle
Fonte: Adaptado de Ribeiro e Ten Caten (2011)

ANEXO C – Valores das Constantes utilizadas no CEP

n	Gráfico para a Média			Gráfico para o Desvio Padrão						Gráfico para a Amplitude						
	Fatores para os Limites de Controle			Fatores para a Linha Central		Fatores para os Limites de Controle				Fatores para a Linha Central		Fatores para os Limites de Controle				
	A	A ₂	A ₃	c ₄	1/c ₄	B ₃	B ₄	B ₅	B ₆	d ₂	1/d ₂	d ₃	D ₁	D ₂	D ₃	D ₄
2	2,121	1,880	2,659	0,7979	1,2533	0	3,627	0	2,606	1,128	0,8865	0,953	0	3,686	0	3,267
3	1,732	1,023	1,954	0,8862	1,1284	0	2,568	0	2,276	1,693	0,5907	0,888	0	4,358	0	2,575
4	1,500	0,729	1,628	0,9213	1,0854	0	2,266	0	2,088	2,059	0,4857	0,880	0	4,698	0	2,282
5	1,342	0,577	1,427	0,9400	1,0638	0	2,089	0	1,964	2,326	0,4299	0,864	0	4,918	0	2,115
6	1,225	0,483	1,287	0,9515	1,0510	0,030	1,970	0,029	1,874	2,534	0,3946	0,848	0	5,078	0	2,004
7	1,134	0,419	1,182	0,9594	1,0423	0,118	1,882	0,113	1,806	2,704	0,3698	0,833	0,204	5,204	0,076	1,924
8	1,061	0,373	1,099	0,9650	1,0363	0,185	1,815	0,179	1,751	2,847	0,3512	0,820	0,388	5,306	0,136	1,864
9	1,000	0,337	1,032	0,9693	1,0317	0,239	1,761	0,232	1,707	2,970	0,3367	0,808	0,547	5,393	0,184	1,816
10	0,949	0,308	0,975	0,9727	1,0281	0,284	1,716	0,276	1,669	3,078	0,3249	0,797	0,687	5,469	0,223	1,777
11	0,905	0,285	0,927	0,9754	1,0252	0,321	1,679	0,313	1,637	3,173	0,3152	0,787	0,811	5,535	0,256	1,744
12	0,866	0,266	0,886	0,9776	1,0229	0,354	1,646	0,346	1,610	3,258	0,3069	0,778	0,922	5,594	0,283	1,717
13	0,832	0,249	0,850	0,9794	1,0210	0,382	1,618	0,374	1,585	3,336	0,2998	0,770	1,025	5,647	0,307	1,693
14	0,802	0,235	0,817	0,9810	1,0194	0,406	1,594	0,399	1,563	3,407	0,2935	0,763	1,118	5,696	0,328	1,672
15	0,775	0,223	0,789	0,9823	1,0180	0,428	1,572	0,421	1,544	3,472	0,2880	0,756	1,203	5,741	0,347	1,653
16	0,750	0,212	0,763	0,9835	1,0168	0,448	1,552	0,440	1,526	3,532	0,2831	0,750	1,282	5,782	0,363	1,637
17	0,728	0,203	0,739	0,9845	1,0157	0,466	1,534	0,458	1,511	3,588	0,2787	0,744	1,356	5,820	0,378	1,622
18	0,707	0,194	0,718	0,9854	1,0148	0,482	1,518	0,475	1,496	3,640	0,2747	0,739	1,424	5,856	0,391	1,608
19	0,688	0,187	0,698	0,9862	1,0140	0,497	1,503	0,490	1,483	3,689	0,2711	0,734	1,487	5,891	0,403	1,597
20	0,671	0,180	0,680	0,9869	1,0133	0,510	1,490	0,504	1,470	3,735	0,2677	0,729	1,549	5,921	0,415	1,585
21	0,655	0,173	0,663	0,9876	1,0126	0,523	1,477	0,516	1,459	3,778	0,2647	0,724	1,605	5,951	0,425	1,575
22	0,640	0,167	0,647	0,9882	1,0119	0,534	1,466	0,528	1,448	3,819	0,2618	0,720	1,659	5,979	0,434	1,566
23	0,626	0,162	0,633	0,9887	1,0114	0,545	1,455	0,539	1,438	3,858	0,2592	0,716	1,710	6,006	0,443	1,557
24	0,612	0,157	0,619	0,9892	1,0109	0,555	1,445	0,549	1,429	3,895	0,2567	0,712	1,759	6,031	0,451	1,548
25	0,600	0,153	0,606	0,9896	1,0105	0,565	1,435	0,559	1,420	3,931	0,2544	0,708	1,806	6,056	0,459	1,541

Para n > 25

$$A = \frac{3}{\sqrt{n}}, A_3 = \frac{3}{c_4 \sqrt{n}}, c_4 \cong \frac{4(n-1)}{4n-3}, B_3 = 1 - \frac{3}{c_4 \sqrt{2(n-1)}}, B_4 = 1 + \frac{3}{c_4 \sqrt{2(n-1)}}, B_5 = c_4 - \frac{3}{\sqrt{2(n-1)}}, B_6 = c_4 + \frac{3}{\sqrt{2(n-1)}}$$

Tabela 10. Constantes utilizadas no CEP

ANEXO D

m	2	3	4	5	6	7	8	9	10	15
g										
1	1,41	1,91	2,24	2,48	2,67	2,83	2,96	3,08	3,18	3,55
5	1,19	1,74	2,10	2,36	2,56	2,73	2,87	2,99	3,10	3,49
10	1,16	1,72	2,08	2,34	2,55	2,72	2,86	2,98	3,09	3,48
15	1,15	1,71	2,07	2,34	2,54	2,71	2,85	2,98	3,08	3,48
30	1,128	1,693	2,059	2,326	2,534	2,704	2,847	2,970	3,078	3,472

Tabela 11. Valores da constante d_2

ANEXO E

Repetitividade (variação do equipamento) $R_{\text{bar}} = (R_A + R_B + \dots) / N^\circ \text{ de operadores}$ $\sigma_e = R_{\text{bar}} / d_2$ $VE = 5,15 \sigma_e$	$VE \% = 100 \times VE / VT$ ou $VE \% = 100 \times VE / \text{Tol.}$
Reprodutibilidade (variação do operador) $R_o = (X_{\text{bar max}} - X_{\text{bar min}}) \text{ (entre operadores)}$ $VO =$ $\sqrt{\left(5,15 \frac{R_o}{d_2}\right)^2 - \frac{(5,15 \times \sigma_e)^2}{nr}}$ $\sigma_o = VO / 5,15$	$VO \% = 100 \times VO / VT$ ou $VO \% = 100 \times VO / \text{Tol.}$
Repetitividade e Reprodutibilidade $\sigma_m = \sqrt{\sigma_e^2 + \sigma_o^2}$ $R\&R = 5,15 \sigma_m \quad \text{ou}$ $R\&R = \sqrt{VE^2 + VO^2}$	$R\&R \% = 100 \times R\&R / VT$ ou $R\&R \% = 100 \times R\&R / \text{Tol.}$
Variação peça a peça $R_p = (X_{\text{bar max}} - X_{\text{bar min}}) \text{ (entre peças)}$ $\sigma_p = R_p / d_2$ $VP = 5,15 \sigma_p$	$VP \% = 100 \times VP / VT$ ou $VP \% = 100 \times VP / \text{Tol.}$
Variação total $VT = \sqrt{R\&R^2 + VP^2}$	

Quadro 5. Fórmulas para o estudo de R&R pelo método da média e amplitude